

Aprendizaje Automático

Aprendizaje no supervisado

Manuel Pegalajar Cuéllar¹

¹Departamento de Ciencias de la Computación e Inteligencia Artificial. Universidad de Granada

Contenido

- 1 Aprendizaje no supervisado
- 2 Clustering
- 3 Reglas de asociación
- 4 Ejercicios y entrega

1 Aprendizaje no supervisado

2 Clustering

3 Reglas de asociación

4 Ejercicios y entrega

Hay 3 tipos básicos de aprendizaje automático:

- **Supervisado**: Dado un conjunto de patrones (datos) de entrada X , se desea predecir el valor de otro patrón de salida y . El conjunto de datos (X, y) se conoce a priori.
- **No Supervisado**: Existe un conjunto de patrones (datos) de entrada X , pero **no existen patrones de salida** y .
- **Por Refuerzo**: No existen datos X ni y a priori. Se aprende a partir de la experiencia.

Aprendizaje no supervisado

Dentro del **aprendizaje no supervisado** existen diferentes problemas que se pueden abordar:

- **Clustering**: Abstracción de datos. Consiste en identificar agrupaciones de los datos en conjuntos denominados **clusters**.
- **Detección de anomalías**: Dado un conjunto de datos, identificar qué patrones pueden ser “*normales*” y cuáles *raros* o *anómalos*.
- **Inferencia de reglas de asociación**: Detección de dependencias entre datos explicables como implicaciones del tipo $X \rightarrow Y$.
- **Reducción de dimensionalidad**: Aprendizaje de atributos o extracción de características relevantes para el problema con una dimensionalidad inferior a la del conjunto de datos original.

En la práctica abordamos dos: **Clustering** y **Extracción de reglas de asociación**.

Contenido



- 1 Aprendizaje no supervisado
- 2 Clustering**
- 3 Reglas de asociación
- 4 Ejercicios y entrega

Clustering

El problema del **Clustering** (*agrupamiento*) consiste en la abstracción de los datos, identificando relaciones entre los mismos, de modo que puedan agruparse en **categorías** o **clusters**.

Hay varios enfoques:


- Modelos basados en centroides
- Modelos basados en densidad
- Modelos jerárquicos



Clustering: K-Means

El algoritmo **k-Means** es un algoritmo basado en centroides. Se dispone de una “plantilla” (**centroide**) para un total de k clusters (**k** hiperparámetro), que se van ajustando iterativamente.

Se requiere definir una medida de distancia entre elementos del conjunto de datos (distancia euclídea, de Manhattan, DTW...)



Clustering: K-Means

K-Means sigue el principio de **Expectation-Maximization**. En cada iteración...

- 1 el paso **Expectation** asigna cada elemento del conjunto de datos al cluster más cercano.
- 2 el paso **Maximization** recalcula el centroide de cada cluster.

La función de pérdida a optimizar por el algoritmo es la siguiente:

$$J = \sum_{k=1}^K \sum_{i=1}^N w_{i,k} d(x^{(i)}, c^k)^2$$

- K es el número de clusters. N el de patrones.
- $x^{(i)}$ es el i -ésimo patrón. c^k el k -ésimo cluster.
- $w_{i,k}$ vale 1 si $x^{(i)}$ pertenece al cluster k y 0 en otro caso.
- $d(\cdot, \cdot)$ es una medida de distancia.

Clustering: K-Means

El pseudocódigo de **K-Means** es el siguiente:

```
1 C= {c1, c2, ..., cK} # Inicializar centroides
2
3 Repetir hasta criterio de parada:
4     Inicializar  $w(i,k) = 0$  para todo  $1 \leq i \leq N$ ,  $1 \leq k \leq K$ 
5
6     # Paso de Expectation
7     Para cada patron de entrada  $x(i)$ :
8         Escoger  $k$  : distancia( $x(i)$ ,  $c(k)$ ) es minima
9         Asignar  $w(i,k) = 1$ 
10
11    # Paso de Maximization
12    Para cada cluster  $k$ :
13        sea  $E(k) = \{x(i) : w(i,k)=1\}$ 
14        Actualizar centroide  $c(k) = \text{media aritmetica de } E(k)$ 
15
16 Devolver C
17
```

Clustering: Métricas

Algunas métricas para evaluar agrupamientos:

- **Homogeneidad (H)**: Número de elementos de un cluster que son miembros de una misma clase (cuando se dispone de datos etiquetados).
- **Compleitud (C)**: Número de elementos de una clase conocida que pertenecen al mismo cluster (cuando se dispone de datos etiquetados).
- **V-Score**: cuando los datos están etiquetados, la V-score se calcula como la media armónica entre la homogeneidad y la completitud.
- **R-Score ajustada**, que calcula la similitud entre clusters. Tiene valores bajos si los clusters son independientes (cerca de 0) y valores cercanos a 1 si son muy similares.
- **WCSS (Within Cluster Sum of Squares)**: Mide cómo de bien se agrupan los elementos pertenecientes a un mismo cluster.
- **S-Score (coeficiente de silueta)**: Mide lo bien que cada patrón encaja en su cluster asignado. Combina información sobre la cohesión y la separación de los clusters.

Ejemplo de implementación del algoritmo **K-Means** desde cero: Cuaderno **KMeansAlgorithm.ipynb**.

Carga el cuaderno en tu cuenta de GDrive y ábrelo con **Colab**.

Estudia bien el cuaderno para ver su implementación, uso y ajuste del hiperparámetro K , así como una explicación más detallada (y práctica) de las métricas **WCSS** y **Silhouette Score**.

Algoritmos basados en centroides vs algoritmos basados en densidad:

- **Algoritmo basado en centroide**: Necesita una suposición inicial sobre el número de clusters en los que se quiere dividir el dataset. Útil cuando usamos clustering para clasificación.
- **Algoritmo basado en densidad**: No hace suposición inicial sobre el número de clusters (puede salir cualquiera). Sin embargo, sí necesita una suposición inicial sobre la distancia que puede haber entre miembros de un cluster (o distancia a los demás miembros del mismo cluster, dependiendo de la técnica).

Contenido

- 1 Aprendizaje no supervisado
- 2 Clustering
- 3 Reglas de asociación**
- 4 Ejercicios y entrega

Reglas de asociación

La **extracción de reglas de asociación** se lleva a cabo sobre **Bases de Datos Transaccionales**.

- Una **transacción** es un conjunto (no ordenado) de **items** (por ejemplo, los productos de una lista de la compra).
- Una **Base de Datos Transaccional** es un conjunto (no ordenado) de **transacciones** (por ejemplo, un conjunto de tickets de un supermercado).

Database

TID	Items
100	A C D
200	B C E
300	A B C E
400	B E

Figura 1: <https://www.codeproject.com/Articles/70371/Apriori-Algorithm>

La nomenclatura que se suele utilizar:

- **Transacciones:** patrones de entrada.
- **Base de Datos Transaccional:** conjunto patrones de entrada (dataset).
- **Items:** elementos individuales/atómicos de las transacciones (por ejemplo, los productos de una lista de la compra)
- **Itemsets:** conjuntos de items que guardan relación entre sí dentro de una transacción (por ejemplo, un subconjunto de los productos de una lista de la compra).
- **Itemsets frecuentes:** conjuntos de items que suelen aparecer juntos en varias transacciones.

Reglas de asociación

En la **extracción de reglas de asociación** existen dos problemas fundamentales:

- Identificación de **itemsets frecuentes**.
- Identificación de **reglas de asociación** de interés.

Una **regla de asociación** es una relación de implicación entre dos itemsets X e Y , notada como $X \rightarrow Y$.

Se cumple que **si un itemset es frecuente**, entonces todos los itemsets que lo forman **también son frecuentes**. Esto nos permite extraer reglas.

Por ejemplo, supongamos el itemset frecuente (*carne*, *pimienta*). Entonces los itemsets (*carne*) y (*pimienta*) también son frecuentes.

Sigamos con el ejemplo del itemset (*carne*, *pimienta*). Entonces podríamos plantearnos extraer alguna (o todas) de las siguientes reglas:

(*carne*) $\rightarrow$ (*pimienta*): El que compra carne suele comprar pimienta.

(*pimienta*) $\rightarrow$ (*carne*): El que compra pimienta suele comprar carne.

No quiere decir que ambas reglas tengan sentido, ni tampoco **que ambas sean aceptables**.

Se deben utilizar **métricas** que sirvan para evaluar la utilidad de cada regla.

Reglas de asociación: Métricas

Se suelen utilizar las siguientes métricas a la hora de evaluar itemsets y reglas de asociación:

- **Soporte de un itemset**. Es la proporción del número de patrones (transacciones) que contienen al itemset frente al total de transacciones de la Base de Datos. Se encuentra en el rango $[0, 1]$. Se corresponde con la probabilidad $p(\text{itemset})$
- **Confianza de una regla ($a \rightarrow c$)**. Es la proporción en la que el itemset (a, c) aparece entre las transacciones donde aparece el itemset (a). Se encuentra en el rango $[0, 1]$. Se corresponde con la probabilidad $p(c|a)$.

Reglas de asociación: Métricas

Se suelen utilizar las siguientes métricas a la hora de evaluar itemsets y reglas de asociación (*continuación*):

- **Lift de una regla ($a \rightarrow c$)**. Describe la confianza que tenemos de que se dé el consecuente cuando se cumple el antecedente. Por ejemplo, en la regla (*Carne*) $\rightarrow$ (*Pimienta*), indica cómo de seguros estamos de que el cliente compre pimienta una vez que ha comprado carne. Se corresponde con el cálculo:

$$\frac{\text{confianza}(a \rightarrow c)}{\text{Soporte}(c)}$$

Valores superiores a 1 indican que podríamos tener una confianza **Lift** aceptable.

Se suelen utilizar las siguientes métricas a la hora de evaluar itemsets y reglas de asociación (*continuación*):

- **Leverage de una regla ($a \rightarrow c$)**. Describe la correlación existente entre itemsets, comparando el soporte de ambos suponiendo independencia. Se calcula como:

$$\text{Soporte}((a, c)) - \text{Soporte}(a)\text{Soporte}(c)$$

- Valores próximos a 0 indican independencia entre el antecedente y el consecuente.
- Valores positivos indican correlación positiva.
- Valores negativos indican correlación negativa.

Extracción de itemsets frecuentes: Algoritmo APriori

El algoritmo **APriori** es un método clásico de extracción de **itemsets frecuentes**.

Se basa en el uso de la métrica de **soporte** para construir iterativamente itemsets más complejos partiendo de itemsets más simples. Necesita un hiperparámetro **min_support** que indique el mínimo soporte de un itemset que estamos dispuestos a aceptar. Su pseudo-código es:

```
1  items= {item : Support(item) > min_support }
2  itemsets= {}
3
4  Desde n=2..|items|, hacer:
5      Para cada itemset=(combinacion de n items frecuentes),
6          hacer:
7              Si Support(itemset) > min_support:
8                  Insertar itemset en itemsets
9
10 Devolver itemsets
```

Extracción de itemsets frecuentes: Algoritmo APriori

La extracción de **reglas de asociación** a partir de un conjunto de itemsets se realiza también de forma sencilla.

No obstante, necesitamos un hiperparámetro **min_conf** que indique la mínima confianza de una regla que estamos dispuestos a aceptar. Su pseudocódigo es:

```
1  reglas= {}
2
3  Para cada itemset tal que |itemset|>=2:
4      Para cada item en itemset:
5          C= itemset \ item
6
7          c1= Calcular confianza de la regla "C -> item"
8          Si c1 > min_conf:
9              Insertar "C -> item" en reglas
10
11          c2= Calcular confianza de la regla "item -> C"
12          Si c2 > min_conf:
13              Insertar "item -> C" en reglas
14  Devolver reglas
```

Algoritmo APriori: Ejemplo

Veamos un ejemplo sobre la siguiente Base de Datos Transaccional:

Database

TID	Items
100	A C D
200	B C E
300	A B C E
400	B E

Figura 2: <https://www.codeproject.com/Articles/70371/Apriori-Algorithm>

Algoritmo APriori: Ejemplo

Extraemos itemsets de forma ascendente (APriori) con **min_support=2/4**:




Figura 3: <https://www.codeproject.com/Articles/70371/Apriori-Algorithm>

Algoritmo APriori: Ejemplo

Extraemos las reglas de los itemsets frecuentes con **min_conf=0.5*100**:

Rules	Support (X Y)	Support(X)	Confidence
{A} -> {C}	2	2	100
{B} -> {C}	2	3	66.66666667
{B} -> {E}	3	3	100
{C} -> {E}	2	3	66.66666667
{B} -> {C E}	2	3	66.66666667
{C} -> {B E}	2	3	66.66666667
{E} -> {B C}	2	3	66.66666667
{C} -> {A}	2	3	66.66666667
{C} -> {B}	2	3	66.66666667
{E} -> {B}	3	3	100
{E} -> {C}	2	3	66.66666667
{C E} -> {B}	2	2	100
{B E} -> {C}	2	3	66.66666667
{B C} -> {E}	2	2	100

Figura 4: <https://www.codeproject.com/Articles/70371/Apriori-Algorithm>

Algoritmo APriori: Desventajas

Aunque **APriori** es un método clásico, simple y sencillo de implementar, tiene la gran desventaja de requerir un coste computacional elevado.

Existen en la actualidad algoritmos de extracción de reglas de asociación más eficientes en tiempo. Ejemplo: **FPGrowth**, **FPMMax** o **HMine**.

En la práctica, **será necesario estudiar y describir alguno de estos métodos** (mínimo uno).

Ejemplo de implementación del algoritmo **APriori** desde cero: Cuaderno **APrioriAlgorithm.ipynb**.

Carga el cuaderno en tu cuenta de GDrive y ábrelo con **Colab**.

Estudia bien el cuaderno para ver su implementación, uso y ajuste de los hiperparámetros, así como una explicación más detallada (y práctica) de las métricas **Soporte** y **Confianza**.

El cuaderno incluye una explicación sobre el uso de la biblioteca **mlxtend** **que se utilizará en la práctica**.

Contenido

- 1 Aprendizaje no supervisado
- 2 Clustering
- 3 Reglas de asociación
- 4 Ejercicios y entrega

Ejercicios y entrega de la práctica

El cuaderno **P2.ipynb** contiene instrucciones para llevar a cabo la práctica 2 de la asignatura.

Se debe entregar únicamente el cuaderno por PRADO. **IMPORTANTE:**

- Prestad atención al análisis y descripción de lo que se hace.
- Cuidad el preprocesamiento de datos.
- Seleccionad varios modelos y “jugad” con sus hiperparámetros.
- **Discusión** sobre los resultados obtenidos por cada modelo por separado, y **conclusiones** finales indicando si hay alguno mejor que otro o no, **justificando y analizando** el porqué.
- No entregar el análisis o una justificación de lo que se hace es como no entregar nada.

PROBLEMA 1: Agrupamiento (5 puntos).

- Contexto: Segmentación de clientes en un centro comercial.
- Uso de Inteligencia Artificial para hallar categorías de tipos de clientes que compran en un centro comercial.
- Se trata de identificar cuántas categorías hay de clientes, así como sus características, que describan los distintos grupos de clientes que se pueden encontrar.

PROBLEMA 2: Extracción de reglas de asociación (5 puntos).

- Contexto: Análisis de ventas.
- Uso de Inteligencia Artificial para hallar correlaciones o dependencias entre las compras efectuadas en una tienda de comestibles.
- Se trata de identificar qué productos se suelen comprar juntos (itemsets frecuentes) y extraer reglas que ayuden a explicar el comportamiento de los clientes de forma automática.

Aprendizaje Automático

Aprendizaje no supervisado

Manuel Pegalajar Cuéllar¹

¹Departamento de Ciencias de la Computación e Inteligencia Artificial. Universidad de Granada