

METAHEURÍSTICA

2025-2026



- Tema 1. Introducción a las Metaheurísticas
- Tema 2. Modelos de Búsqueda: Entornos y Trayectorias vs Poblaciones
- Tema 3. Metaheurísticas Basadas en Poblaciones
- Tema 4: Algoritmos Meméticos
- Tema 5. Metaheurísticas Basadas en Trayectorias
- Tema 6. Metaheurísticas Basadas en Adaptación Social
- Tema 7. Aspectos Avanzados en Metaheurísticas
- Tema 8. Metaheurísticas Paralelas
- Tema 9. Modelos de IA Evolutivos. Aprendizaje Evolutivo

METAHEURÍSTICAS

TEMA 3. METAHEURÍSTICAS BASADAS EN POBLACIONES

Parte II:

1. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA I (Algoritmos genéticos)
2. EVOLUCIÓN DIFERENCIAL
3. ESTRATEGIAS DE EVOLUCIÓN
4. TEMA 6. PSO. ALGORITMOS DE NUBES DE PARTÍCULAS
5. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA II (Competiciones y modelos)
6. NUEVOS MODELOS BIOINSPIRADOS PARA OPTIMIZACIÓN DE PARÁMETROS

METAHEURÍSTICAS

TEMA 3. METAHEURÍSTICAS BASADAS EN POBLACIONES

Parte II:

1. **ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA I (Algoritmos genéticos)**
2. **EVOLUCIÓN DIFERENCIAL**
3. **ESTRATEGIAS DE EVOLUCIÓN**
4. **TEMA 6. PSO. ALGORITMOS DE NUBES DE PARTÍCULAS**
5. **ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA II (Competiciones y modelos)**
6. **NUEVOS MODELOS BIOINSPIRADOS PARA OPTIMIZACIÓN DE PARÁMETROS**

EVOLUCIÓN ARTIFICIAL

Existen cuatro paradigmas básicos:

Algoritmos Genéticos que utilizan operadores genéticos sobre cromosomas. 1975, Michigan University



John Holland
Inventor of genetic algorithms
Professor of CS and Psychology at the U. of Michigan.

Estrategias de Evolución que enfatizan los cambios de comportamiento al nivel de los individuos. 1964, Technische Universität Berlin



Hans-Paul Schwefel
Universität Dortmund

Inventors of Evolution Strategies



Ing. Ingo Rechenberg
Bionics & Evolutionstechnik
Technical University Berlin
<http://www.bionik.tu-berlin.de/>

Programación Evolutiva que enfatizan los cambios de comportamiento al nivel de las especies. 1960-1966, Florida



Lawrence J. Fogel,
Natural Selection, Inc.
Inventor of Evolutionary Programming

Programación Genética que evoluciona expresiones representadas como árboles. 1989, Stanford University



John Koza
Stanford University.
Inventor of Genetic Programming

Optimización Evolutiva de Parámetros (Evolutionary Parameter Optimization): Introducción

- Los diseñadores de cada una de las técnicas de Computación Evolutiva vieron que sus problemas particulares podían ser resueltos por algoritmos de evolución.
 - Fogel estaba interesado en resolver programas de evolución.
 - **Rechenberg & Schwefel estaban interesados en resolver problemas de optimización de parámetros.**
 - Holland estaba interesado en el desarrollo de sistemas adaptativos robustos.


Optimización Evolutiva de Parámetros (Evolutionary Parameter Optimization): Introducción

Centramos nuestra atención en el problema de encontrar el óptimo global de una función con variables reales que está caracterizada por:

**múltiples mínimos
no diferenciable**

$$f(X_i) = D \cdot 10 + \sum_{j=1}^D \left[x_{ij}^2 - 10 \cdot \cos(2\pi x_{ij}) \right]$$

**Tiene muchos mínimos
locales y es altamente
multimodal.**



Optimización Evolutiva de Parámetros (Evolutionary Parameter Optimization): Introducción

Motivación del problema

- Hay muchas aplicaciones en las que un científico/ingeniero tiene que optimizar una función no lineal y no diferenciable con múltiples mínimos.

Ejemplo: Problemas en la competición CEC2011
14 problemas



Real-world Numerical Optimization Problems



Special Track: Competition: Testing Evolutionary Algorithms on Real-world Numerical Optimization Problems [CEC'2011](#), New Orleans, USA, Jun 5 - 8, 2011. Organizer: P.N. Suganthan.

4. Special Sessions and Workshops: Problem definitions and contributions (pdf files)
<http://sci2s.ugr.es/EAMHCO/#SS>

1. Parameter Estimation for Frequency-Modulated (FM) Sound Waves
2. Lennard-Jones Potential Problem
3. The Bifunctional Catalyst Blend Optimal Control Problem
4. Optimal Control of a Non-Linear Stirred Tank Reactor
5. Tersoff Potential Function Minimization Problem
6. Spread Spectrum Radar Poly phase Code Design
7. Transmission Network Expansion Planning (TNEP) Problem
8. Large Scale Transmission Pricing Problem
9. Circular Antenna Array Design Problem
10. Dynamic Economic Dispatch (DED) Problem
11. Static Economic Load Dispatch (ELD) Problem
12. Hydrothermal Scheduling Problem
13. Messenger: Spacecraft Trajectory Optimization Problem
14. Cassini 2: Spacecraft Trajectory Optimization Problem

**13 Algorithms
participate in the
Special Track**

Optimización Evolutiva de Parámetros (Evolutionary Parameter Optimization): Introducción

Algoritmos Evolutivos de Parámetros Reales Más Populares

- ▶ Algoritmos Genéticos con Codificación Real (*Real-coded (parameter) genetic algorithm* (RCGAs))
- ▶ Estrategias de Evolución (*Evolution strategies* (ES))
- ▶ Evolución Diferencial (*Differential evolution* (DE))
- ▶ Nube de Partículas (*Particle swarm optimization* (PSO))
- ▶ Algoritmos Meméticos con Codificación Real (*Real coding memetic algorithms* (RCMA))

▶ Recientemente:

Published: 05 July 2020

Comprehensive Taxonomies of Nature- and Bio-inspired Optimization: Inspiration Versus Algorithmic Behavior, Critical Analysis Recommendations


[Daniel Molina](#) ✉, [Javier Poyatos](#), [Javier Del Ser](#), [Salvador García](#), [Amir Hussain](#) & [Francisco Herrera](#)

[Cognitive Computation](#) **12**, 897–939(2020) | [Cite this article](#)

6 Citations | 0 Altmetric | [Metrics](#)

Trabajos pioneros y destacados

Codificación binaria



CROSSOVER is the fundamental mechanism of genetic rearrangement for both real organisms and genetic algorithms.

Chromosomes line up and then swap the portions of their genetic code beyond the crossover point.

Operador de cruce con parámetros reales.
¿Rediseñar el operador de cruce?

Pioneros y trabajos destacados

Algoritmos Genéticos con Codificación Real

- ▶ Las variables de decisión son codificadas directamente, en lugar de usar cadenas binarias.
- ▶ La **recombinación** y **mutación** necesitan cambios estructurales


Recombinación

$\Rightarrow ?$

Mutación

$(x_1 x_2 \dots x_n) \Rightarrow ?$

- ▶ El operador de selección sigue siendo el mismo
- ▶ Intercambios simples no son suficiente



Pioneros y trabajos destacados

Problemas con cruce real: Vecindario y Cruce

Idea subyacente del cruce basada en el concepto de herencia: combinar genotipos paternos para que los genotipos de los hijos queden “**en algún lugar entre ellos**”.




Figure 2

Interpretación y Generalización

El **cruce** y **mutación** tradicional tienen una interpretación natural en la estructura del vecindario en términos de **proximidad** y **intermediación**.


Pioneros y trabajos destacados

Primera propuesta de Codificación Real: Cruce Lineal/Aritmético


Wright, A. (1991). Genetic Algorithms for Real Parameter Optimization. FOGA 1, 205-218.

- *Cruce lineal*

- *De 2 puntos padres, se generan 3 puntos nuevos:*
 - $(1/2)p1 + (1/2)p2$, $(3/2)p1 - (1/2)p2$, $(-1/2)p1 + (3/2)p2$
 - $(1/2)p1 + (1/2)p2$ es el punto medio de $p1$ y $p2$
 - Los otros están en la línea determinada por $p1$ y $p2$
- *Los 2 de los 3 mejores puntos son enviados a la siguiente generación.*
- *Desventaja- Esquema sumamente alterado. No es compatible con el teorema del esquema descrito en la siguiente diapositiva.*




Modelos ampliados: Arithmetical crossover (Michalewicz, 1992),
Max-Min Arithmetic operator (Herrera, Lozano, Verdegay, 1995)



Pioneros y trabajos destacados

Variable-wise recombination: Blend Crossover (BLX- α)

Eshelman L.J., Schaffer J.D. (1993). **Real-Coded Genetic Algorithms and Interval-Schemata**. FOGA 2, 187-202.



- Distribución de probabilidad uniforme con una cota controlada por α
- Diversidad en los hijos proporcional a la de los padres
- La búsqueda es demasiado amplia si los padres están distantes

Pioneros y trabajos destacados

Variable-wise recombination of Parents (RCGA first generation)


- ▶ Usa distribución de probabilidad para crear descendencia
- ▶ Diferentes implementaciones desde 1991:
 - ▶ Blend crossover (BLX- α), 1993
 - ▶ Simulated binary crossover (SBX- β), 1995
 - ▶ Fuzzy recombination (FR-d), 1995
 - ▶ Fuzzy connectives based operator (FCB), 1994
- ▶ **Característica principal:** La diferencia entre los padres se usa para crear a los hijos
 - ▶ Proporciona una propiedad auto-adaptativa

Análisis experimentales: F. Herrera, M. Lozano, J.L. Verdegay (1998). Tackling real-coded genetic algorithms: operators and tools for the behavioural analysis.


Artificial Intelligence Reviews 12(4): 265-319

Pioneros y trabajos destacados


BLX- α (Eshelman et al., 1993)




SBX (Deb et al., 1995)



Fuzzy recombination (Voigt et al., 1995)



Fuzzy Connectives based Operator (Herrera et al. 1994)




Pioneros y trabajos destacados

Taxonomía de los operadores de cruce


Cruce discreto



Cruce basado en
agregación




Cruce basado en
vecindario




Pioneros y trabajos destacados

Operadores de cruce basados en Parent Center



- FR (Voigt et al, 1995)
- SBX (Deb et al, 1995)
- XLM (Takahashi et al 2001)
- PCX (Deb et al, 2002)
- vSBX (Ballester et al, 2003)
- PNX (Ballester et al, 2004)
- PBX- α (Lozano et al, 2004)

PNX (Ballester et al., 2004)



Comportamiento similar que el de operadores auto-adaptados

METAHEURÍSTICAS

TEMA 3. METAHEURÍSTICAS BASADAS EN POBLACIONES

Parte II:

1. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA I (Algoritmos genéticos)
2. **ESTRATEGIAS DE EVOLUCIÓN**
3. EVOLUCIÓN DIFERENCIAL
4. TEMA 6. PSO. ALGORITMOS DE NUBES DE PARTÍCULAS
5. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA (Competiciones y modelos)
6. NUEVOS MODELOS BIOINSPIRADOS PARA OPTIMIZACIÓN DE PARÁMETROS

Pioneros y trabajos destacados


Estrategias de evolución

Rechenberg & Schwefel (1964) estaban preocupados por resolver problemas de optimización de parámetros. Auto-adaptación de los parámetros.

$$\text{Mut: } I \longrightarrow I$$
$$(x_1, \dots, x_n)$$

$$\text{Mut}(x) = x' = (x_1 + z_1, \dots, x_n + z_n)$$

$$z_i \sim N_i(0, \sigma'^2)$$



State of the art of the first generation: Schwefel, H.P. *Evolution and Optimum Seeking*. Sixth-Generation Computer Technology Series. Wiley, New York, 1995.


Pioneros y trabajos destacados

State of the art of the ES second generation: CMA-ES

Evolution Strategy with Covariance Matrix Adaptation (Hansen & Ostermeier, 1996)

- ▶ Selection-mutation ES se ejecuta para n iteraciones
- ▶ Se registran los pasos exitosos
- ▶ Son analizados para encontrar direcciones básicas y puntos fuertes no correlacionados
- ▶ Requiere $O(n^3)$ para solucionar un problema de autovalores
- ▶ Rotación invariante

Nikolaus Hansen
www.lri.fr/~hansen/



- Hansen, N. and A. Ostermeier (2001). Completely Derandomized Self-Adaptation in Evolution Strategies. *Evolutionary Computation*, 9(2), pp. 159-195;
- Hansen, N., S.D. Müller and P. Koumoutsakos (2003). Reducing the Time Complexity of the Derandomized Evolution Strategy with Covariance Matrix Adaptation (CMA-ES). *Evolutionary Computation*, 11(1), pp. 1-18;

METAHEURÍSTICAS

TEMA 3. METAHEURÍSTICAS BASADAS EN POBLACIONES

Parte II:

1. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA I (Algoritmos genéticos)
2. ESTRATEGIAS DE EVOLUCIÓN
3. EVOLUCIÓN DIFERENCIAL
4. TEMA 6. PSO. ALGORITMOS DE NUBES DE PARTÍCULAS
5. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA II (Competiciones y modelos)
6. NUEVOS MODELOS BIOINSPIRADOS PARA OPTIMIZACIÓN DE PARÁMETROS

METAHEURÍSTICAS

TEMA 3. METAHEURÍSTICAS BASADAS EN POBLACIONES

EVOLUCIÓN DIFERENCIAL

1. EVOLUCIÓN DIFERENCIAL
2. VARIANTES DE LA EVOLUCIÓN DIFERENCIA
3. MODELOS AVANZANDOS EN EVOLUCIÓN DIFERENCIAL

1. EVOLUCIÓN DIFERENCIAL

- Es un modelo evolutivo que enfatiza la mutación, utiliza un operador de cruce/recombinación a posteriori de la mutación. Fué propuesto para optimización con parámetros reales.
- Fue propuesta of R. Storm (Univ. Berkeley), 1997

R. Storn, Differential Evolution, A simple and eficiente heuristic strategy for global optimization over continuous spaces. Journal of Global Optimization, 11 (1997) 341-359.



Kenneth V. Price, Rainer M. Storn, and Jouni A. Lampinen
[Differential Evolution: A Practical Approach to Global Optimization \(Natural Computing Series\)](#)
Springer-Verlag, 2005.

1. EVOLUCIÓN DIFERENCIAL

- **Inicialización:**

Una población $P_{x,0}$ de N_p vectores de parámetros D-dimensionales $x_{i,0}=[x_{1,i,0}, \dots, x_{D,i,0}]$, $i=1, \dots, N_p$ se genera aleatoriamente dentro de unos límites inferiores y superiores previos $b_L=[b_{1,L}, \dots, b_{D,L}]$ y $b_U=[b_{1,U}, \dots, b_{D,U}]$.

Ejemplo: el valor inicial (en la generación $g=0$) del j-ésimo parámetro del i-ésimo vector se genera por: $x_{j,i,0}=\text{rand}_j[0, 1] \cdot (b_{j,U}-b_{j,L}) + b_{j,L}$, $j=1, \dots, D$, $i=1, \dots, N_p$.

- **Generación:**

Mutación Diferencial: con respecto a cada vector $x_{i,g}$ en la población actual, llamado vector objetivo, se genera un vector mutado $v_{i,g}$ añadiendo un vector diferencia, escalado y aleatoriamente muestreado, a un vector base aleatoriamente seleccionado de la población actual.

En la generación g-ésima, se genera una población $P_{u,g}$ consistente de N_p vectores D-dimensionales $u_{i,g}=[u_{1,i,g}, \dots, u_{D,i,g}]$ a través de operadores de mutación y recombinación aplicados a la población actual $P_{x,g}$.

1. EVOLUCIÓN DIFERENCIAL




Imagen de la Evolución Diferencial clásica

1. EVOLUCIÓN DIFERENCIAL

Ejemplo: en la generación g -ésima, el i -ésimo vector mutado $v_{i,g}$ con respecto al i -ésimo vector objetivo $x_{i,g}$ en la población actual se genera mediante

$$V_{i,g} = x_{r0,g} + F \cdot (x_{r1,g} - x_{r2,g}), \quad i \neq r0 \neq r1 \neq r2.$$

El factor de escalado de la mutación $F \in [0,1]$





Illustration of classic DE

1. EVOLUCIÓN DIFERENCIAL

Ejemplo: en la generación g-ésima, el i-ésimo vector mutado $v_{i,g}$ con respecto al i-ésimo vector objetivo $x_{i,g}$ en la población actual se genera mediante

$$V_{i,g} = x_{r0,g} + F \cdot (x_{r1,g} - x_{r2,g}), \quad i \neq r0 \neq r1 \neq r2.$$

El factor de escalado de la mutación $F \in [0,1]$




1. EVOLUCIÓN DIFERENCIAL

Ejemplo: en la generación g -ésima, el i -ésimo vector mutado $v_{i,g}$ con respecto al i -ésimo vector objetivo $x_{i,g}$ en la población actual se genera mediante

$$V_{i,g} = x_{r0,g} + F \cdot (x_{r1,g} - x_{r2,g}), \quad i \neq r0 \neq r1 \neq r2.$$

El factor de escalado de la mutación $F \in [0,1]$



1. EVOLUCIÓN DIFERENCIAL

- **Recombinación Discreta:**

Con respecto a cada vector objetivo $x_{i,g}$ en la población actual, un nuevo vector $u_{i,g}$ se genera cruzando el vector objetivo $x_{i,g}$ con el correspondiente vector mutado $v_{i,g}$ bajo un ratio predefinido de cruce $Cr \in [0, 1]$.


Ejemplo: en la generación g -ésima, el i -ésimo vector $u_{i,g}$ con respecto al i -ésimo vector objetivo $x_{i,g}$ en la población actual se genera mediante:

$$u_{j,i,g} = \begin{cases} v_{j,i,g} & \text{if } \text{rand}_j[0,1] \leq Cr \\ x_{j,i,g} & \text{otherwise} \end{cases}$$


- **Reemplazamiento:**

Si el vector $u_{i,g}$ tiene mejor valor de la función objetivo que su correspondiente vector objetivo $x_{i,g}$, sustituye el vector objetivo en la generación $(g+1)$; si esto no ocurre, el vector objetivo permanece en la generación $(g+1)$.

1. EVOLUCIÓN DIFERENCIAL



1. EVOLUCIÓN DIFERENCIAL



1. EVOLUCIÓN DIFERENCIAL

Procedimiento Básico – Evolución Diferencial

```
Procedure DE{
  t = 0;
  Initialize Pop(t);    /* of |Pop(t)| Individuals */
  Evaluate Pop(t);
  While (Not Done)
  {for i = 1 to |Pop(t)| do
    {parent1, parent2, parent3} = Select_3_Parents(Pop(t));
    thisGene = random_int(|Pop(t)|);
    for k = 1 to n do /* n genes per Individual */
      if (random < p) *P is crossover constant in [0,1]*
        Offspringik = parent1ik + Y(parent2ik - parent3ik);
      else
        Offspringik = Individualik in Pop(t);
      end /* for k */
    Evaluate(Offspringi);
  end /* for i */
  Pop(t+1) = {j | Offspringj is_better_than Individualj} ∪
             {k | Individualk is_better_than Offspringk};
  t = t + 1;}
```

2. VARIANTES DE LA EVOLUCIÓN DIFERENCIAL

- Mutación diferencial:
 - Vector de una diferencia: $F \cdot (x_{r1} - x_{r2})$
 - Vector de dos diferencias: $F \cdot (x_{r1} - x_{r2}) + F \cdot (x_{r3} - x_{r4})$
 - Factor de escalado de mutación F
 - Rol crucial: balance exploración y explotación.

DE/rand/1:
$$\mathbf{V}_{i,G} = \mathbf{X}_{r1,G} + F \cdot (\mathbf{X}_{r2,G} - \mathbf{X}_{r3,G})$$

DE/best/1:
$$\mathbf{V}_{i,G} = \mathbf{X}_{best,G} + F \cdot (\mathbf{X}_{r1,G} - \mathbf{X}_{r2,G})$$


DE/current-to-best/1:
$$\mathbf{V}_{i,G} = \mathbf{X}_{i,G} + F \cdot (\mathbf{X}_{best,G} - \mathbf{X}_{i,G}) + F \cdot (\mathbf{X}_{r1,G} - \mathbf{X}_{r2,G})$$

DE/rand/2:
$$\mathbf{V}_{i,G} = \mathbf{X}_{r1,G} + F \cdot (\mathbf{X}_{r2,G} - \mathbf{X}_{r3,G} + \mathbf{X}_{r4,G} - \mathbf{X}_{r5,G})$$

DE/best/2:
$$\mathbf{V}_{i,G} = \mathbf{X}_{best,G} + F \cdot (\mathbf{X}_{r1,G} - \mathbf{X}_{r2,G} + \mathbf{X}_{r3,G} - \mathbf{X}_{r4,G})$$

2. VARIANTES DE LA EVOLUCIÓN DIFERENCIAL

- Recombinación
 - Recombinación discreta (cruce) (variante rotacional)
 - Un punto y multipunto
 - Exponencial
 - Binomial (uniforme)
 - Recombinación aritmética
 - Recombinación lineal (invariante rotacional)
 - Recombinación intermedia (variante rotacional)
 - Recombinación intermedia extendida (variante rotacional)



2. VARIANTES DE LA EVOLUCIÓN DIFERENCIAL

Ratio de cruce $CR \in [0, 1]$

Descomponible (CR pequeño) y funciones no descomponibles (CR grande)

Guía práctica:

$N_p \in [5D, 10D]$; elección inicial de $F = 0.5$ y $CR = 0.1 / 0.9$;

Incrementar N_p y / o F si encontramos convergencia prematura.

3. ALGUNOS TRABAJOS EN EVOLUCIÓN DIFERENCIAL



R. Storn and K. V. Price, “Differential evolution-A simple and Efficient Heuristic for Global Optimization over Continuous Spaces,” *Journal of Global Optimization*, 11:341-359,1997.



K. V. Price, R. Storn, J. Lampinen, *Differential Evolution - A Practical Approach to Global Optimization*, Springer, Berlin, 2005.

J. Zhang, A.C. Sanderson. JADE: Adaptive Differential Evolution with Optional External Archive. *IEEE Transactions on Evolutionary Computation*, 13:5 (2009) 945-958.

A.K. Qin, V.L. Huang, P.N. Suganthan. Differential Evolution Algorithm with strategy Adaptation for Global Numerical Optimization. *IEEE Transactions on Evolutionary Computation*, 13:2 (2009) 398-417.

METAHEURÍSTICAS

TEMA 3. METAHEURÍSTICAS BASADAS EN POBLACIONES

Parte II:

1. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA I (Algoritmos genéticos)
2. EVOLUCIÓN DIFERENCIAL
3. ESTRATEGIAS DE EVOLUCIÓN
4. **TEMA 6. PSO. ALGORITMOS DE NUBES DE PARTÍCULAS**
5. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA (Competiciones y modelos)
6. NUEVOS MODELOS BIOINSPIRADOS PARA OPTIMIZACIÓN DE PARÁMETROS

METAHEURÍSTICAS

OPTIMIZACIÓN BASADA EN NUBES DE PARTÍCULAS (PARTICLE SWARM)

- 1. INTRODUCCIÓN Y RÁPIDO RESUMEN**
- 2. FUNCIONAMIENTO DEL ALGORITMO PSO**
- 3. ASPECTOS AVANZADOS**

Kennedy, J., Eberhart, R.C. Swarm Intelligence. Morgan Kauffmann, 2001.

1. INTRODUCCIÓN Y RÁPIDO RESUMEN

- La “Particle Swarm Optimization” (PSO) es una metaheurística poblacional inspirada en el comportamiento social del vuelo de las bandadas de aves y el movimiento de los bancos de peces.
- La población se compone de varias partículas (*nube de partículas = particle swarm*) que se mueven (“*vuelan*”) por el espacio de búsqueda durante la ejecución del algoritmo.
- Este movimiento de cada partícula p depende de:
 - Su mejor posición desde que comenzó el algoritmo ($pBest$),
 - la mejor posición de las partículas *de su entorno* ($lBest$) o de *toda la nube* ($gBest$) desde que comenzó el algoritmo.

En cada iteración, se cambia aleatoriamente la velocidad de p para acercarla a las posiciones $pBest$ y $lBest/gBest$.

1. INTRODUCCIÓN Y RÁPIDO RESUMEN (2)

- Desarrollo: USA, en 1995.
- Primeros autores: Russ C. Eberhart y James Kennedy
Kennedy, J. and Eberhart, R. (1995). "Particle Swarm Optimization", Proc. 1995 IEEE Intl. Conf. on Neural Networks, pp. 1942-1948, IEEE Press.
- Aplicación típica:
 - Optimización continua (optimización de parámetros reales, numérica).
- Características atribuidas:
 - Asume un intercambio de información (**interacciones sociales**) entre los agentes de búsqueda.
 - **Idea básica**: guardar información del mejor propio y global.
 - Implementación muy sencilla, pocos parámetros.
 - Convergencia rápida a buenas soluciones.

2. FUNCIONAMIENTO DEL ALGORITMO PSO


- **FUNCIONAMIENTO BÁSICO**
- **ANATOMÍA DE UNA PARTÍCULA**
- **INICIALIZACIÓN DE LA NUBE DE PARTÍCULAS**
- **MOVIMIENTO DE LAS PARTÍCULAS**
- **PSEUDOCÓDIGOS**
- **VALORES DE LOS PARÁMETROS**
- **TOPOLOGÍAS DE LA NUBE DE PARTÍCULAS**

Funcionamiento Básico

- PSO simula el comportamiento de las bandadas de aves.
- Supongamos que una de estas bandadas busca comida en un área y que solamente hay una pieza de comida en dicha área.
- Los pájaros no saben donde está la comida pero sí conocen su distancia a la misma.
- La estrategia más eficaz para hallar la comida es seguir al ave que se encuentre más cerca de ella.

Funcionamiento Básico (2)

- PSO emula este escenario para resolver problemas de optimización. Cada solución (**partícula**) es un "*ave*" en el espacio de búsqueda que está siempre en continuo movimiento y que nunca muere.



Funcionamiento Básico (2)

- La nube de partículas es un **sistema multiagente**. Las partículas son agentes simples que se mueven por el espacio de búsqueda y que guardan (y posiblemente comunican) la mejor solución que han encontrado.
- Cada partícula tiene un **fitness**, una **posición** y un **vector velocidad** que dirige su "*vuelo*". El movimiento de las partículas por el espacio está guiado por las partículas óptimas en el momento actual.



Anatomía de una Partícula


Una partícula está compuesta por:

- Tres vectores:

- El **vector X** almacena la posición actual (localización) de la partícula en el espacio de búsqueda,
- El **vector pBest** almacena la localización de la mejor solución encontrada por la partícula hasta el momento, y
- El **vector V** almacena el gradiente (dirección) según el cuál se moverá la partícula.

- Dos valores de fitness:


- El **x_fitness** almacena el fitness de la solución actual (vector X), y
- El **p_fitness** almacena el fitness de la mejor solución local (vector *pBest*).



Inicialización de la Nube de Partículas

- La nube se inicializa generando las posiciones y las velocidades iniciales de las partículas.
- Las posiciones se pueden generar aleatoriamente en el espacio de búsqueda, de forma regular, o con una combinación de ambas.
- Las velocidades se generan aleatoriamente, con cada componente en el intervalo $[-V_{\max}, V_{\max}]$.
No es conveniente fijarlas a cero, no se obtienen buenos resultados.
 $V_{\max}$ será la velocidad máxima que pueda tomar una partícula en cada movimiento.

Inicialización de la Nube de Partículas (2)



Movimiento de las Partículas

¿Cómo se mueve una partícula de una posición del espacio de búsqueda a otra?

- Se hace simplemente añadiendo el vector velocidad V_i al vector posición X_i para obtener un nuevo vector posición:

$$X_i \leftarrow X_i + V_i$$

- Una vez calculada la nueva posición de la partícula, se evalúa ésta. Si el nuevo fitness es mejor que el que la partícula tenía hasta ahora, $pBest_fitness$, entonces:

$$pBest_i \leftarrow X_i \quad ; \quad pBest_fitness \leftarrow x_fitness.$$

Movimiento de las Partículas (2)

- De este modo, el primer paso es ajustar el vector velocidad, para después sumárselo al vector posición.
- Las fórmulas empleadas son las siguientes:

$$v_{id} = v_{id} + \underbrace{\varphi_1 \cdot \text{rnd}() \cdot (pBest_{id} - x_{id})}_{\text{COGNITIVO}} + \underbrace{\varphi_2 \cdot \text{rnd}() \cdot (g_{id} - x_{id})}_{\text{SOCIAL}}$$
$$x_{id} = x_{id} + v_{id}$$

donde:

- p_i es la partícula en cuestión, $pBest_{id}$ es la mejor solución encontrada por la partícula.
- φ_1, φ_2 son ratios de aprendizaje (pesos) que controlan los componentes **cognitivo** y **social**,
- g representa el índice de la partícula con el mejor $pBest_fitness$ del entorno de p_i ($lBest$) o de toda la nube ($gBest$),
- los **rnd()** son números aleatorios generados en $[0,1]$, y
- d es la d -ésima dimensión del vector.


Movimiento de las Partículas (3)

TIPOS DE ALGORITMOS DE PSO:

- Kennedy identifica cuatro tipos de algoritmos de PSO en función de los valores de φ_1 y φ_2 :
 - Modelo completo: $\varphi_1, \varphi_2 > 0$.
 - Sólo Cognitivo: $\varphi_1 > 0$ y $\varphi_2 = 0$.
 - Sólo Social: $\varphi_1 = 0$ y $\varphi_2 > 0$.
 - Sólo Social exclusivo: $\varphi_1 = 0$, $\varphi_2 > 0$ y $g \neq i$ (la partícula en sí no puede ser la mejor de su entorno).

Movimiento de las Partículas (4)

REPRESENTACIÓN GRÁFICA:



Pseudocódigo PSO Local

$t = 0;$

Para $i=1$ hasta Número_partículas
 inicializar X_i y V_i ;

Mientras (no se cumpla la condición de parada) hacer
 $t \leftarrow t + 1$

 Para $i=1$ hasta Número_partículas

 evaluar X_i ;

 Si $F(X_i)$ es mejor que $F(pBest_i)$ entonces

$pBest_i \leftarrow X_i$; $F(pBest_i) \leftarrow F(X_i)$

 Para $i=1$ hasta Número_partículas

 Escoger $lBest_i$, la partícula con mejor fitness del entorno de X_i

 Calcular V_i , la velocidad de X_i , de acuerdo a $pBest_i$ y $lBest_i$

 Calcular la nueva posición X_i , de acuerdo a X_i y V_i

Devolver la mejor solución encontrada

Pseudocódigo PSO Global

$t = 0;$

Para $i=1$ hasta Número_partículas
 inicializar X_i y V_i ;

Mientras (no se cumpla la condición de parada) hacer
 $t \leftarrow t + 1$

 Para $i=1$ hasta Número_partículas

 evaluar X_i ;

 Si $F(X_i)$ es mejor que $F(pBest)$ entonces

$pBest_i \leftarrow X_i$; $F(pBest_i) \leftarrow F(X_i)$

Si $F(pBest)$ es mejor que $F(gBest)$ entonces

$gBest \leftarrow pBest_i$; $F(gBest_i) \leftarrow F(pBest_i)$

 Para $i=1$ hasta Número_partículas

 Calcular V_i , la velocidad de X_i , de acuerdo a $pBest_i$ y **$gBest_i$**

 Calcular la nueva posición X_i , de acuerdo a X_i y V_i

Devolver la mejor solución encontrada


Valores de los Parámetros

- **Tamaño de la nube:** Entre 20 y 40 partículas (problemas simples, 10; problemas muy complejos, 100-200).
- **Velocidad máxima:** $V_{\max}$ se suele definir a partir del intervalo de cada variable.
- **Ratios de aprendizaje:** Habitualmente, $\varphi_1 = \varphi_2 = 2$.
- **PSO Global vs. PSO Local:** La versión global converge más rápido pero cae más fácilmente en óptimos locales y viceversa.

Topologías de la Nube de Partículas


- Las topologías definen el entorno de cada partícula individual. La propia partícula siempre pertenece a su entorno.
- Los entornos pueden ser de dos tipos:
 - **Geográficos:** se calcula la distancia de la partícula actual al resto y se toman las más cercanas para componer su entorno.
 - **Sociales:** se define a priori una lista de vecinas para partícula, independientemente de su posición en el espacio.
- Los entornos sociales son los más empleados.
- Una vez decidido el entorno, es necesario definir su tamaño. El algoritmo no es muy sensible a este parámetro (3 o 5 son valores habituales con buen comportamiento).
- Cuando el tamaño es toda la nube de partículas, el entorno es a la vez geográfico y social, y tenemos la PSO global.

Topologías de la Nube de Partículas (2)



Topologías de la Nube de Partículas (3)

- La topología social más empleada es la de anillo, en la que se considera un vecindario circular.
- Se numera cada partícula, se construye un círculo virtual con estos números y se define el entorno de una partícula con sus vecinas en el círculo:



METAHEURÍSTICAS

TEMA 3. METAHEURÍSTICAS BASADAS EN POBLACIONES

Parte II:

1. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA I (Algoritmos genéticos)
2. EVOLUCIÓN DIFERENCIAL
3. ESTRATEGIAS DE EVOLUCIÓN
4. TEMA 6. PSO. ALGORITMOS DE NUBES DE PARTÍCULAS
5. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA II (Competiciones y modelos)
6. NUEVOS MODELOS BIOINSPIRADOS PARA OPTIMIZACIÓN DE PARÁMETROS

Milestone: CEC'2005 Real Parameter

Optimization Session and Benchmark

Special Session on Real-Parameter Optimization.

2005 IEEE CEC, Edinburgh, UK, Sept 2-5. 2005.

Organizers: K. Deb and P.N. Suganthan.

Unimodal Functions

Success Performance Indices

Multimodal Functions

Solved in at least one run

Multimodal Functions

Never solved

El estudio se hizo con dimensiones $D = 10$, $D = 30$, $D=50$.

El número máximo de evaluaciones de aptitud es $10,000 \cdot D$.

Cada vuelta para cuando el número máximo de evaluaciones se alcanza

P. N. Suganthan, N. Hansen, J. J. Liang, K. Deb, Y.-P. Chen, A. Auger and S. Tiwari, "[Problem Definitions and Evaluation Criteria for the CEC 2005 Special Session on Real-Parameter Optimization](#)", *Technical Report*, Nanyang Technological University, Singapore, May 2005 AND KanGAL Report #2005005, IIT Kanpur, India.

Milestone: CEC'2005 Real Parameter

Optimization Session and Benchmark

Special Session on Real-Parameter Optimization.

2005 IEEE CEC, Edinburgh, UK, Sept 2-5. 2005.

Organizers: K. Deb and P.N. Suganthan.

Unimodal Functions

Success Performance Indices

6 funciones

1 Sphere
2 Schwefel 1.2
3 Ellipsoid Condition 10^6
4 Schwefel 1.2 with Noise
5 Schwefel 2.6 on Bounds
6 Rosenbrock

Multimodal Functions

Solved in at least one run

6 funciones

7 Griewank out Bounds
9 Rastrigin Separable
10 Rastrigin Rotated
11 Weierstrass
12 Schwefel 2.13
15 Hybrid Separable

Multimodal Functions

Never solved

13 funciones

8 Ackley Condition 10^2
13 Expanded 6&7
14 Expanded Schaffer F6
16 Hybrid Rotated
17 Hybrid with Noise
18 Hybrid F18
19 Hybrid Narrow
20 Hybrid on Bounds
21 Hybrid F21
22 Hybrid High Condition
23 Hybrid Non-Continuous
24 Hybrid F24
25 Hybrid out


Milestone: CEC'2005 Real Parameter

Optimization Session and Benchmark


- Algorithms involved in the comparison: **(11 algoritmos)**
 - **BLX-GL50** (Garcia-Martinez & Lozano, 2005): Hybrid Real-Coded Genetic Algorithms with Female and Male Differentiation
 - **BLX-MA** (Molina *et al.*, 2005): Adaptive Local Search Parameters for Real-Coded Memetic Algorithms
 - **CoEVO** (Posik, 2005): Mutation Step Co-evolution
 - **DE** (Ronkkonen *et al.*, 2005): Differential Evolution
 - **DMS-L-PSO**: Dynamic Multi-Swarm Particle Swarm Optimizer with Local Search
 - **EDA** (Yuan & Gallagher, 2005): Estimation of Distribution Algorithm
 - **G-CMA-ES** (Auger & Hansen, 2005): A restart Covariance Matrix Adaptation Evolution Strategy with increasing population size
 - **K-PCX** (Sinha *et al.*, 2005): A Population-based, Steady-State real-parameter optimization algorithm with parent-centric recombination operator, a polynomial mutation operator and a niched -selection operation.
 - **L-CMA-ES** (Auger & Hansen, 2005): A restart local search Covariance Matrix Adaptation Evolution Strategy
 - **L-SaDE** (Qin & Suganthan, 2005): Self-adaptive Differential Evolution algorithm with Local Search
 - **SPC-PNX** (Ballester *et al.*, 2005): A steady-state real-parameter GA with PNX crossover operator

Milestone: CEC'2005 Real Parameter Optimization Session and Benchmark

$D = 10$



$D = 30$



S. García, [D. Molina](#), [M. Lozano](#), [F. Herrera](#), A Study on the Use of Non-Parametric Tests for Analyzing the Evolutionary Algorithms' Behaviour: A Case Study on the CEC'2005 Special Session on Real Parameter Optimization. *Journal of Heuristics*, 15 (2009) 617-644. [doi: 10.1007/s10732-008-9080-4](https://doi.org/10.1007/s10732-008-9080-4).

Milestone: CEC'2005 Real Parameter Optimization Session and Benchmark

G-CMA-ES vs.	R^+	R^-	p -value
BLX-GL50	289.5	35.5	0.001
BLX-MA	295.5	29.5	0.001
CoEVO	301.0	24.0	0.000
DE	262.5	62.5	0.009
DMS-L-PSO	199.0	126.0	0.357
EDA	284.5	40.5	0.001
K-PCX	269.0	56.0	0.004
L-CMA-ES	273.0	52.0	0.003
L-SaDE	209.0	116.0	0.259
SPC-PNX	305.5	19.5	0.000

G-CMAES versus el resto de algoritmos. $D = 10$
P-valor obtenido mediante la aproximación normal

S. García, [D. Molina](#), [M. Lozano](#), [F. Herrera](#), A Study on the Use of Non-Parametric Tests for Analyzing the Evolutionary Algorithms' Behaviour: A Case Study on the CEC'2005 Special Session on Real Parameter Optimization. *Journal of Heuristics*, 15 (2009) 617-644. [doi: 10.1007/s10732-008-9080-4](https://doi.org/10.1007/s10732-008-9080-4).

Milestone: CEC'2005 Real Parameter

Optimization Session and Benchmark

Algoritmos con buen ranking y comportamiento estadístico similar:

MA-CMA-Chains: [D. Molina](#), [M. Lozano](#), [C. García-Martínez](#), [F. Herrera](#), Memetic Algorithms for Continuous Optimization Based on Local Search Chains. *Evolutionary Computation*, 18(1), 2010, 27–63.




Figure 3: Example of LS chain. p_{i+1} is the final parameter value reached by the LS algorithm when it started with a value of p_i . p_0 is the default value for the strategy parameter

MA-CMA-Chains: Adaptación de búsqueda local

Milestone: CEC'2014 Real Parameter Optimization Session and Benchmark

Differential Evolution winner

http://www.ntu.edu.sg/home/EPNSugan/index_files/CEC2014/CEC2014.htm



CEC2014

J. J. Liang, B-Y. Qu, P. N. Suganthan, Problem Definitions and Evaluation Criteria for the CEC 2014 Special Session and Competition on Single Objective Real-Parameter Numerical Optimization, Technical Report 201311, Computational Intelligence Laboratory, Zhengzhou University, Zhengzhou China and Technical Report, Nanyang Technological University, Singapore, December 2013.

There are again two MAs among the three winner algorithms:

L-SHADE [1], an extension of SHADE (SHADE got the fourth place in CEC'2013)

GaAPADE [2], a hybridization of an GA, an DE and an Evolutionary Strategy;

MVMO [3]

[1] R. Tanabe, A. Fukunaga. Improving the Search Performance of SHADE Using Linear Population Size Reduction. In IEEE Congress on Evolutionary Computation, (2014), 1658-1665.

[2] S. Elsayed, S. Ruhul, D. Essam and N. Hamza. Testing United Multi-Operator Evolutionary Algorithms on the CEC2014 Real-Parameter Numerical Optimization. In IEEE Congress on Evolutionary Computation, (2014), 1650-1657.

[3] I. Erlich, J.L. Rueda, S. Wildenhues. Evaluating the Mean-Variance Mapping Optimization on the IEEE-CEC 2014 Test Suite. In IEEE Congress on Evolutionary Computation, (2014), 1625-1632.

Milestone: CEC'2013-15 Real Parameter Optimization Session and Benchmark

Comparación de los mejores

Reference algorithms

IPOP-CMA-ES Winner in CEC'2005.

GAMPC Winner in the CEC'2011.

CEC'2013 Competition

ICMAES-ILS Hybrid of an ILS with CMA-ES.

NBIPOP_aCMA IPOP-CMAES with two populations.

DRMA MA with LS chaining and division in hypercubes.

CEC'2014 Competition

L-LSHADE Adaptive DE.

GaAPPAGE Hybrid GA+DE+CMA-ES.

MVMO14 MVMO.

CEC'2015 Competition

SPS-L-SHADE-EIG Replace L-SHADE with another crossover, and stuck detection.

LSHADE-ND Combine a L-SHADE with a neuro-dynamic optimization method.

Milestone: CEC'2013-15 Real Parameter Optimization Session and Benchmark

Comparación de los mejores

Results for CEC'2013

Position of algorithms by their average ranking

Competition	Algorithm	D10	D30	D50
CEC'2005	IPOP-CMAES	7	7	8
CEC'2011	GAMPC	10	10	10
CEC'2013	ICMAES-ILS	4	5	4
	NBIPOP _a CMA	9	9	9
	DRMA	5	6	6
CEC'2014	L-SHADE	1	2.5	2
	GAAPPADE	3	2.5	5
	MVMO14	8	8	7
CEC'2015	SPS-L-SHADE-EIG	2	4	3
	L-SHADE-ND	6	1	1

Milestone: CEC'2013-15 Real Parameter Optimization Session and Benchmark

Comparación de los mejores

Results for CEC'2014

Position of algorithms by their average ranking

Competition	Algorithm	D10	D30	D50
CEC'2005	IPOP-CMAES	7	5	5
CEC'2011	GAMPC	10	10	10
CEC'2013	ICMAES-ILS	4	3	1
	NBIPOP _a CMA	9	8	8
	DRMA	5	6	7
CEC'2014	L-SHADE	2	1	2
	GAAPPADE	8	7	6
	MVMO14	6	9	9
CEC'2015	SPS-L-SHADE-EIG	3	4	3
	L-SHADE-ND	1	2	4

Milestone: CEC'2013-15 Real Parameter Optimization Session and Benchmark

Comparación de los mejores

Results for CEC'2015

Position of algorithms by their average ranking

Competition	Algorithm	D10	D30	D50
CEC'2005	IPOP-CMAES	9	7	8
CEC'2011	GAMPC	10	10	10
CEC'2013	ICMAES-ILS	7	6	6
	NBIPOP _a CMA	8	8	7
	DRMA	4	5	3
CEC'2014	L-SHADE	5	4	4.5
	GAAPPADE	1	2	1
	MVMO14	6	9	9
CEC'2015	SPS-L-SHADE-EIG	2	1	2
	L-SHADE-ND	3	3	4.5

Milestone: CEC'2013-15 Real Parameter Optimization Session and Benchmark

Comparación de los mejores

Conclusions

Robust algorithms

- L-SHADE and L-SHADE-ND are very robust algorithms.

Expected

- ICMAES-ILS, CEC'2013 winner, is improved by new ones.


Unexpected

- ICMAES-ILS improve CEC'2014 winners for $D=50$.
- GAAPPAGE, from CEC'2013, improve the CEC'2014 and CEC'2015 winners in CEC'2015 competition.

Results

- Older winners are unfairly ignored, improve newer ones.
- Organizers should use them as [reference algorithms](#).

Optimization Session and Benchmark



Summarise

- Several proposals in papers do not compare against *state-of-arts*.
- State-of-art is difficult to identify:
 - Even in competitions, there is not a clear improvement.
 - Older proposals sometimes are fairly ignored.

METAHEURÍSTICAS

TEMA 3. METAHEURÍSTICAS BASADAS EN POBLACIONES

Parte II:

1. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA I (Algoritmos genéticos)
2. EVOLUCIÓN DIFERENCIAL
3. ESTRATEGIAS DE EVOLUCIÓN
4. TEMA 6. PSO. ALGORITMOS DE NUBES DE PARTÍCULAS
5. ALGORITMOS EVOLUTIVOS PARA OPTIMIZACIÓN CONTINUA (Competiciones y modelos)
6. **NUEVOS MODELOS BIOINSPIRADOS PARA OPTIMIZACIÓN DE PARÁMETROS**

Tendencias actuales

Hay diferentes áreas de investigación que centran la atención de los investigadores en “parameter optimization”:

- Nuevos frameworks para Optimización Bioinspirada de Parámetros, y
- desarrollo de enfoques avanzados para competir con the state of the art.
- Automatic Tuning and Self-Adaptation of Algorithmic Parameters (Iterated Race and extensions)



Performance evaluation of automatically tuned continuous optimizers on different benchmark sets


Tianjun Liao^a, , , Daniel Molina^b, , Thomas Stützle^c, 

<http://www.sciencedirect.com/science/article/pii/S1568494614005584>

Tendencias actuales

Hay diferentes áreas de investigación que centran la atención de los investigadores en “parameter optimization”:

- Nuevos frameworks para Optimización Bioinspirada de Parámetros, y
- desarrollo de enfoques avanzados para competir con the state of the art.



Shark smell optimization




Grey Wolf Optimization

Nuevos modelos bioinspirados para la optimización de parámetros (SSO, 2016)

Shark smell optimization

O. Avedinia, N. Amdjady, A. Chasemi (2014). **A new metaheuristic algorithm based Shart Smell Optimization**. Complexity, 21: 97–116, 2016

Movement of Shark Toward Prey



A New Metaheuristic Algorithm Based on Shark Smell Optimization

OVEIS ABEDINIA,¹ NIMA AMJADY,¹ AND ALI GHASEMI²

¹Department of Electrical Engineering, Semnan University, Semnan, Iran and ²Young Researchers and Elite Club, Ardabil Branch, Islamic Azad University, Ardabil, Iran

$$|v_{ij}^k| = \min \left[\left| \eta_k \cdot R1 \cdot \frac{\partial(\text{OF})}{\partial x_j} \right|_{x_{ij}^k} + \alpha_k \cdot R2 \cdot v_{ij}^{k-1}, \left| \beta_k \cdot v_{ij}^{k-1} \right| \right]$$

$$j = 1, \dots, \text{ND}, \quad i = 1, \dots, \text{NP}, \quad k = 1, \dots, k_{\max}$$

$$Y_i^{k+1} = X_i^k + V_i^k \cdot \Delta t_k \quad i = 1, \dots, \text{NP} \quad k = 1, \dots, k_{\max} \quad (9)$$

where Δt_k indicates time interval of the stage k . For simplicity, it is assumed that $\Delta t_k = 1$ for all stages.

From optimization viewpoint, shark implements a local search in each stage to find better candidate solutions. This local search is modeled in the SSO algorithm as follows:

$$Z_i^{k+1,m} = Y_i^{k+1} + R3 \cdot Y_i^{k+1} \quad (10)$$

$$m = 1, \dots, M \quad i = 1, \dots, \text{NP} \quad k = 1, \dots, k_{\max}$$

$$X_i^{k+1} = \arg \max \{ \text{OF}(Y_i^{k+1}), \text{OF}(Z_i^{k+1,1}), \dots, \text{OF}(Z_i^{k+1,M}) \}$$

$$i = 1, \dots, \text{NP}$$

Nuevos modelos bioinspirados para la optimización de parámetros - Modelos

Advances in Engineering Software 69 (2014) 46–61



Contents lists available at ScienceDirect

Advances in Engineering Software

journal homepage: www.elsevier.com/locate/advengsoft



Grey Wolf Optimizer

Seyedali Mirjalili^{a,*}, Seyed Mohammad Mirjalili^b, Andrew Lewis^a

^a School of Information and Communication Technology, Griffith University, Nathan Campus, Brisbane QLD 4111, Australia

^b Department of Electrical Engineering, Faculty of Electrical and Computer Engineering, Shahid Beheshti University, G.C. 1983963113, Tehran, Iran



**Estudio
comparativo
incluyendo
CMAES**

Information Sciences 329 (2016) 597–618



Contents lists available at ScienceDirect

Information Sciences

journal homepage: www.elsevier.com/locate/ins



Across neighborhood search for numerical optimization

Guohua Wu^{1,*}

Science and Technology on Information Systems Engineering Laboratory, National University of Defense Technology, Changsha 410073, Hunan, PR China



Nuevos modelos bioinspirados para la optimización de parámetros – Análisis crítico a esta explosión de propuestas

INTERNATIONAL TRANSACTIONS
IN OPERATIONAL RESEARCH



Intl. Trans. in Op. Res. 00 (2013) 1–16
DOI: 10.1111/itor.12001

INTERNATIONAL
TRANSACTIONS
IN OPERATIONAL
RESEARCH

Metaheuristics—the metaphor exposed

Kenneth Sörensen

*University of Antwerp, Operations Research Group ANT/OR, Prinsstraat 13 – B5xx, 2000 Antwerp, Belgium
E-mail: kenneth.sorensen@ua.ac.be [Sörensen]*

Received 2 November 2012; received in revised form 12 November 2012; accepted 13 November 2012

Abstract

In recent years, the field of combinatorial optimization has witnessed a true tsunami of “novel” metaheuristic methods, most of them based on a metaphor of some natural or man-made process. The behavior of virtually any species of insects, the flow of water, musicians playing together – it seems that no idea is too far-fetched to serve as inspiration to launch yet another metaheuristic. In this paper, we will argue that this line of research is threatening to lead the area of metaheuristics away from scientific rigor. We will examine the historical context that gave rise to the increasing use of metaphors as inspiration and justification for the development of new methods, discuss the reasons for the vulnerability of the metaheuristics field to this line of research, and point out its fallacies. At the same time, truly innovative research of high quality is being performed as well. We conclude the paper by discussing some of the properties of this research and by pointing out some of the most promising research avenues for the field of metaheuristics.

Keywords: optimization; combinatorial optimization; metaheuristics; heuristics

Nuevos modelos bioinspirados para la optimización de parámetros – Estado del arte

Revisión de propuestas de Metaheurísticas

<https://arxiv.org/abs/2002.08136>

Published: 05 July 2020

Comprehensive Taxonomies of Nature- and Bio-inspired Optimization: Inspiration Versus Algorithmic Behavior, Critical Analysis Recommendations

[Daniel Molina](#) , [Javier Poyatos](#), [Javier Del Ser](#), [Salvador García](#), [Amir Hussain](#) & [Francisco Herrera](#)

Cognitive Computation **12**, 897–939(2020) | [Cite this article](#)

6 Citations | 0 Altmetric | [Metrics](#)

arXiv.org > cs > arXiv:2002.08136


Computer Science > Artificial Intelligence

Comprehensive Taxonomies of Nature- and Bio-inspired Optimization: Inspiration versus Algorithmic Behavior, Critical Analysis and Recommendations

[Daniel Molina](#), [Javier Poyatos](#), [Javier Del Ser](#), [Salvador García](#), [Amir Hussain](#), [Francisco Herrera](#)

(Submitted on 19 Feb 2020 (v1), last revised 20 Feb 2020 (this version, v2))

In recent years, a great variety of nature- and bio-inspired algorithms has been reported in order to efficiently address complex optimization problems. In the last few years, this field has grown considerably, reaching unprecedented levels that dark the future prospects of this field. In this paper, we propose a comprehensive, principle-based taxonomies that allow researchers to organize existing algorithms according to different criteria: the source of inspiration and the behavior of each algorithm. Using these taxonomies, we analyze the similarities between them, and the identification of the most similar classical algorithm for each category. Furthermore, what is claimed in their public disclosure: specifically, we show that more than one-third of the algorithms are grounded on the conclusions of our critical analysis, we give several recommendations for a growing research field.



Nuevos modelos bioinspirados para la optimización de parámetros – Estado del arte

Revisión de propuestas de Me
<https://arxiv.org/abs/2002.08136>

arXiv.org > cs > arXiv:2002.08136
Computer Science > Artificial Intelligence

Comprehensive Taxonomies of Algorithmic Behavior, Critical

Daniel Molina, Javier Poyatos, Javier Del Ser, S
(Submitted on 19 Feb 2020 (v1), last revised 20 Feb 2020)

In recent years, a great variety of nature- and bio-inspired algorithms have been observed in Nature in order to efficiently address con- siderable problems, reaching unprecedented levels of performance. This paper presents comprehensive, principle-based taxonomies that allow the classification of different algorithms according to different criteria: the source of inspiration and the behavior. The paper also identifies similarities between them, and the identification of the

Optimización inspirada en la naturaleza y en la biología: lo bueno, lo malo, lo feo y lo esperanzador

D. Molina, J Poyatos, E Osaba, J DEL SER, F Herrera
DYNA 97 (2), 114-117, 2022




Figure 6: Classification of proposals by its original algorithm.

PRACTICA 4 – Hasta 5 ptos – Alternativa Examen (1 + 1.5 + 1 + 1.5)

- Elegir una MH (MHe) no estudiada en clase (Hasta 1) (Alternativamente hacer una propuesta original)**
 - Resumen (hasta 2-3 paginas)**
 - Presentación transparencias. Transparencia: analizar componentes que provocan exploración vs componentes que provocan explotación. Analizar este equilibrio.**
- Adaptar el uso de la MH a uno de los problemas de prácticas. Discutir cómo y hacer un estudio experimental comparando con los resultados de las prácticas 1 a 3 que se tengan. (Hasta 1) (Hasta 1.5 por dificultad)**
- Diseñar una propuesta de calidad (mejorando a MHe) Algoritmo híbrido memético (MHe + Local Search, opción u otra hibridación) (Hasta 1)**
- Plantear mejoras sobre el comportamiento/diseño de MHe (Hasta 1.5 con estudio experimental):**
 - Modificar/introducir componentes para mejorar el equilibrio diversidad-convergencia (ej. CHC, GADEGD, ...)**
 - Adaptar el algoritmo para que obtenga múltiples soluciones.**

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

- Usaremos benchmark “CEC 2017 Special Session and Competition on Single Objective Bound Constrained Real-Parameter Numerical Optimization”.
- 30 funciones, distinto nivel de complejidad.
- Distintos valores de dimensión: 10, 30, 50 (no 100).
- Criterio de parada: $10.000 * dimension$.
- Rango de todas las funciones: $[-100, 100]$.
- Se ejecuta cada una X veces para calcular la media (usamos $T=10$, por reducir tiempos, el estándar son 50).
- Se mide el error con respecto al óptimo ($fun * 100$): 100 para f_1 , 200 f_2 , ...
- Se calcula el error cada cierto % de evaluaciones: 1%, 2%, ..., 10%, 20%, ...

G. Wu, R. Mallipeddi, P. N. Suganthan, Problem definitions and evaluation criteria for the CEC 2017 competition and special session on constrained single objective real-parameter optimization, Tech. rep., Nanyang Technological University, Singapore (2016).

3/16

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

- Código actualizado en <https://github.com/dmolina/cec2017real/>.
- Disponible en C++, con wrapper para Python.
- Se puede compilar como librería, o dentro del proyecto.
- Ficheros:
 - *cec17_test_func.c*: fichero original del benchmark.
 - *cec17.c*: con las funciones del API simplificado.
 - *input_data*: debe estar en el directorio donde se ejecute el binario.
 - *extract.py*: script en Python para agrupar los resultados.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

Cuestiones

- ¿Cuáles son los criterios que se van a utilizar a la hora de calificar la práctica alternativa?

Se tienen 4 bloques y en cada uno se evaluará el trabajo realizado, que se ajuste a lo solicitado y la calidad del estudio experimental y su análisis. En el bloque 1 se analiza la calidad de la descripción, en los bloques 2 y 3 el estudio experimental y análisis, y en el bloque 4 se tienen en cuenta originalidad y la calidad de la propuesta. Si la MHe es original, se tendrá en cuenta la creatividad asociada.

- ¿Hay que implementar nuestra metaheurística inventada, o es suficiente con una explicación mediante pseudocódigo?

Hay que implementarla y analizarla experimentalmente con la competición CEC2017, así como el modelo memético (punto 3) y las extensiones (punto 4) de la propuesta.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

Cuestiones

- ¿Hay que superar alguna metaheurística tomada como referencia?

No necesariamente, la naturaleza de la MHe condicionará la calidad del resultado.

- ¿Podrían subir algún guión especificando qué hay que entregar exactamente?

Este documento sirve de guión, junto en el fichero PDF de Daniel Molina que explica cómo hacer la experimentación.

Es necesario entregar un documento que describa con detalle el estudio realizado y entregar el software asociado.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

Cuestiones

- ¿Cuando hay que avisarle (si es que hace falta) de cuál será nuestra metaheurística inventada?

Para indicar que MHe se va a utilizar (original o del documento mencionado) se tiene plazo hasta final de Mayo, y se necesita confirmación del profesor para evitar un uso excesivo de la misma MHe. Puede no entregarse la práctica e ir al examen, avisando con 48 horas de antelación a la fecha del examen.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

¿Se puede plantear un estudio alternativo?


Si, se puede hacer un estudio en un campo de aplicación concreto.

Ejemplo: Evolución de modelos de Deep Learning

Real, Esteban, et al. "Large-scale evolution of image classifiers."
arXiv preprint 2016, ICML. 2017.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen



METAHEURÍSTICA

2025-2026



- Tema 1. Introducción a las Metaheurísticas
- Tema 2. Modelos de Búsqueda: Entornos y Trayectorias vs Poblaciones
- Tema 3. Metaheurísticas Basadas en Poblaciones
- Tema 4: Algoritmos Meméticos
- Tema 5. Metaheurísticas Basadas en Trayectorias
- Tema 6. Metaheurísticas Basadas en Adaptación Social
- Tema 7. Aspectos Avanzados en Metaheurísticas
- Tema 8. Metaheurísticas Paralelas
- Tema 9. Modelos de IA Evolutivos. Aprendizaje Evolutivo