Aprendizaje Automático

Introducción a las prácticas

Manuel Pegalajar Cuéllar[1]

[1]Departamento de Ciencias de la Computación e Inteligencia Artificial. Universidad de Granada

Contenido

Parte I: Información general de las prácticas

1. Profesor/es de prácticas
2. Objetivos y Metodología
3. Materiales de prácticas
4. Primer uso de Colab y bibliotecas asociadas
5. Cómo realizar la entrega de prácticas

Parte II: Herramientas de prácticas

6. La biblioteca NumPy
7. Visualización de datos con MatplotLib
8. Lectura de datos con Pandas
9. Scikit-Learn

Parte I

Información general de las prácticas

Contenido

1. Profesor/es de prácticas
2. Objetivos y Metodología
3. Materiales de prácticas
4. Primer uso de Colab y bibliotecas asociadas
5. Cómo realizar la entrega de prácticas

Profesor

- Manuel Pegalajar Cuéllar (grupos de los lunes y los miércoles)
- E-Mail: manupc@ugr.es
- URL: https://www.ugr.es/personal/manuel-pegalajar-cuellar
- Localización: Despacho D19. 4a. planta de la ETSIIT.
- Tutorías:

Segundo semestre

DÍA	HORARIO	LUGAR
Lunes	10:30 - 12:30	D19 (Etsiit)
Lunes	15:30 - 17:30	D19 (Etsiit)
Martes	10:30 - 12:30	D19 (Etsiit)

Figura 1: Horario de tutorías personalizadas.

Concertar cita previa por e-mail.

Profesor

- Marios Kountouris (grupo de los viernes)
- E-Mail: mariosk@ugr.es
- URL: https://www.ugr.es/personal/marios-kountouris

Concertar cita previa por e-mail.

Contenido

1. Profesor/es de prácticas
2. Objetivos y Metodología
3. Materiales de prácticas
4. Primer uso de Colab y bibliotecas asociadas
5. Cómo realizar la entrega de prácticas

Objetivos de las prácticas

- Llevar a la práctica los conceptos de teoría.
- Que **aprendáis** para después **aprobar**.

¿Cómo?

Planificación de las prácticas:

P0 Introducción a Python, Numpy y Sk-Learn. *(no evaluable)*

P1 Práctica de aprendizaje supervisado.

P2 Práctica de aprendizaje no supervisado.

P3 Práctica de aprendizaje automático (más) avanzado.

Proyecto **Proyecto práctico opcional a desarrollar por el estudiante.**

Metodología de las prácticas

- Exposiciones de repaso por parte del profesor.
- Seminarios de introducción a las prácticas.
- Resolución de ejercicios en clase y trabajo autónomo.
- Corrección/feedback sobre las entregas *ASAP*.

La asistencia a prácticas **no es obligatoria**, pero sí **recomendable**.

Además...

- Quiero buen ambiente en clase.
- **Nadie nace sabiendo**. Todos aprendemos (yo incluido). Solicitad ayuda cuando la necesitéis.
- Dadme feedback sobre vuestras necesidades de aprendizaje.

Metodología de las prácticas

Planificación inicial estimada:

P0 17/Feb al 7/Mar.

P1 10/Mar al 30/Mar **(entrega)**.

P2 31/Mar al 27/Abr **(entrega)**.

P3 28/Abr al 25/May **(entrega)**.

Proyecto **Trabajo por grupos de 2** a lo largo del semestre. Plazo límite: 30/May.

Entregas: Con cada trabajo/práctica se entrega un **Notebook** que integra **código**, **resultados** y **discusión**.

- La **discusión** de los resultados, y el **análisis** y **descripción** del trabajo realizado, resultan fundamentales *(es importante que los resultados sean correctos, pero todavía lo es más* **demostrar que se entiende lo que se está haciendo***)*.

Evaluación de las prácticas

La evaluación de las prácticas será la siguiente:

- P0 No evaluable.
- P1 Máximo de 10 puntos.
- P2 Máximo de 10 puntos.
- P3 Máximo de 10 puntos.
- Proyecto **OPCIONAL**. **EN GRUPOS DE 2**. Máximo de 10 puntos.

La **calificación de prácticas** se obtiene mediante la fórmula:

$$PR = 2\frac{P1 + P2 + P3 + Proyecto}{10}$$

La **calificación FINAL de prácticas** se encuentra en el rango $[0, 8]$.

¿Por qué un proyecto práctico opcional?

El aprendizaje automático es muy extenso, y avanza a ritmos vertiginosos.

Posiblemente, lo que enseñamos hoy en el aula quede obsoleto en pocos años.

El **aprendizaje a lo largo de la vida** resultará esencial para mantenerse actualizado.

El objetivo principal del proyecto opcional es, precisamente, favorecer la **capacidad de auto-aprendizaje** para ser capaz de mantenerse actualizado y estar preparado para aprender cuestiones novedosas.

Para ello, el proyecto tratará sobre **temáticas que no se hayan tratado en teoría** o, en su defecto, **se hayan visto en menor profundidad**.

Objetivo secundario: DISFRUTAR del aprendizaje automático aprendiendo.

Contenido

1. Profesor/es de prácticas
2. Objetivos y Metodología
3. Materiales de prácticas
4. Primer uso de Colab y bibliotecas asociadas
5. Cómo realizar la entrega de prácticas

Materiales necesarios

Trabajaremos fundamentalmente con:

- **Google Colab**. Herramienta online de Google para desarrollo de scripts Python. Accesible mediante la cuenta **@go.ugr.es**.
- **NumPy**. Biblioteca fundamental de cálculo numérico y científico en Python.
- **MatplotLib**. Biblioteca de visualización y generación de gráficas.
- **Pandas**. Biblioteca fundamental en Ciencia de Datos.
- **Scikit-Learn**. Biblioteca Python de aprendizaje automático robusta y bien testeada, construida sobre las bibliotecas **NumPy** y **SciPy**.
- **TensorFlow/Keras**. Biblioteca Python de Google para desarrollo de modelos avanzados de aprendizaje automático y Deep Learning.

Bibliografía fundamental

Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow. O'Reilly Media, 2022.

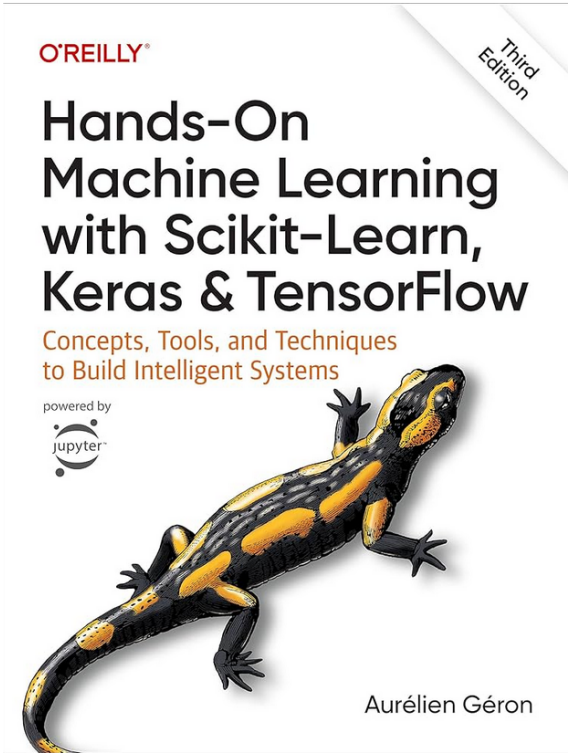

Notebooks disponibles online:
https://github.com/ageron/handson-ml3

Bibliografía fundamental

Sebastian Raschka, Vahid Mirjalili, Python Machine Learning. Packt. 2019

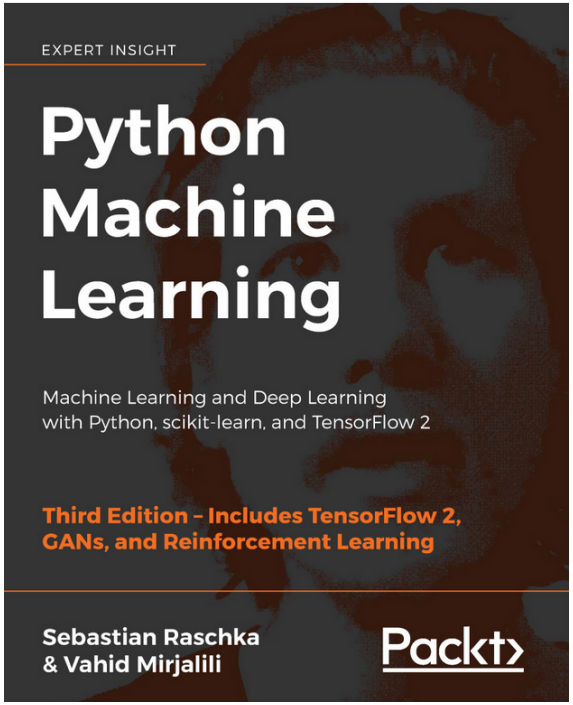

Notebooks disponibles online:
https://github.com/rasbt/python-machine-learning-book-3rd-edition

Contenido

1. Profesor/es de prácticas
2. Objetivos y Metodología
3. Materiales de prácticas
4. Primer uso de Colab y bibliotecas asociadas
5. Cómo realizar la entrega de prácticas

Uso de Google Colab en las prácticas

Accesible online desde https://colab.research.google.com/

- Con cada práctica entregaréis un **fichero .ipynb** exportado desde Colab.
- En dicho fichero se incorpora **código**, **resultados**, **discusión** y **análisis** de los mismos. Actúa como un *"todo en uno"*; es decir, un fichero de Colab integra implementación y documento de memoria de prácticas.
- El uso de Colab no significa que podáis realizar una memoria de menor calidad o menor grado de detalle que la que redactaríais en un PDF independiente.

Se recomienda revisar con atención la documentación oficial: https://colab.research.google.com/notebooks/intro.ipynb

Pasos para usar Google Colab

1. Accedemos a https://colab.research.google.com/ e iniciamos sesión con nuestra cuenta **@go.ugr.es**.

Pasos para usar Google Colab

2. Acto seguido, se nos permite abrir un cuaderno *Notebook* desde distintas fuentes, o bien crear uno nuevo (el cual se almacenará en nuestro espacio de GDrive).

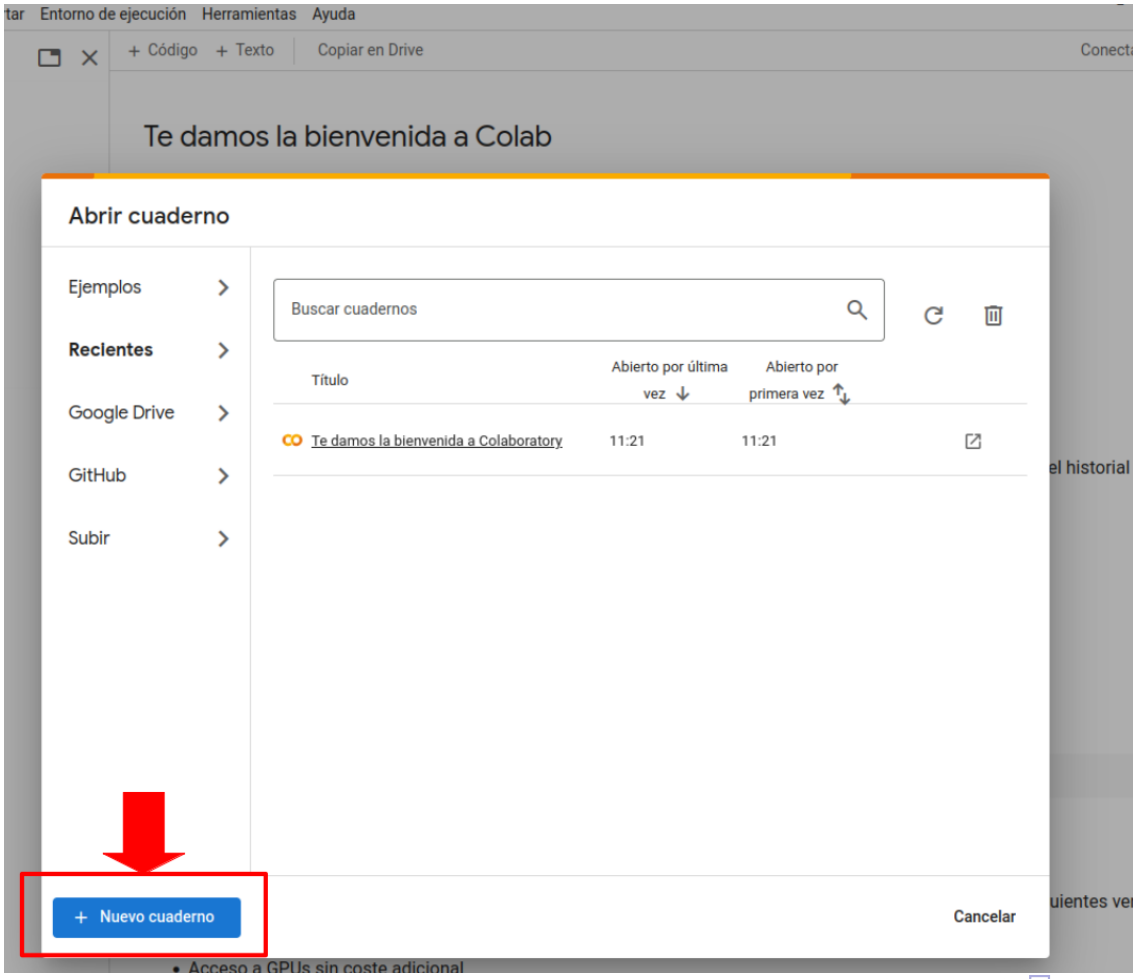

Pasos para usar Google Colab

3. El cuaderno ya está creado en nuestro GDrive, con nombre **untitled?.ipynb**. El nombre se puede cambiar haciendo clic sobre él.

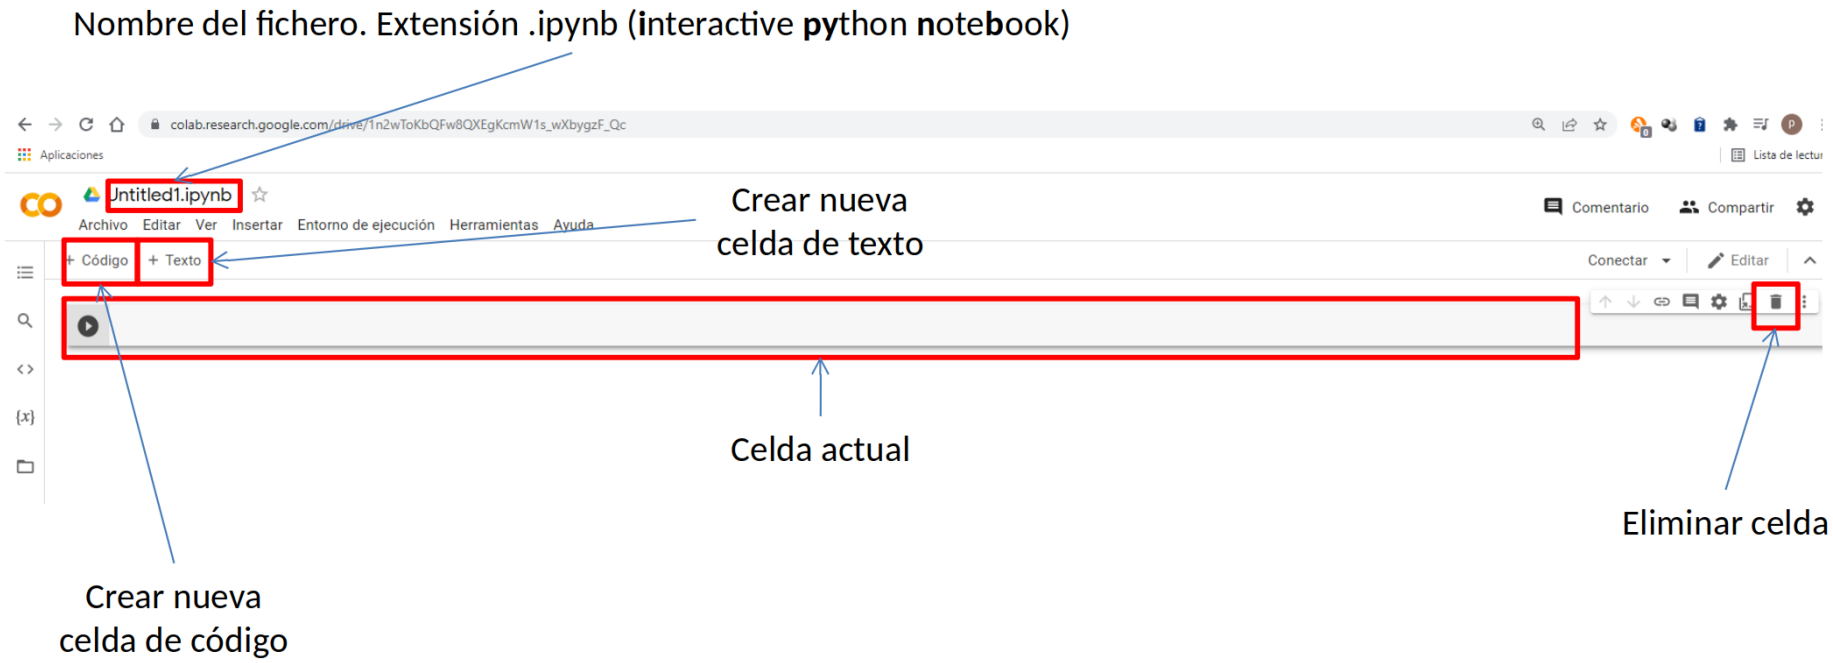

Primer contacto con Colab

1. Copia el fichero Intro_Notebook.ipynb y el fichero UGR-Logo.png a tu cuenta de GDrive, dentro de la carpeta Colab Notebooks. También puedes **subir** el fichero desde el menú Archivo-subir cuaderno.
2. Abre el cuaderno desde Colab.

Te interesa practicar (tienes 5' para hacerlo):

- Creación de celdas de texto con distintos formatos, celdas de código, borrarlas, ejecutarlas...
- Intercalar celdas de texto y de código Python.
- Conocer cómo ejecutar una única celda, todas las celdas y reiniciar la sesión para ejecutar todo.
- Familiarizarte con el concepto de sesión activa. Presta atención a las celdas 8 y 9 de código: Son fuentes de muchos errores de programación con Notebooks.
- Te conviene familiarizarte con las macros (sobre todo de creación/borrado/ejecución de celdas).

Contenido

1. Profesor/es de prácticas
2. Objetivos y Metodología
3. Materiales de prácticas
4. Primer uso de Colab y bibliotecas asociadas
5. Cómo realizar la entrega de prácticas

Cuadernos Colab en las entregas de prácticas

Normas de entrega:

- Se entregará, a través de PRADO, un único Notebook por cada práctica (extensión .ipynb).
- El Notebook será autocontenido y tendrá celdas de texto y de código.
- Se deberá organizar en **secciones**.
- La primera celda deberá contener:
  - Un título de la práctica.
  - El número de práctica, la asignatura y el curso académico.
  - **Nombre y apellidos del autor**.
- En las celdas de texto se deberá explicar la formulación del problema, cómo se ha abordado, una descripción y análisis de resultados, discusión de los mismos y conclusiones finales.

Cuadernos Colab en las entregas de prácticas

No hay informe/memoria de prácticas en formato PDF. Dicho informe se incluye dentro del notebook como celdas de texto. Por tanto, el contenido debe cumplir un objetivo fundamental, que consiste en explicar:

- **qué** se ha hecho,
- **cómo** se ha hecho lo que se ha hecho,
- **porqué** se ha hecho así (motivación),
- **qué resultados** se han obtenido, y
- **qué conclusiones** podemos obtener a partir de los mismos.

Un informe debe ser claro, conciso y bien estructurado. Si no hay informe/discusión, **es como no entregar nada** (con su correspondiente calificación de 0 puntos).

Cuadernos Colab en las entregas de prácticas

Estructura básica del informe (que puede/debería intercalarse con celdas de código):

1. **Portada**: la primera celda.
2. **Índice**: que permita comprender la estructura general de los contenidos y también localizarlos con facilidad.
3. **Introducción**: se describe el problema a resolver (¿qué queremos hacer?), la motivación (¿por qué es relevante hacerlo?), y los objetivos (¿qué objetivos concretos vamos a abordar de cara a resolver el problema?).
4. **Fundamentos teóricos**: se presentan los conceptos necesarios para comprender el trabajo. **No se trata de repetir mecánicamente lo que se indica en teoría/prácticas, sino en demostrar que se comprenden los conceptos fundamentales**.
5. **Estado del Arte**: se presenta qué se ha hecho en el campo con anterioridad, y cuáles son los mejores métodos en la actualidad.

Cuadernos Colab en las entregas de prácticas

Estructura básica del informe (continuación):

6. **Métodos**: descripción detallada de los métodos empleados y/o propuestos.
7. **Experimentos**:
   - Descripción del conjunto de datos empleado.
   - Protocolo de validación experimental.
   - Métricas empleadas (para entrenamiento y en validación).
   - Experimentos realizados.
   - Resultados obtenidos.
   - Discusión sobre los mismos.
8. **Conclusiones**: **No se trata de una conclusión subjetiva por parte del que crea el informe**. Se presenta, de modo breve y a modo de resumen, las principales conclusiones del trabajo realizado.
9. **Bibliografía**: Contiene todas las referencias manejadas por el estudiante a la hora de realizar el trabajo. **Los apuntes o diapositivas del profesor no son bibliografía**.

Cuadernos Colab en las entregas de prácticas

Algunas recomendaciones:

- Se deben **discutir y analizar los resultados** obtenidos, tanto a nivel cualitativo como cuantitativo. No vale decir *"Podemos ver el resultado durante la ejecución del programa"*.
- **MUY IMPORTANTE**: incluir información que ponga en valor el trabajo realizado:
  - ventajas e inconvenientes de los métodos empleados, problemas encontrados a la hora de realizar la práctica,
  - descripción de experimentos fallidos realizados,
  - motivos que nos llevan a usar unos valores para los parámetros en lugar de otros, etc.
- Las figuras y tablas deben verse correctamente (una figura borrosa o con fuente muy pequeña no cumple su función). En las tablas, limitad el número de decimales a 2 o 3.

Cuadernos Colab en las entregas de prácticas

Algunas recomendaciones:

- Usad figuras con diagramas para apoyaros en las explicaciones. Un texto se entiende mejor si hay una figura o gráfica asociada.
- Integrad las fórmulas y las ecuaciones dentro del mismo documento.
- Usad LaTeX integrado en el cuaderno.

En resumen, tenemos que hacernos la siguiente pregunta: *Si nosotros no hubiésemos escrito esta memoria, al leerla, ¿comprenderíamos el trabajo desarrollado? ¿Seríamos capaces de valorar el trabajo realizado y los conocimientos de quien lo ha hecho?*

Creación de secciones en cuadernos Colab

Se pueden crear índices en Google Colab de forma sencilla y visual:

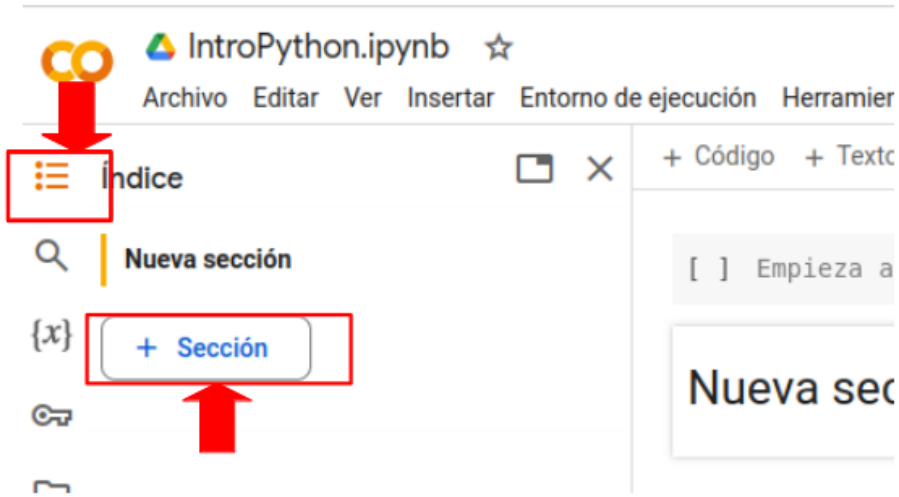

Creación de secciones en cuadernos Colab

Se pueden crear subsecciones de índices en Google Colab. También se puede hacer de forma manual en una celda de texto incluyendo símbolos # de forma sencilla y visual:

- # sección (1)
- ## subsección (1.1)
- ### subsubsección (1.1.1)
- ### subsubsección (1.1.2)
- ## subsección (1.2)
- # sección (2)
- ## subsección (2.1)
- ...

Creación de secciones en cuadernos Colab

Un ejemplo:

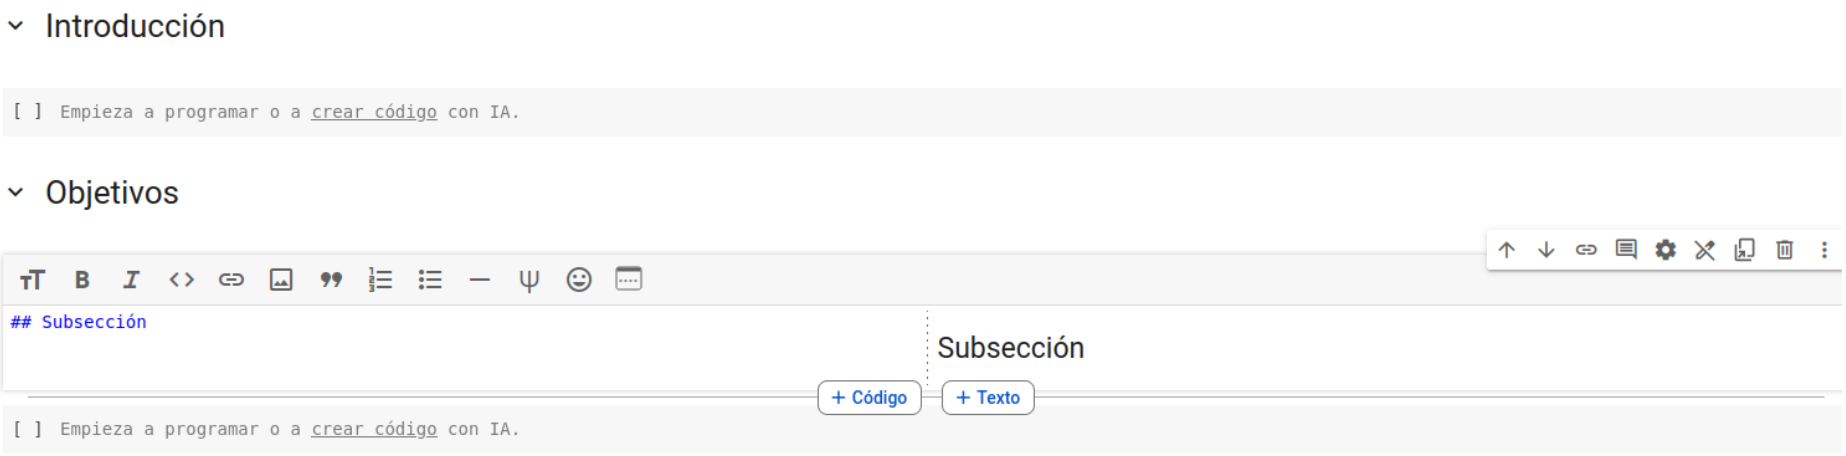

Integración de LaTEX en cuadernos Colab

Tutoriales sobre LaTEX:

- OverLeaf: https://www.overleaf.com/learn/latex/Tutorials
- Otro tutorial: https://latex-tutorial.com/tutorials/

Ejemplo: Fichero LatexColab.ipynb

Ejemplo de uso de ecuaciones LaTEX

```
La función sigmoide $\sigma(x)$ se define según se indica en la
fórmula siguiente:

\begin{equation}
\sigma(x)= {1\over {1+e^{-x}}}
\end{equation}

Algunas de las funciones de activación más comunes son:


\begin{array}{cc}
\textbf{Nombre} & \textbf{Función}\\
```

La función sigmoide $\sigma(x)$ se define según se indica en la fórmula siguiente:

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

Algunas de las funciones de activación más comunes son:

Nombre	**Función**
Sigmoide	$\sigma(x) = \frac{1}{1+e^{-x}}$
ReLU	$f(x) = max(0, x)$

Un ejemplo completo

Ejemplo de cuaderno: Fichero IntroPython.ipynb.

- Copiad el cuaderno IntroPython.ipynb a vuestro GDrive, en la carpeta dedicada a Notebooks de Colab.
- Se trata del primer tutorial de la asignatura, dedicado a la programación básica utilizando lenguaje Python.
- Seguid sus instrucciones para aprender a programar en Python a nivel introductorio.
- Se puede utilizar también para ver cómo usar diferentes estructuras (imágenes, ecuaciones, secciones...)

Parte II

Herramientas de prácticas

Contenido

6 La biblioteca NumPy

7 Visualización de datos con MatplotLib

8 Lectura de datos con Pandas

9 Scikit-Learn

NumPy

NumPy es un referente en Python para la realización de cálculos matemáticos.
Introduce el tipo de dato array/array multidimensional ndarray.

Referencia completa a la biblioteca:

https://numpy.org/doc/stable/reference/index.html

Uso en Python: Normalmente importándola con alias.

```
import numpy as np

```

Creación de arrays

Normalmente como:

- ```
  array= np.array(lista)
  ```

  Para crear un array a partir de una lista (o array multidimensional a partir de lista de listas)

- ```
  array= np.zeros((dim1, dim2, ..., dimn))
  ```

  Para crear un array de *n* dimensiones, cada dimensión *i* con tamaño **dimi**, inicializado a 0.

- ```
  array= np.ones((dim1, dim2, ...))
  ```

  Para crear un array de *n* dimensiones, cada dimensión *i* con tamaño **dimi**, inicializado a 1.

La variable **array** se crea con tipo de dato **ndarray** de NumPy.
  ```

Creación de arrays

Normalmente como:

- ```
  array= np.empty(dim1, dim2, ...)
  ```

  Para crear un array de *n* dimensiones, cada dimensión *i* con tamaño **dimi**, inicializado con basura.

- ```
  array= np.arange(start, end, step)
  ```

  Para crear un array de forma similar a la función **range** de Python.

- ```
  array= np.linspace(start, end, n)
  ```

  Para crear un array 1D conteniendo **n** valores entre **start** y **end** (**inclusive**) distribuidos uniformemente.

Parámetros opcionales: Dependen de las funciones.
dtype: Permite establecer el tipo de dato de las componentes del array.
  ```

Atributos accesibles del tipo *ndarray*

Hay bastantes. Los más comunes son:

- ```
  array.size
  ```

  El número total de componentes en el array.

- ```
  array.ndim
  ```

  El número de dimensiones que tiene el array.

- ```
  array.shape
  ```

  Tupla de array.ndim componentes, donde cada componente indica el número de elementos posibles del array en dicha dimensión.

- ```
  array.dtype
  ```

  El tipo de dato de las componentes del array.

Tipos de datos de las componentes de un array

Son los posibles valores para **dtype**. Hay muchos, pero destacamos los más comunes:

- Todos los tipos básicos de Python (int, float, complex, str, object)
- Enteros con diversa precisión: np.int16, np.int8, np.int32...
- Enteros sin signo con diversa precisión: np.uint16, np.uint8, np.uint32...
- Reales con diversa precisión: np.float16, np.float32, np.float64...
- Complejos con diversa precisión: np.complex64, np.complex128, ...
- etc.

Ejemplos de inicialización

Ejemplos de inicialización y acceso a atributos de nu objeto **ndarray**:

```
import numpy as np

a= np.zeros(10, dtype=int) # Array 1D de 10 0's int
a= np.linspace(0, 1, 11) # [0, 0.1, 0.2, ..., 0.9, 1]
a= np.ones((10, 10), dtype=float) # Array 2D de 10x10
a= np.empty(5, dtype=complex) # array vacio de 5 elms
a= np.ones((10, 5), dtype=float) # Array 2D de 10x5

print(a.size) # 50= 10*5
print(a.ndim) # 2
print(a.shape, a.shape[0], a.shape[1]) # (10, 5) , 10, 5
print(a.dtype) # np.float64

```

Indexación y acceso a componentes

Hay varias formas de acceder a las componentes de un array:

a) Todos los mecanismos de indexación posibles con listas.

```
import numpy as np

a= np.arange(5) # [0, 1, 2, 3, 4]

print(a[1], a[-1]) # 1, 4
print(a[2:]) # 2, 3, 4

```

Indexación y acceso a componentes

Hay varias formas de acceder a las componentes de un array:

b) El operador **:** y la **,**

```
import numpy as np

a= np.array([ [1, 2, 3], [4, 5, 6] ])

print(a[0]) # [1, 2, 3]
print(a[0][0]) # 1
print(a[0,0]) # 1
print(a[0, 1:]) # [2, 3]
print(a[0, :]) # [1, 2, 3]
print(a[:, -1]) # [3, 6]

```

Indexación y acceso a componentes

Hay varias formas de acceder a las componentes de un array:

c) Utilizando acceso a componentes mediante tupla de índices.

d) Indexación booleana

```
import numpy as np

a= np.array([ [1, 2, 3], [4, 5, 6] ])
b= np.array([ 4, 6, 1, 3, 6, 8 ])

# Tupla de indices
print(a[:, (2, 0)]) # [[3, 1],[6, 4]]

# Indexacion booleana
print(a[ a>3 ])  # [[3, 1],[6, 4]]
print(b[ b>3 ]) # [4, 6, 6, 8]
```

Reorganización de componentes y dimensiones

Hay varias formas de modificar la disposición de las componentes de un array:

- Cambio de la forma (*shape*) de un array con **reshape**.
- Inserción de nueva dimensión con **newaxis**.
- Intercambio de posiciones de dimensiones con **swapaxes**.
- Eliminación de dimensiones de tamaño 1 con **squeeze**.

```
import numpy as np

a= np.array([ [1, 2, 3, 4, 5, 6] ])

# reshape
print(a.reshape(2, 3)) # [[1, 2, 3], [4, 5, 6]]
print(a.reshape(-1, 3)) # [[1, 2, 3], [4, 5, 6]]

a= a.reshape(1, -1) # [[1],[2],[3],[4],[5],[6]]

# squeeze
a= a.squeeze() # [1, 2, 3, 4, 5, 6]
```

Por dónde empezar con NumPy

La biblioteca NumPy es enorme. Se necesitaría todo un curso para aprender a usar la biblioteca al completo y de forma eficiente. Algunas funcionalidades´:

- Operaciones aritméticas elemento a elemento: +, -, *, **, /, %, ...
- Funciones matemáticas: sqrt, pow, exp, sin, tan, ... (Todas las de math).
- Cambio de forma y copia: reshape (manteniendo número de componentes), concatenate, hstack, vstack, copy, ...
- Funciones de matrices (ndarray 2D): @, dot, cross, T, linalg.det, linalg.inv, ...
- Estadística: mean, std, var, sum, prod, cumsum, min, max, argmin, argmax, ...
- Constantes y valores universales: pi, inf, -inf, nan, e, ...
- Valores aleatorios: random.seed, random.rand, random.randn, random.randint, random.permutation...

Cuaderno de iniciación a NumPy: IntroNumpy.ipynb

Contenido

6 La biblioteca NumPy

7 Visualización de datos con MatplotLib

8 Lectura de datos con Pandas

9 Scikit-Learn

MatplotLib

La visualización de datos:

- Permite analizar el comportamiento de la información que tenemos sobre un problema a resolver.
- Permite analizar los resultados de los modelos de IA que generemos para resolverlo.
- Imprescindible para el Análisis Exploratorio de Datos.
- Existen multitud de alternativas, genéricas y especializadas, para mostrar gráficas de gran calidad.

MatPlotLib es una de las bibliotecas más conocidas para visualización de datos. Sus capacidades son similares a las de software de pago o tradicionalmente usado para cálculo científico (Matlab, Octave).
Realizar gráficas con la biblioteca es sencillo.
Realizar una visualización atractiva es más complejo, requiere amplios conocimientos de la biblioteca. Referencia completa a la biblioteca matplotlib:

https://matplotlib.org/stable/index.html

Uso en Python: Normalmente importando sub-paquetes con alias.

```
1     import matplotlib.pyplot as plt
2
```

Gráficos de líneas:

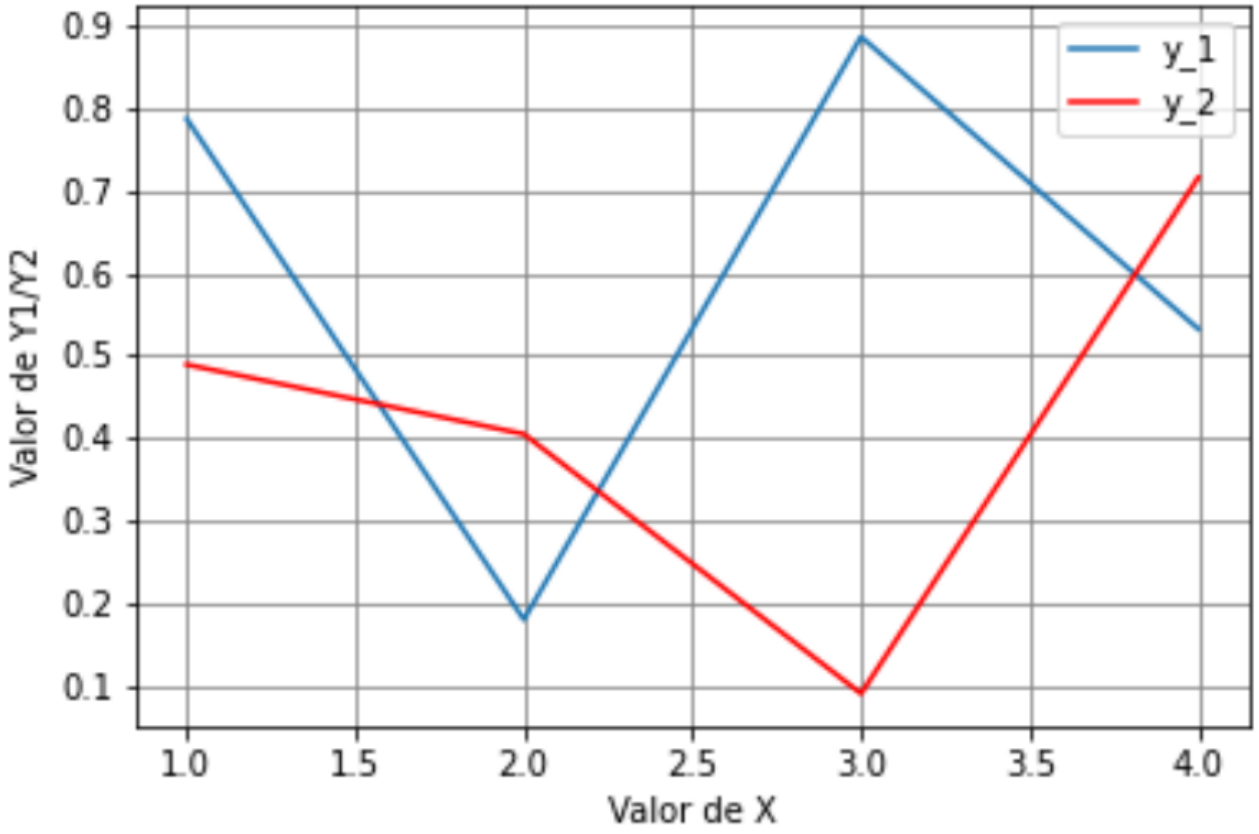

Múltiples gráficas por figura (subplots):

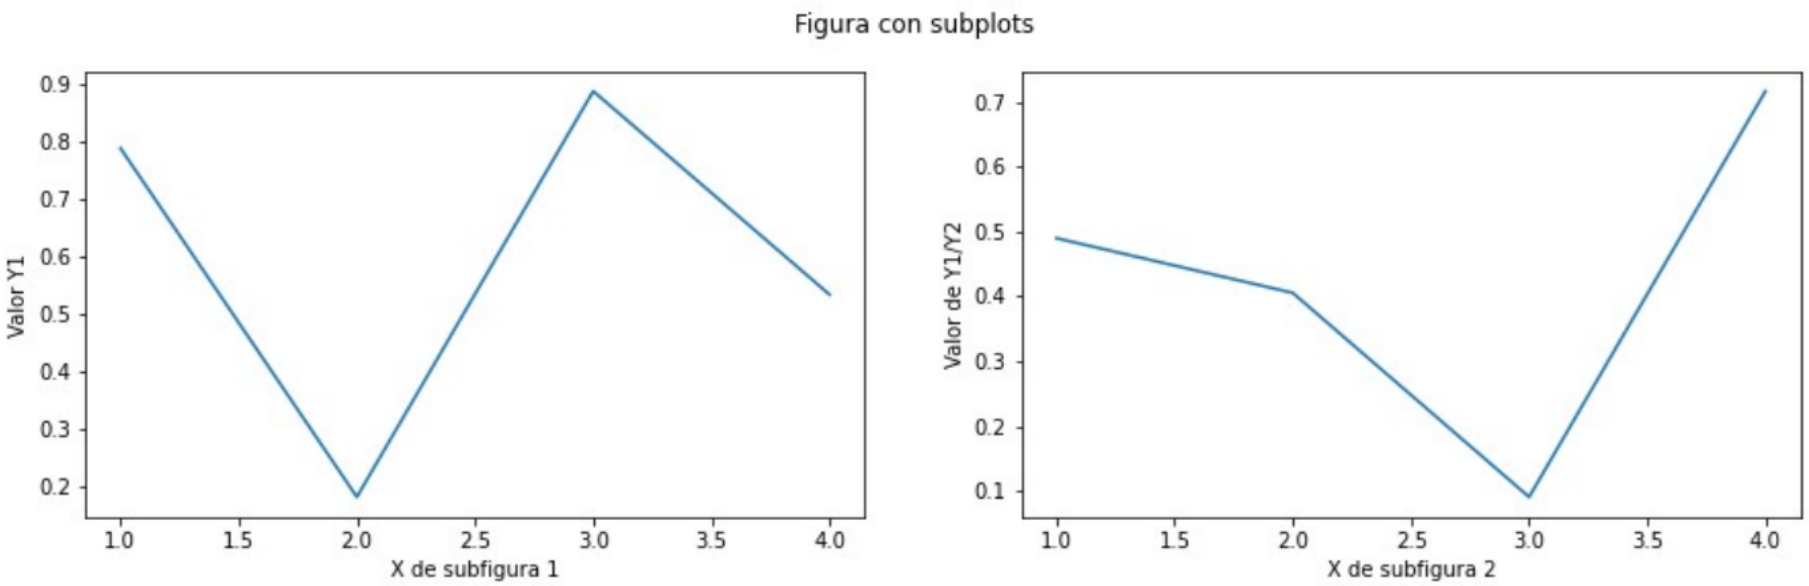

Gráficos de dispersión (scatter plots):

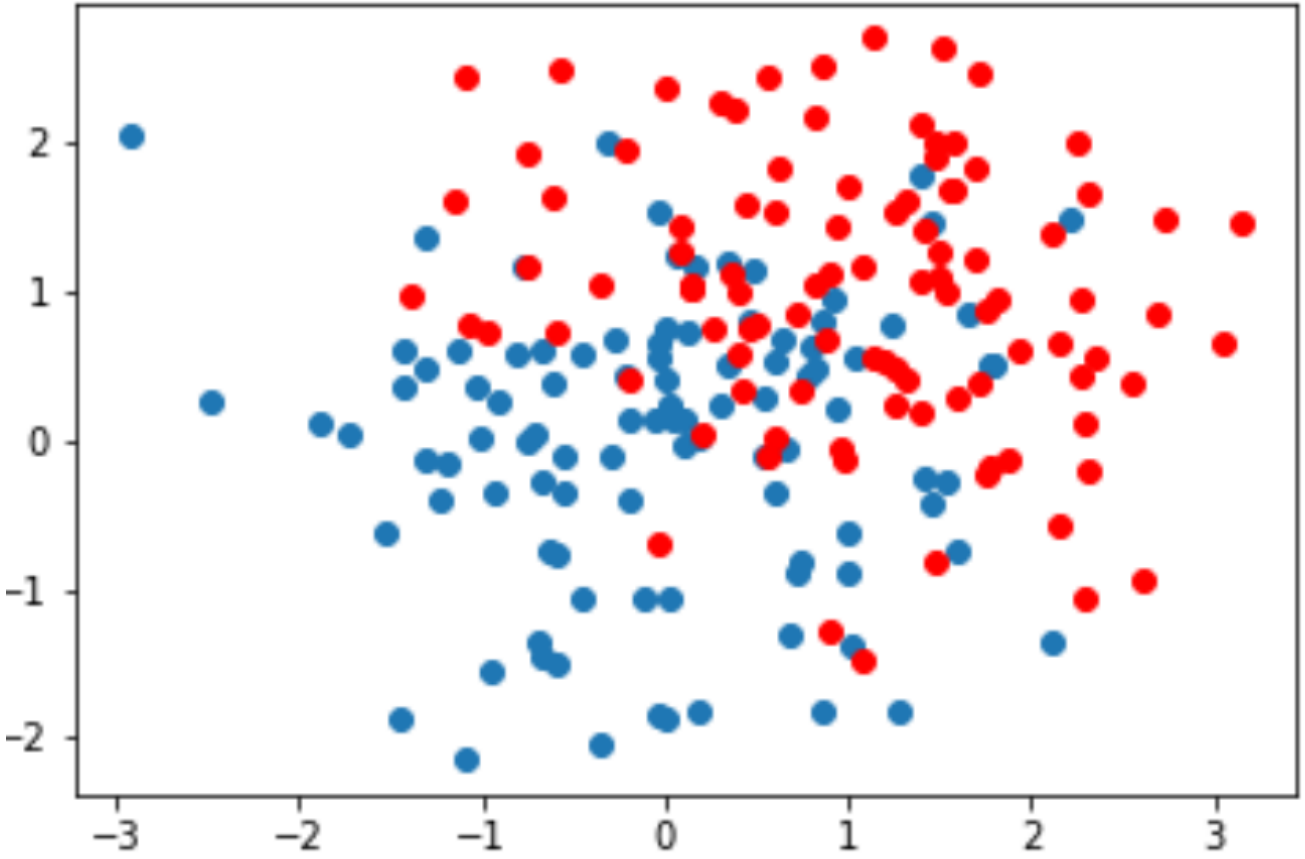

Histogramas:

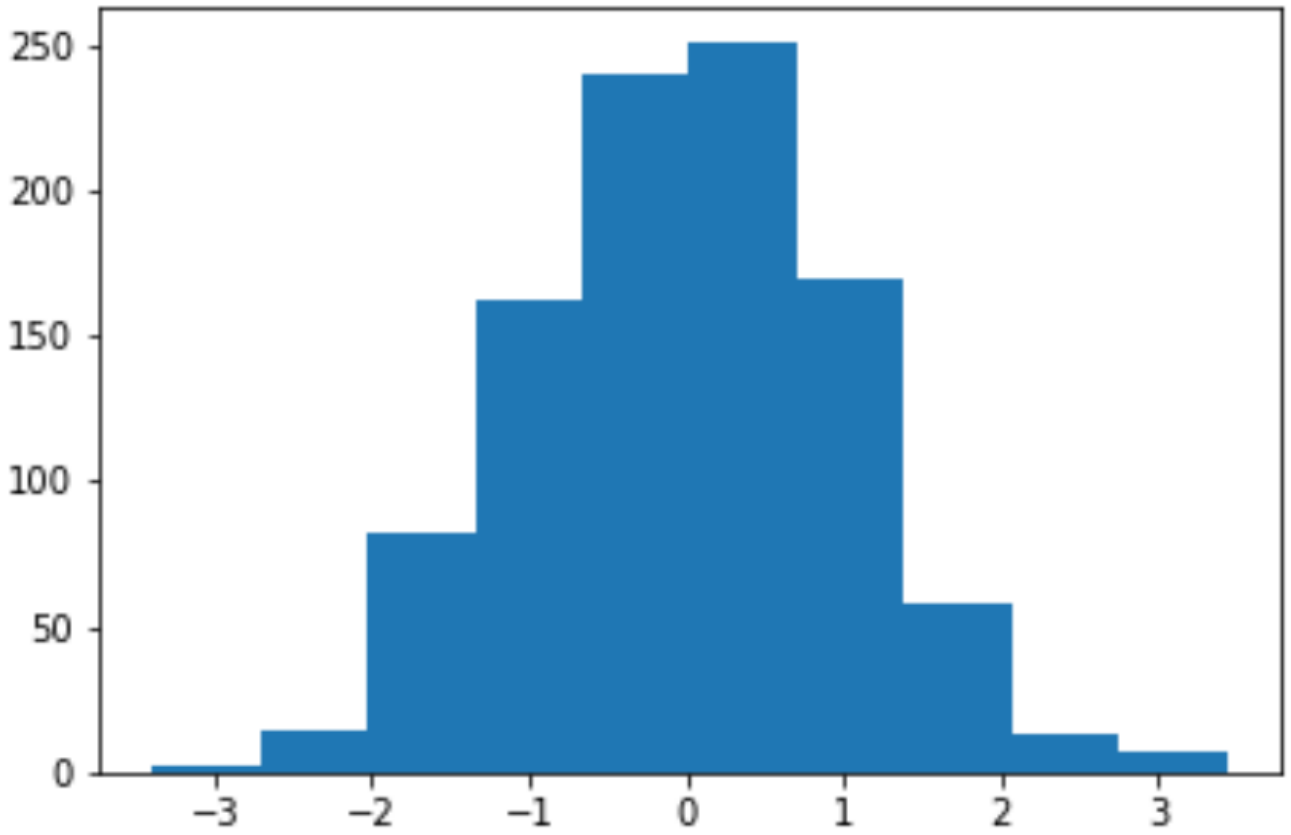

Gráficos de barras:

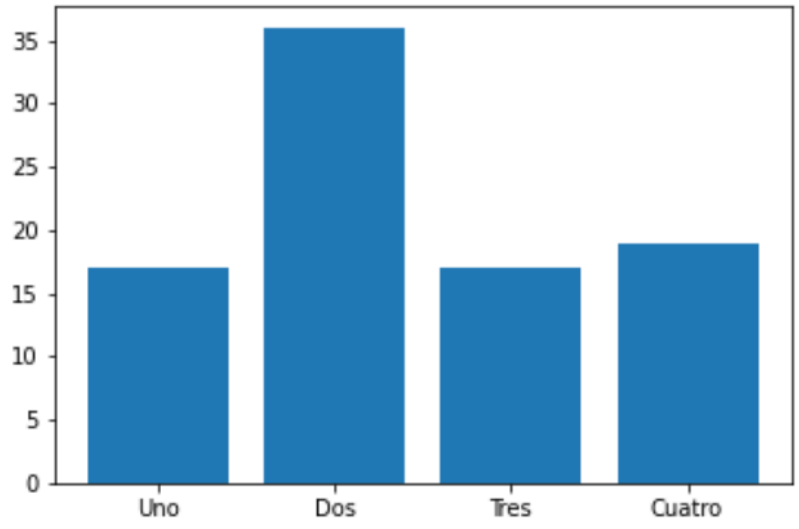

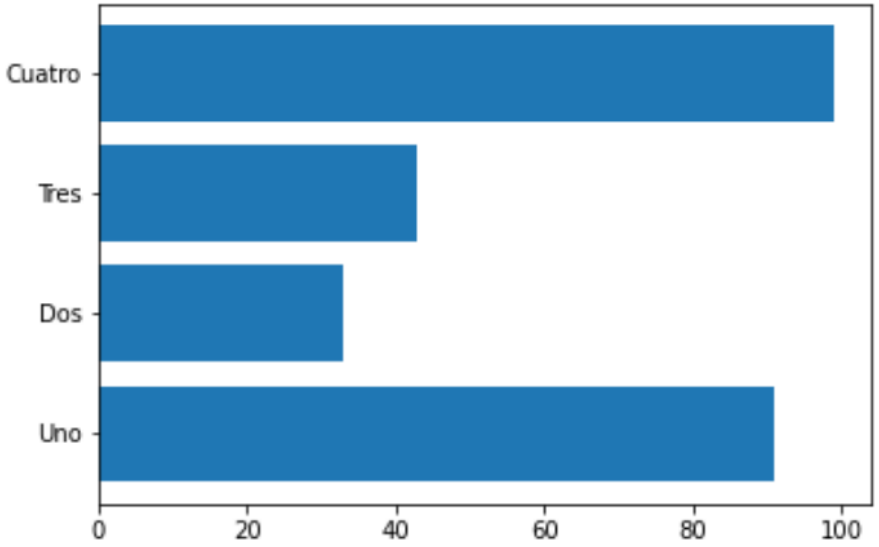

Gráficos de sectores (quesos):

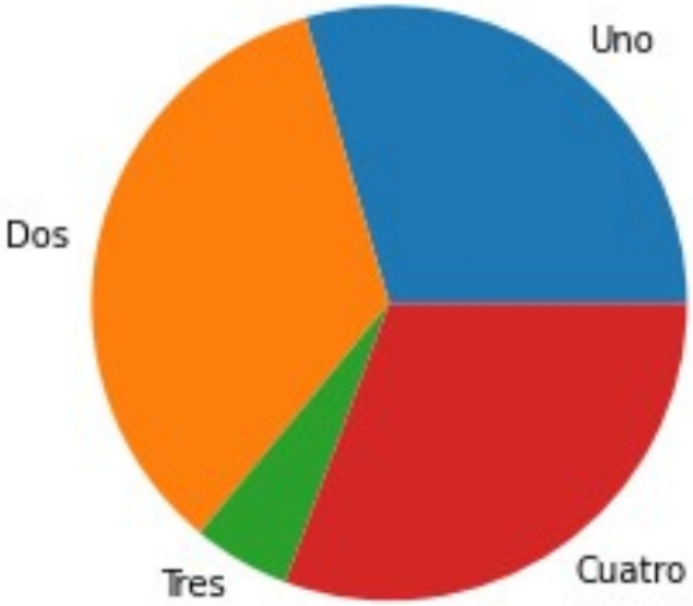

Gráficos de cajas y bigotes:

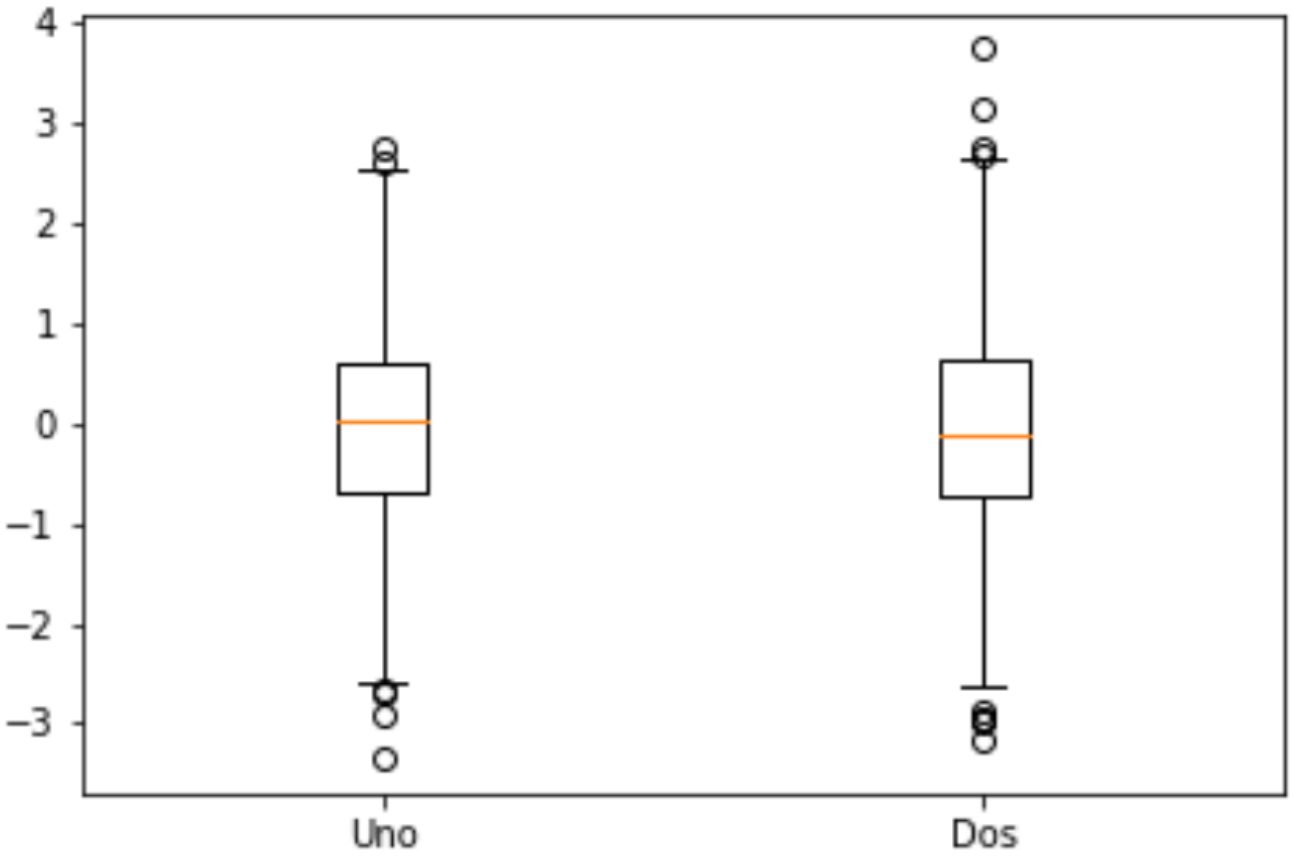

Gráficos de superficies y contornos:

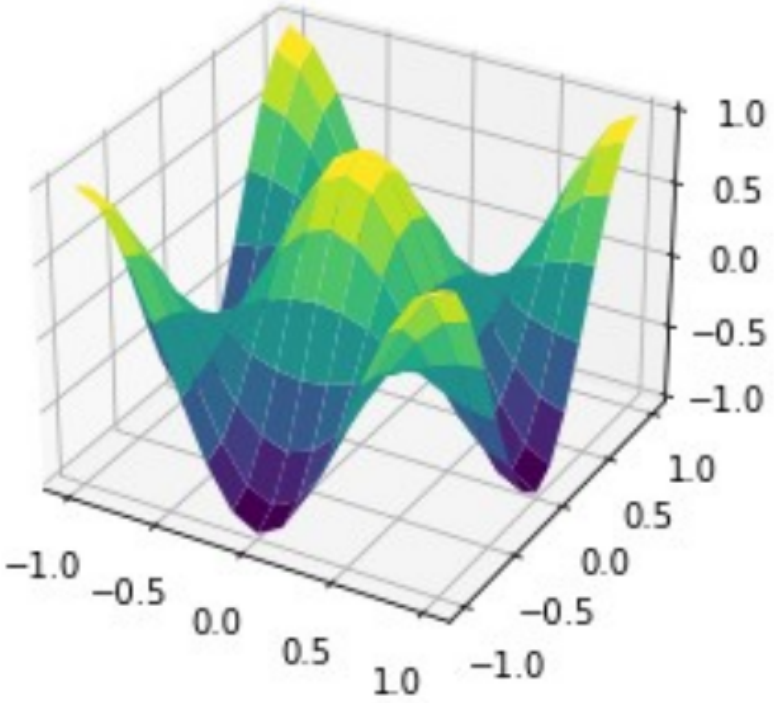

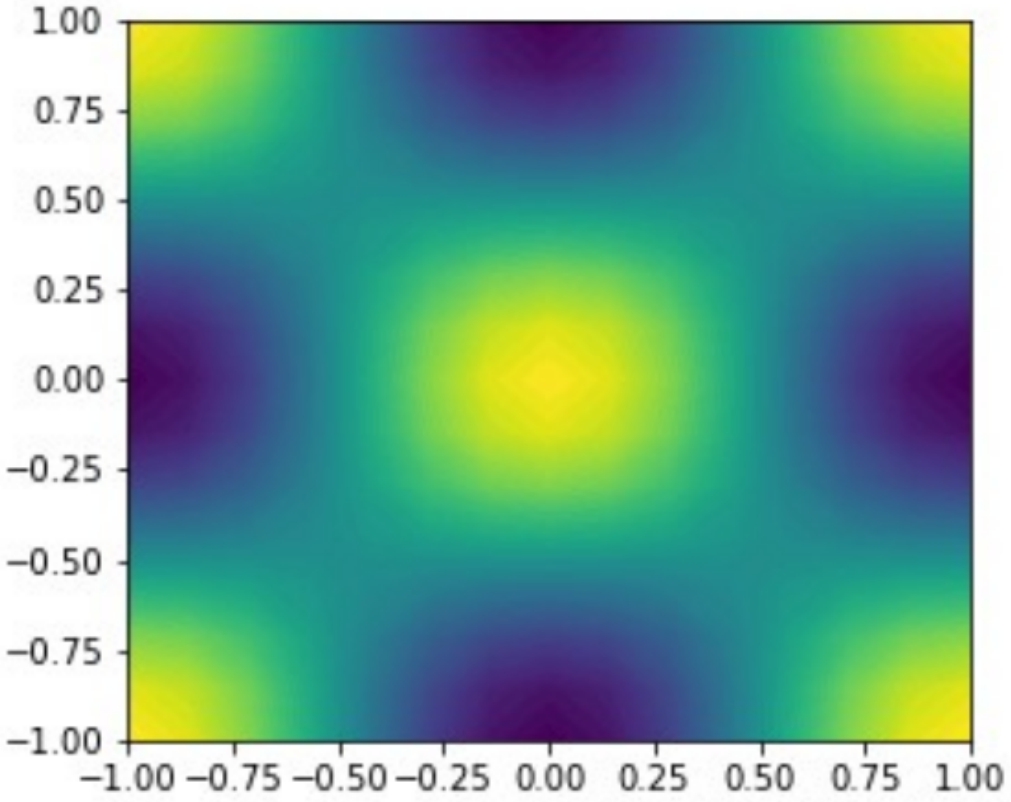

MatplotLib: Algunas funcionalidades

MatplotLib se encuentra muy bien integrada con otras bibliotecas como **NumPy**.

Por ejemplo, la biblioteca **Pandas** utiliza **MatplotLib** para realizar su propia visualización de datos.

Puedes comenzar a utilizar la biblioteca **MatplotLib** cargando en tu cuenta de GDrive el fichero **IntroMatplotLib.ipynb**.

Contenido

6 La biblioteca NumPy

7 Visualización de datos con MatplotLib

8 Lectura de datos con Pandas

9 Scikit-Learn

Pandas

Pandas permite, de forma cómoda, cargar volúmenes de datos desde diferentes formatos y procesarlos, para extraer información relevante que posteriormente se use en la construcción de sistemas de IA y de Machine Learning.

Es una biblioteca básica en el área de las Ciencias de Datos.

Al igual que NumPy, es muy extensa.

En la asignatura usaremos Pandas de forma muy básica. Puedes encontrar una introducción más detallada en:

https://pandas.pydata.org/docs/user_guide/10min.html

Pandas: Tipos de datos

Tipos fundamentales sobre los que se construye la biblioteca:

- **DataFrame**: Tabla de datos
- **Series**: Conjunto de datos (columna)

Multitud de formatos de datos soportados: CSV, xls, HDF, SPSS, Pickle...

Al igual que las bibliotecas anteriores, se suele importar con alias desde Python:

```
1     import pandas as pd
2
```

Pandas: Iniciación

En Pandas, los datos se cargan en tablas (**Dataframes**). Una vez leídos los datos en un dataframe df, algunos métodos útiles de Pandas son:

- **df.head(n)**: Muestra las n primeras filas del dataframe.
- **df.tail(n)**: Muestra las n últimas filas del dataframe df.
- **df.sample(n)**: Muestra n filas aleatorias del dataframe df.
- **df.shape**: Tupla conteniendo la forma (filas, columnas) del dataframe df.
- **df.info()**: Muestra un resumen de los tipos de datos de cada columna, y los valores perdidos/NaN que hay en el dataframe df.
- **df.describe(n)**: Muestra estadísticos básicos sobre las variables numéricas del dataframe df (media, desviación estándar, índices intercuartílicos. . .).

Pandas: Inspección de datos

Puedes comenzar a trabajar con Pandas incluyendo en tu GDrive el fichero IntroPandas.ipynb.

Contenido

6 La biblioteca NumPy

7 Visualización de datos con MatplotLib

8 Lectura de datos con Pandas

9 Scikit-Learn

SkLearn

Scikit-learn *(SkLearn)* es una de las librerías de aprendizaje automático más populares y completas.

Se recomienda revisar y estudiar su documentación que, aparte de ser abundante, es muy útil:

https://scikit-learn.org/stable/user_guide.html

SkLearn

La biblioteca **SkLearn** contiene multitud de datasets incluidos de modo que puedan utilizarse directamente para el estudio o la práctica de aprendizaje automático. Los más básicos se encuentran en el siguiente enlace:

https://scikit-learn.org/stable/datasets/toy_dataset.html

Un ejemplo de su uso:

```
from sklearn import datasets as ds

iris_data= ds.load_iris() # Carga del dataset de la flor de Iris

```

La biblioteca **SkLearn** está completamente integrada con **NumPy**.

SkLearn

La biblioteca **SkLearn** también contempla el uso de múltiples modelos para realizar aprendizaje:

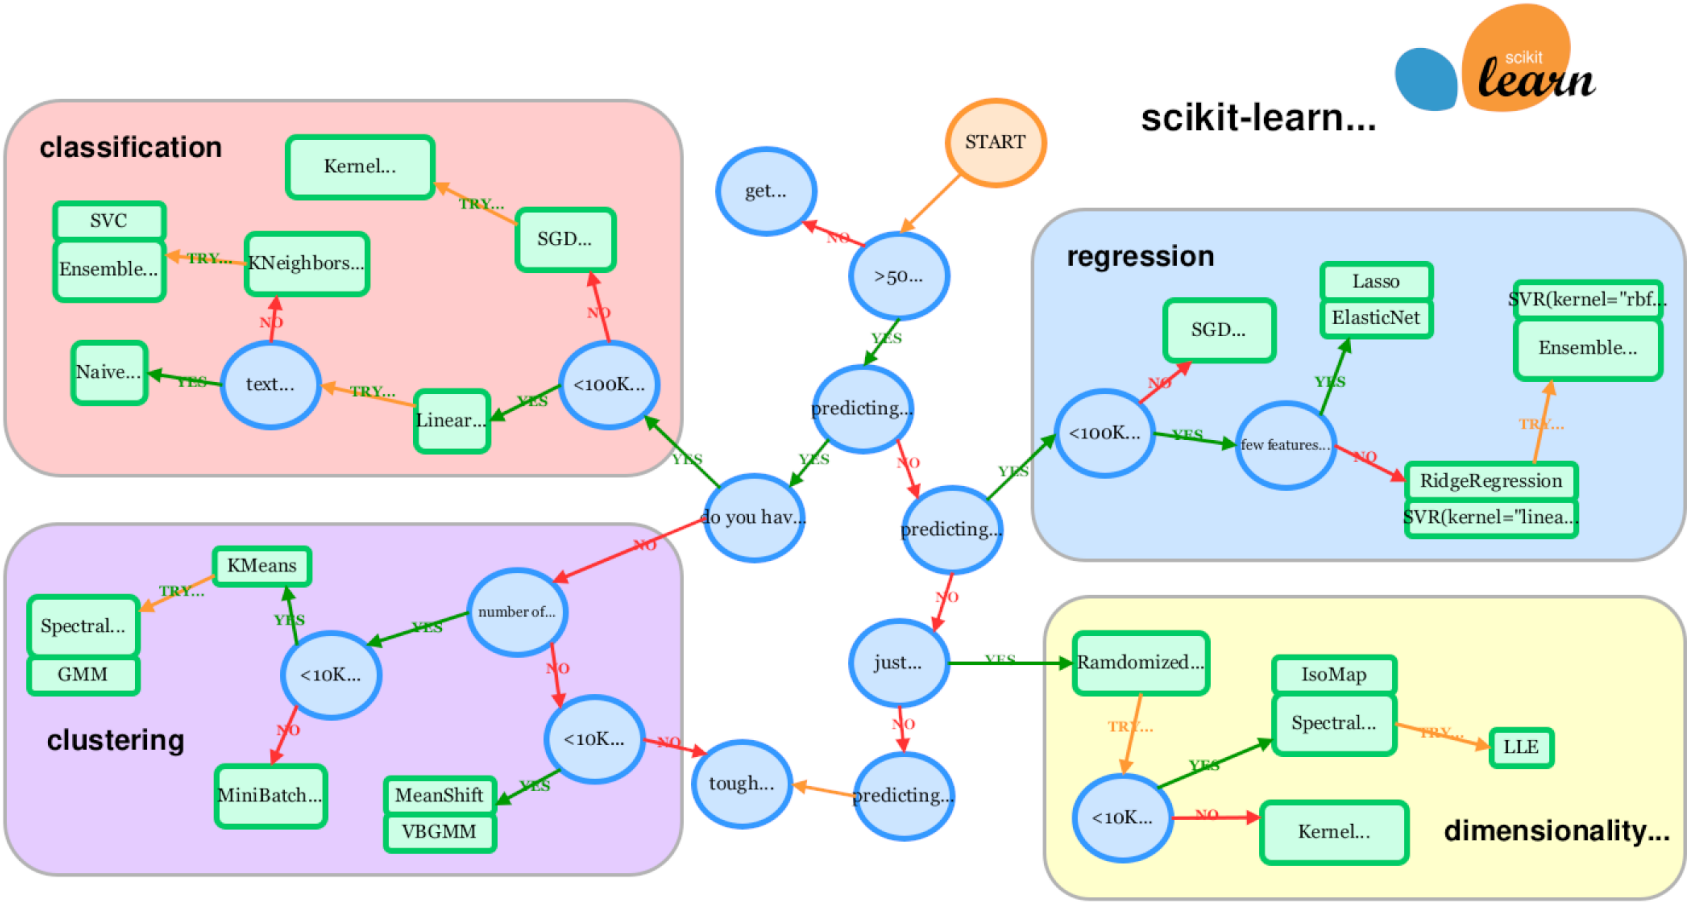

SkLearn

Favorece el prototipado rápido. En pocas líneas podemos leer un conjunto de datos, entrenar un modelo y usarlo para predecir:

```
from sklearn import datasets as ds
from sklearn import svm

digits= ds.load_digits()
clasificador= svm.SVC(gamma=0.001, C=100.)
clasificador.fit(digits.data[:-1], digits.target[:-1])

pred= clasificador.predict(digits.data[-1:])
real= digits.target[-1]
print('Real: {}, Prediccion: {}'.format(real, pred[0]))

# Muestra 'Real: 8, Prediccion: 8'

```

SkLearn

Otro ejemplo: Regresión de datos.

```
from sklearn.linear_model import LinearRegression
import numpy as np

X= np.linspace(start=0, stop= 10, num=11)
y= 2*X-7

regresor= LinearRegression()
regresor.fit(X, y)
pred= regresor.predict([[11.0]])
# pred vale aproximadamente 15

```

Las funciones **fit** y **predict** se utilizan para entrenar el modelo y para ejecutarlo, respectivamente. Son comunes a los modelos incluidos en **SkLearn**.

SkLearn: Algunas funcionalidades

Entre otras, ofrece las siguientes funcionalidades:

- **Particionamiento de datos** en entrenamiento y test.

```
1        # 60% para training y 40% para test
2        X_train, X_test, y_train, y_test =
    train_test_split(X, y, test_size=0.4)
3
```

- **Validación cruzada como protocolo de validación experimental**:
  - **sklearn.model_selection.Kfold**: División del conjunto de datos en K subconjuntos/folds/splits.
  - **sklearn.model_selection.StratifiedKFold**: Cada fold tiene el mismo porcentaje de muestras de cada tipo.
  - **sklearn.model_selection.ShuffleSplit**: Genera permutaciones aleatorias (no necesariamente disjuntas).

https://scikit-learn.org/stable/modules/cross_validation.html

Particionamiento vs. validación cruzada:

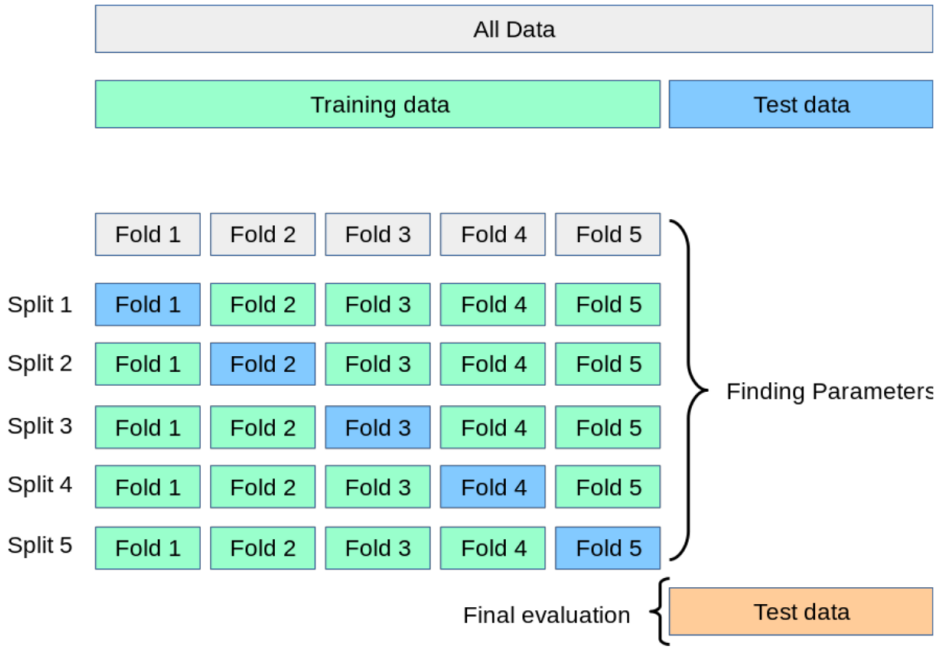

Se complementan. La validación cruzada se usa en el entrenamiento. La partición de test para validar el modelo entrenado.

SkLearn: Algunas funcionalidades

Más funcionalidades:

- **Evaluación de rendimiento** de modelos entrenados.

  https://scikit-learn.org/stable/modules/model_evaluation.html

  - **sklearn.model_selection.cross_val_score** o **cross_validate**
  - **sklearn.metrics.confusion_matrix**
  - **sklearn.metrics.classification_report**

Métricas de evaluación del rendimiento

$$F_1 = 2\frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

	precision	recall	f1-score	support
setosa	1.00	1.00	1.00	16
versicolor	0.88	0.96	0.92	23
virginica	0.95	0.86	0.90	21
accuracy			0.93	60
macro avg	0.94	0.94	0.94	60
weighted avg	0.94	0.93	0.93	60

Promedios de las métricas obtenidas en cada una de las clases. **macro avg** no tiene en cuenta el desbalanceo entre clases. **weighted avg** calcula ese promedio ponderando la presencia de cada clase. Ej. (16/60)*1 + (23/60)*0.92 + (21/60)*0.90 = 0.93

Los 16 ejemplos de test de flor de Iris de tipo setosa se han clasificado correctamente.

El 96% de los ejemplos cuya clase es versicolor se clasificaron correctamente. TP/P=22/23

El 93% de todos los ejemplos se clasificó correctamente. 56/60

El 88% de los ejemplos clasificados como versicolor se clasificaron correctamente. TP/PP=22/25

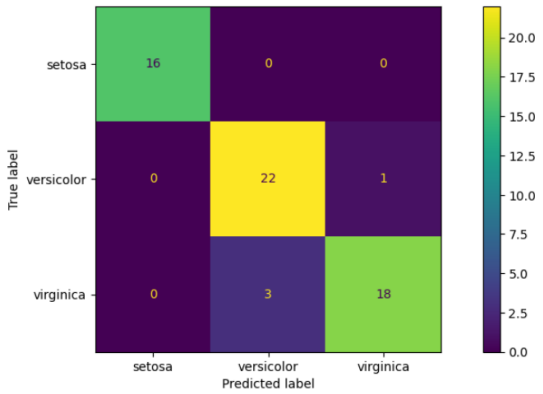

SkLearn: Algunas funcionalidades

Más funcionalidades:

- **Preprocesamiento de datos** (cambios de escala, codificación...).

  https://scikit-learn.org/stable/modules/preprocessing.html

- **Selección de características** (selección de atributos predictores).

  https://scikit-learn.org/stable/modules/feature_selection.html

- **Tratamiento de valores perdidos** (mecanismos para tratar datos desconocidos en un conjunto).

  https://scikit-learn.org/stable/modules/impute.html

- **Optimización de hiperparámetros de modelos** (automatización de búsqueda de mejores condiciones de ejecución o aprendizaje de un modelo).

  https://scikit-learn.org/stable/modules/grid_search.html

- **Encadenamiento/composición de operaciones** (Pipelines).

  https://scikit-learn.org/stable/modules/compose.html

SkLearn

Puedes comenzar a trabajar con **SkLearn** incluyendo en tu GDrive el fichero **IntroSkLearn.ipynb**.

Aprendizaje Automático

Introducción a las prácticas

Manuel Pegalajar Cuéllar[1]

[1]Departamento de Ciencias de la Computación e Inteligencia Artificial. Universidad de Granada