




Aprendizaje Automático

Curso 2024-2025

Tema 1. Conceptos básicos del aprendizaje automático



Bibliografía






➤ **Tema 1: Conceptos básicos del Aprendizaje Automático**

- Tema 2: Aprendizaje Supervisado. Regresión y Clasificación. Modelos. Evaluación
- Tema 3: Ingeniería de Características y Preprocesamiento de Datos. Calidad de Datos
- Tema 4: Aprendizaje no Supervisado
- Tema 5: Aprendizaje Profundo. Fundamentos
- Tema 6: Aprendizaje Profundo en diferentes tipos de datos y problemas
- Tema 7. Aprendizaje por refuerzo
- Tema 8: Optimización en Aprendizaje Automático. Hiperparámetros, selección de modelos y regularización
- Tema 9: Aspectos Avanzados, retos y desafíos del aprendizaje automático

Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es? ¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)

Algunos retos del aprendizaje automático en un entorno real

Calidad de datos. La era del big data

Data Centric vs Model Centric

Pinceladas finales. AI Act, IA fiable, ...

¿Qué es el aprendizaje automático?

- El aprendizaje automático es la ciencia (y el arte) de programar ordenadores para que puedan aprender de los datos.
- Una definición un poco más general:
- El aprendizaje automático es el campo de estudio que confiere a los ordenadores la capacidad de aprender sin ser programados explícitamente.

-Arthur Samuel, 1959

¿Qué es el aprendizaje automático?

- El aprendizaje automático es la ciencia (y el arte) de programar ordenadores para que puedan aprender de los datos.
- El aprendizaje automático es el campo de estudio que confiere a los ordenadores la capacidad de aprender sin ser programados explícitamente.

-Arthur Samuel, 1959

- **Y una más orientada a la ingeniería:**
- **Se dice que un programa informático aprende de la experiencia E con respecto a alguna tarea T y alguna medida de rendimiento P, si su rendimiento en T, medido por P, mejora con la experiencia E.**

-Tom Mitchell, 1997

¿Qué es el aprendizaje automático?

- Un filtro antispam es un programa de aprendizaje automático que, a partir de ejemplos de correos electrónicos spam (por ejemplo, marcados por los usuarios) y ejemplos de correos electrónicos normales (no spam), puede aprender a marcar el spam.

Los ejemplos que el sistema utiliza para aprender se denominan conjunto de entrenamiento.

- Cada ejemplo de entrenamiento se denomina instancia (o muestra) de entrenamiento. En este caso, la tarea T es marcar el spam de los nuevos correos electrónicos, la experiencia E son los datos de entrenamiento y hay que definir la medida de rendimiento P ; por ejemplo, se puede utilizar la proporción de correos electrónicos clasificados correctamente.
- Esta medida concreta del rendimiento se denomina precisión y se utiliza a menudo en tareas de clasificación.

¿Por qué utilizar el aprendizaje automático?

Ingeniería del conocimiento (creando reglas)




Figure 1-1. The traditional approach

¿Por qué utilizar el aprendizaje automático?

Aprender de datos/observaciones




Figure 1-2. The Machine Learning approach

¿Por qué utilizar el aprendizaje automático? Se puede adaptar a cambios




Figure 1-3. Automatically adapting to change

¿Por qué utilizar el aprendizaje automático?

- La aplicación de técnicas de AA para indagar en grandes cantidades de datos puede ayudar a descubrir patrones que no eran evidentes de inmediato.
- Es lo que se denomina **minería de datos**.




Figure 1-4. Machine Learning can help humans learn

¿Por qué utilizar el aprendizaje automático?

El aprendizaje automático es muy útil para:

- Problemas para los que las soluciones existentes requieren muchos ajustes o largas listas de reglas: un algoritmo de aprendizaje automático a menudo puede simplificar el código y ofrecer mejores resultados que el enfoque tradicional.
- Problemas complejos para los que el uso de un enfoque tradicional no ofrece una buena solución: las mejores técnicas de aprendizaje automático pueden quizás encontrar una solución.
- Entornos fluctuantes: un sistema de aprendizaje automático puede adaptarse a nuevos datos.
- Obtención de información sobre problemas complejos y grandes cantidades de datos.



Ejemplos de aplicaciones


- **Análisis de imágenes de productos en una línea de producción para clasificarlos automáticamente: CNNs**
- **Detección de tumores en escáneres cerebrales: segmentación semántica (CNNs)**
- **Clasificación automática de artículos de noticias: PLN (RNNs, CNNs o Transformadores)**
- **Marcar automáticamente los comentarios ofensivos en los foros de debate: PLN**
- **Resumir documentos largos automáticamente: PLN**
- **Crear un chatbot o un asistente personal: PLN**
- **Previsión de los ingresos de su empresa el año que viene, a partir de numerosas métricas de rendimiento: Regresión, Series temporales.**
- **Cómo hacer que tu aplicación reaccione a los comandos de voz: Reconocimiento de voz (Transformers)**

Ejemplos de aplicaciones



- **Detección de fraudes con tarjetas de crédito: Detección de anomalías**
- **Segmentar a los clientes en función de sus compras para poder diseñar una estrategia de marketing diferente para cada segmento: Agrupación**
- **Representar un conjunto de datos complejo y de alta dimensionalidad en un diagrama claro y perspicaz: Visualización de datos, reducción de la dimensionalidad**
- **Recomendar un producto que pueda interesar a un cliente, basándose en sus compras anteriores: Sistema de recomendación**
- **Construir un bot inteligente para un juego: Aprendizaje por refuerzo (AlphaGO)**

Aprendizaje automático: formalización



$$(\mathbf{x}_i, y_i), \quad (i = 1, \dots, m)$$


$f(\mathbf{x}, \omega)$, $\omega \in \Omega$,
(conjunto de parámetros para fijar
el modelo, conjunto de funciones)

L (función de pérdida/error) ,
 R (riesgo o pérdida promedio)

$$R(\omega) = \int L(y, f(\mathbf{x}, \omega)) p(\mathbf{x}, y) d\mathbf{x} dy$$

El aprendizaje es el proceso de estimación de la función $f(\mathbf{x}, \omega_0)$, que minimiza el riesgo funcional sobre el conjunto de funciones soportadas por la máquina de aprendizaje utilizando solo los datos de entrenamiento ($p(\mathbf{x}, y)$ no se conoce).

Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es?
¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)

Algunos retos del aprendizaje automático en un entorno real

Calidad de datos. La era del big data

Data Centric vs Model Centric

Pinceladas finales. AI Act, IA fiable, ...

Aprendizaje supervisado

- En el **aprendizaje supervisado**, el conjunto de entrenamiento con el que se alimenta al algoritmo incluye las soluciones deseadas, denominadas etiquetas.




Figure 1-5. A labeled training set for spam classification (an example of supervised learning)


Aprendizaje supervisado

- Una tarea típica de aprendizaje supervisado es la **clasificación**. El filtro de spam es un buen ejemplo de ello: se entrena con muchos correos electrónicos de ejemplo junto con su clase (spam o ham), y debe aprender a clasificar los nuevos correos.
- Otra tarea típica consiste en predecir un valor numérico objetivo (se denomina **regresión**), como el precio de un coche, a partir de un conjunto de características (kilometraje, antigüedad, marca, etc.) denominadas predictores. Este tipo de tarea se denomina regresión. Para entrenar el sistema, hay que darle muchos ejemplos de coches, incluidos tanto sus predictores como sus etiquetas (es decir, sus precios).

Nota: Regresión es un término estadístico introducido por Francis Galton cuando estudiaba el hecho de que los hijos de personas altas tienden a ser más bajos que sus padres. Como los hijos eran más bajos, lo llamó regresión a la media. Este nombre se aplicó después a los métodos que utilizaba para analizar las correlaciones entre variables.


Aprendizaje supervisado

Clasificación (2 clases)



$$L(y, f(\mathbf{x}, \omega)) = \begin{cases} 0, & \text{if } y = f(\mathbf{x}, \omega), \\ 1, & \text{if } y \neq f(\mathbf{x}, \omega). \end{cases}$$

$$R(\omega) = \int L(y, f(\mathbf{x}, \omega)) p(\mathbf{x}, y) d\mathbf{x} dy$$



Aprendizaje supervisado

- Ejemplo: Diseño de un Clasificador para *Iris*
 - Problema simple muy conocido: *clasificación de lirios*.
 - Tres clases de lirios: *setosa*, *versicolor* y *virginica*.
 - Cuatro atributos: *longitud y anchura de pétalo y sépalo*, respectivamente.
 - 150 ejemplos, 50 de cada clase.
 - Disponible en <http://www.ics.uci.edu/~mlearn/MLRepository.html>





setosa



versicolor




virginica



Aprendizaje supervisado

Wisconsin Breast Cancer: Predict malignant/benign

WISCONSIN
BREAST
CANCER
COALITION




Attribute name	Description
RADIUS	<i>Mean of distances from center to points on the perimeter</i>
TEXTURE	<i>Standard deviation of grayscale values</i>
PERIMETER	<i>Perimeter of the mass</i>
AREA	<i>Area of the mass</i>
SMOOTHNESS	<i>Local variation in radius lengths</i>
COMPACTNESS	<i>Computed as: $\text{perimeter}^2 / \text{area} - 1.0$</i>
CONCAVITY	<i>Severity of concave portions of the contour</i>
CONCAVE POINTS	<i>Number of concave portions of the contour</i>
SYMMETRY	<i>A measure of the nuclei's symmetry</i>
FRACTAL DIMENSION	<i>'Coastline approximation' - 1.0</i>
DIAGNOSIS (Target)	<i>Diagnosis of cell sample: malignant or benign</i>

Aprendizaje supervisado

MNIST data

Handwriting recognition.
Assign a digit from 0 to 9.



Aprendizaje supervisado

Kaggle: The Home of Data Science

otto group

\$10,000 • 1,987 teams

Otto Group Product Classification Challenge


Tue 17 Mar 2015

Enter/Merge by

Mon 18 May 2015 (39 days to go)

A KAGGLE competition with a Multiclass and imbalanced problem

For this competition, we have provided a dataset with 93 features for more than 200,000 products. The objective is to build a predictive model which is able to distinguish between our main product categories. The winning models will be open sourced.



Aprendizaje supervisado

- Una tarea típica de aprendizaje supervisado es la **clasificación**. El filtro de spam es un buen ejemplo de ello: se entrena con muchos correos electrónicos de ejemplo junto con su clase (spam o ham), y debe aprender a clasificar los nuevos correos.
- Otra tarea típica consiste en predecir un valor numérico objetivo (se denomina **regresión**), como el precio de un coche, a partir de un conjunto de características (kilometraje, antigüedad, marca, etc.) denominadas predictores. Este tipo de tarea se denomina regresión.

Nota: Regresión es un término estadístico introducido por Francis Galton cuando estudiaba el hecho de que los hijos de personas altas tienden a ser más bajos que sus padres. Como los hijos eran más bajos, lo llamó regresión a la media. Este nombre se aplicó después a los métodos que utilizaba para analizar las correlaciones entre variables.

Aprendizaje supervisado





Figure 1-6. A regression problem: predict a value, given an input feature (there are usually multiple input features, and sometimes multiple output values)

Aprendizaje supervisado

- Estos son algunos de los algoritmos de aprendizaje supervisado más importantes:
- k-Nearest Neighbors
- regresión lineal, regresión logística,
- máquinas de vectores soporte (SVM),
- Algoritmos basados en reglas
- árboles de decisión y bosques aleatorios,
- redes neuronales.


Aprendizaje supervisado

Regresión



$$L(y, f(\mathbf{x}, \omega)) = (y - f(\mathbf{x}, \omega))^2.$$

$$R(\omega) = \int (y - f(\mathbf{x}, \omega))^2 p(\mathbf{x}, y) d\mathbf{x} dy$$



Aprendizaje semi-supervisado

- Dado que etiquetar los datos suele llevar mucho tiempo y ser costoso, a menudo tendremos muchos casos sin etiquetar y pocos casos etiquetados. Algunos algoritmos pueden trabajar con datos parcialmente etiquetados. Es lo que se denomina **aprendizaje semisupervisado**.




Figure 1-11. Semisupervised learning with two classes (triangles and squares): the unlabeled examples (circles) help classify a new instance (the cross) into the triangle class rather than the square class, even though it is closer to the labeled squares

Aprendizaje no supervisado

- En el aprendizaje no supervisado, los datos de entrenamiento no están etiquetados. El sistema intenta aprender sin un profesor.




Figure 1-7. An unlabeled training set for unsupervised learning


Aprendizaje no supervisado

■ Agrupamiento

- K-Means
- DBSCAN
- Hierarchical Cluster Analysis (HCA)

■ Detección de anomalías y novedades

- SVM de una clase (One-Class SVM)
- Isolation Forest



■ Visualización y reducción de la dimensionalidad

- Análisis de componentes principales (PCA)
- Kernel PCA
- Incrustación lineal local (Local Linear Embedding, LLE)
- Incrustación estocástica de vecinos distribuida (t-SNE)

■ Aprendizaje de reglas de asociación

- Apriori
- Eclat



Aprendizaje no supervisado

- Supongamos que tienes muchos datos sobre los visitantes de tu blog. Es posible que desees ejecutar un algoritmo de agrupación para tratar de detectar grupos de visitantes similares.
- En ningún momento le dices al algoritmo a qué grupo pertenece un visitante: él encuentra esas conexiones sin tu ayuda. Por ejemplo, puede darse cuenta de que el 40% de sus visitantes son hombres aficionados a los cómics que suelen leer su blog por la noche, mientras que el 20% son jóvenes aficionados a la ciencia ficción que lo visitan durante los fines de semana. Si utiliza un algoritmo de agrupación jerárquica, también puede subdividir cada grupo en otros más pequeños.





Figure 1-8. Clustering

Aprendizaje no supervisado: Clustering


Clustering.
Agrupamiento

$$\mathbf{x} \xrightarrow{\mathbf{f}(\mathbf{x}, \omega)} \mathbf{c}(\mathbf{x})$$

Minimizar
distancia
intra-cluster




Maximizar
distancia
inter-cluster






$$L(\mathbf{f}(\mathbf{x}, \omega)) = (\mathbf{x} - \mathbf{f}(\mathbf{x}, \omega)) \cdot (\mathbf{x} - \mathbf{f}(\mathbf{x}, \omega)),$$

$$R(\omega) = \int (\mathbf{x} - \mathbf{f}(\mathbf{x}, \omega)) \cdot (\mathbf{x} - \mathbf{f}(\mathbf{x}, \omega)) p(\mathbf{x}) d\mathbf{x}$$



Aprendizaje no supervisado: Clustering

Clustering. Agrupamiento




La decisión del número de clusters
es uno de los retos en agrupamiento


Aprendizaje no supervisado: Clustering

Clustering. Agrupamiento

Modelos
Jerárquicos



Modelos
Particionales



Aprendizaje no supervisado: Clustering

Clustering. Agrupamiento. Ejemplos

- **Marketing:** descubrimiento de distintos grupos de clientes en la BD. Usar este conocimiento en la política publicitaria, ofertas, ...
- **Uso de la tierra:** Identificación de áreas de uso similar a partir de BD con observaciones de la tierra (cultivos, ...)
- **Seguros:** Identificar grupos de asegurados con características parecidas (siniestros, posesiones,). Ofertarles productos que otros clientes de ese grupo ya poseen y ellos no
- **Planificación urbana:** Identificar grupos de viviendas de acuerdo a su tipo, valor o situación geográfica
- **WWW:** Clasificación de documentos, analizar ficheros .log para descubrir patrones de acceso similares, ...

Aprendizaje no supervisado: Detección Anomalías

- Otra tarea no supervisada importante es la detección de **anomalías**: por ejemplo, detectar transacciones inusuales con tarjetas de crédito para evitar fraudes, detectar defectos de fabricación o eliminar automáticamente los valores atípicos de un conjunto de datos antes de pasarlo a otro algoritmo de aprendizaje. Durante el entrenamiento, al sistema se le muestran la mayoría de los casos normales, para que aprenda a reconocerlos; entonces, cuando ve un nuevo caso, puede decir si se parece a uno normal o si es probable que sea una anomalía.




Figure 1-10. Anomaly detection

Aprendizaje no supervisado: Asociación

- Otra tarea no supervisada habitual es el **aprendizaje de reglas de asociación**, en el que el objetivo es indagar en grandes cantidades de datos y descubrir relaciones interesantes entre atributos.
- Por ejemplo, supongamos que eres propietario de un supermercado.
- La aplicación de una regla de asociación a sus registros de ventas puede revelar que las personas que compran salsa barbacoa y patatas fritas también suelen comprar filetes. Por lo tanto, es posible que desee colocar estos artículos cerca unos de otros.

Leyenda urbana en aprendizaje de reglas de asociación: pañales y cervezas en el fin de semana



Aprendizaje supervisado/no supervisado:

Modelo formal




FIGURE 2.8 Mapping application requirements onto a formal learning problem formulation.

Aprendizaje basado en instancias frente a aprendizaje basado en modelos

- **Aprendizaje basado en instancias:** Posiblemente la forma más simple de aprender sea simplemente aprender de memoria.
- El sistema aprende los ejemplos de memoria y, a continuación, generaliza a nuevos casos utilizando una medida de similitud para compararlos con los ejemplos aprendidos (o con un subconjunto de ellos).





Figure 1-15. Instance-based learning

Aprendizaje basado en instancias frente a aprendizaje basado en modelos

► Aprendizaje basado en instancias



$f(\mathbf{x})$ = etiqueta del ejemplo de entrenamiento más cercano a $\mathbf{x}$

- Todo lo que necesitamos es una función de distancia para nuestras entradas.
- ¡No se requiere entrenamiento!

Aprendizaje basado en instancias frente a aprendizaje basado en modelos

Una forma de generalizar a partir de un conjunto de ejemplos es construir un modelo de esos ejemplos y utilizarlo para hacer predicciones. Es lo que se denomina **aprendizaje basado en modelos**.






Figure 1-16. Model-based learning

Aprendizaje basado en modelos



Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es?
¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)


Algunos retos del aprendizaje automático
en un entorno real

Calidad de datos. La era del big data

Data Centric vs Model Centric

Pinceladas finales. AI Act, IA fiable, ...

Entorno general de Aprendizaje Automático



Entrenamiento y testeo


- **Divide tus datos en dos conjuntos: el conjunto de entrenamiento y el conjunto de prueba o test.**
- Como implican estos nombres, el modelo se entrena con el conjunto de entrenamiento y se prueba con el conjunto de test. La tasa de error en casos nuevos se denomina error de generalización (o error fuera de la muestra) y, al evaluar el modelo en el conjunto de pruebas, se obtiene una estimación de este error. Este valor le indica el rendimiento de su modelo en instancias que nunca ha visto antes.
- Es habitual utilizar el 80% de los datos para el entrenamiento y reservar el 20% para las pruebas. Sin embargo, esto depende del tamaño del conjunto de datos: si contiene 10 millones de instancias, retener el 1% significa que el conjunto de prueba contendrá 100.000 instancias, probablemente más que suficiente para obtener una buena estimación del error de generalización.

Entorno general de Aprendizaje Automático


Training Images



Training



Testing/generalization



Test Image



Entorno general de Aprendizaje Automático

Generalización



Conjunto entrenamiento (etiquetas conocidas)




¿Qué tan bien se generaliza un modelo aprendido a partir de los datos con los que fue entrenado a un nuevo conjunto de pruebas/test?

Entorno general de Aprendizaje Automático

- Partition

- Train




**k-fold cross
validation (k-fcv)**

• Partition

• Train

• Test

k-fold cross
validation (k-fcv)




Entorno general de Aprendizaje Automático

Criterios para evaluar

- **Precisión o exactitud** (s, ϵ)
 - En ocasiones se debe considerar el costo de la clasificación incorrecta
- **Velocidad**
 - Tiempo necesario para la construcción del modelo
 - Tiempo necesario para usar el modelo
- **Robustez**: capacidad para tratar con valores desconocidos
- **Escalabilidad**: Aumento del tiempo necesario (en construcción y evaluación) con el tamaño de la BD
- **Interpretabilidad**: comprensibilidad del modelo obtenido
- **Complejidad del modelo**: Tamaño del árbol de clasificación, número de reglas, antecedentes en las reglas,...

Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es?
¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)

Algunos retos del aprendizaje automático
en un entorno real


Calidad de datos. La era del big data

Data Centric vs Model Centric



Pinceladas finales. AI Act, IA fiable, ...

Aprendizaje por refuerzo


- El aprendizaje por refuerzo es una “aproximación” muy diferente.
- El sistema de aprendizaje, denominado agente en este contexto, puede observar el entorno, seleccionar y realizar acciones y obtener recompensas a cambio (o penalizaciones en forma de recompensas negativas).
- A continuación, debe aprender por sí mismo cuál es la mejor estrategia, denominada política, para obtener la mayor recompensa a lo largo del tiempo. Una política define qué acción debe elegir el agente cuando se encuentra en una situación determinada.



Aprendizaje por refuerzo





Aprendizaje por refuerzo




Juegos Arcade
(Breakout)

El algoritmo se enfrentó a 49 juegos
Arcade de los años 80 superando a
otros algoritmos y a un jugador
humano profesional



Video

Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es?
¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)

Algunos retos del aprendizaje automático en un entorno real




Calidad de datos. La era del big data

Data Centric vs Model Centric

Pinceladas finales. AI Act, IA fiable, ...

Aprendizaje profundo (deep learning)

Deep neural network



Aprendizaje profundo (deep learning)

Video



www.cybercontrols.org ed MLP

Aprendizaje profundo. Identificación de objetos en video



Security Forum Awards

Security Forum 2017

In the Security Forum Award I+D+I category the winner is University of Granada: Real-time video firearms detection system



Video



Video

MIT
Technology
Review

Connectivity

The Best of the Physics arXiv (week ending March 4, 2017)


This week's most thought-provoking papers from the Physics arXiv.

by Emerging Technology from the arXiv March 4, 2017

Videos

Automatic Handgun Detection Alarm in Videos Using Deep Learning
R Olmos, S Tabik, F Herrera, Neurocomputing 275, 66-72, 2018

Aprendizaje profundo (deep learning)




Aprendizaje profundo.

Clasificación con datos temporales

Una IA predice con éxito si moriremos pronto, aunque nadie sabe cómo lo hace

MADRID Actualizado: 15/11/2019 02:13h

- La Inteligencia Artificial logró predecir la muerte de personas, en el plazo de un año, con solo ver sus electrocardiogramas



400.000 pacientes
1.7 millones de registros
electrocardiograma

Actividad eléctrica del corazón, el patrón cambia debido a afecciones cardíacas

Centro Médico de Geisinger, Pennsylvania

Un sistema inteligente predice las posibilidades de que una persona muera en el plazo de un año.


El sistema fue incluso capaz de anunciar la muerte de pacientes con valores que los médicos habían considerado normales.

¿Cómo se predice? No existe explicabilidad sobre la actuación de la IA en este problema

https://www.abc.es/ciencia/abci-predice-exito-si-moiremos-pronto-aunque-nadie-sabe-como-hace-201911141623_noticia.html

<https://www.nature.com/articles/s41591-020-0870-z> Prediction of mortality from 12-lead electrocardiogram voltage data using a deep neural network (Nature Medicine, 2020)

Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es?
¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)

Algunos retos del aprendizaje automático en un entorno real

Calidad de datos. La era del big data

Data Centric vs Model Centric

Pinceladas finales. AI Act, IA fiable, ...

Algunos retos del aprendizaje automático en un entorno real

Teorema “No free lunch”

- David Wolpert demostró que si no se hace absolutamente ninguna suposición sobre los datos, no hay ninguna razón para preferir un modelo a otro.
- Es lo que se denomina el teorema del "**No Free Lunch**" (NFL). Para algunos conjuntos de datos, el mejor modelo es un modelo lineal, mientras que para otros es una red neuronal.
- No hay ningún modelo que a priori garantice que funcione mejor (de ahí el nombre del teorema). La única forma de saber con seguridad qué modelo es el mejor es evaluarlos todos. Como esto no es posible, en la práctica se hacen algunas suposiciones razonables sobre los datos y se evalúan sólo unos pocos modelos razonables.

Algunos retos del aprendizaje automático en un entorno real

Selección de modelos

- **Selección de modelos:** Al elegir entre diferentes tipos de modelos (por ejemplo, lineal frente a polinómico), es habitual entrenar cada modelo y comparar su rendimiento en un conjunto de pruebas.
- Sin embargo, este enfoque puede llevar a un sobreajuste, especialmente si el modelo y los hiperparámetros están excesivamente ajustados para funcionar bien en ese conjunto de pruebas específico.

Algunos retos del aprendizaje automático en un entorno real

Sobreajuste de los datos de entrenamiento

- En aprendizaje automático, esto se denomina sobreajuste: significa que el modelo funciona bien con los datos de entrenamiento, pero no generaliza bien.
- La restricción de un modelo para simplificarlo y reducir el riesgo de sobreajuste se denomina **regularización** (anteriormente mencionada).

Algunos retos del aprendizaje automático en un entorno real

Ajuste de hiperparámetros

- **Regularización y ajuste de hiperparámetros:** Para evitar el sobreajuste, se aplican técnicas de regularización. El proceso consiste en entrenar múltiples modelos con diferentes valores de hiperparámetro para encontrar el que minimice el error de generalización.
- Sin embargo, si el ajuste de los hiperparámetros se basa únicamente en el rendimiento del conjunto de test, puede dar lugar a un modelo que funcione bien con los datos de test, pero mal con los datos nuevos que no se han visto.

Algunos retos del aprendizaje automático en un entorno real

Desajuste de datos

- **Representatividad de los datos de validación y prueba:** Cuando se entrenan modelos, especialmente con datos que son fáciles de adquirir pero que no son perfectamente representativos de los datos de producción (como imágenes descargadas de la web frente a imágenes tomadas con una aplicación móvil), es crucial asegurarse de que los conjuntos de validación y test representan fielmente los datos reales que se esperan en producción.

Esto ayuda a evaluar con precisión el rendimiento del modelo y su capacidad de generalización.

Algunos retos del aprendizaje automático en un entorno real


Datos de entrenamiento no representativos

- Para generalizar bien, es crucial que los datos de entrenamiento sean representativos de los nuevos casos a los que se quiere generalizar.
- Esto se denomina **sesgo de muestreo**.

Algunos retos del aprendizaje automático en un entorno real

Cantidad insuficiente de datos de entrenamiento


- Incluso para problemas muy sencillos se suelen necesitar miles de ejemplos, y para problemas complejos, como el reconocimiento de imágenes o del habla, es posible que se necesiten millones de ejemplos (a menos que se puedan reutilizar partes de un modelo existente).



“Scaling to very very corpora for Natural Language Disambiguation,” Proceedings of the 39th Annual Meeting of the Association for Computational Linguistics (2001): 26–33.

En un famoso artículo publicado en 2001, los investigadores de Microsoft Michele Banko y Eric Brill demostraron que algoritmos de aprendizaje automático muy diferentes, incluidos algunos bastante sencillos, funcionaban casi idénticamente bien en un complejo problema de desambiguación del lenguaje natural una vez que se les proporcionaban suficientes datos.

Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es?
¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)

Algunos retos del aprendizaje automático
en un entorno real

Calidad de datos. La era del big data

Data Centric vs Model Centric

Pinceladas finales. AI Act, IA fiable, ...

Calidad de datos. La era del big data





figure
eight

© Data Scientist report 2018. COMMONLY
USED DATA TYPES

El Big Bang del Big Data

Volumen estimado de datos digitales creados o replicados en todo el mundo, en zetabytes



Un zetabyte equivale a mil millones de gigabytes.


* Previsión de marzo de 2021.

Fuentes: IDC, Seagate, Statista



statista

Calidad de datos. La era del big data



**La nueva
economía, el
dato como el
capital**

Calidad de datos.

La era del big data. El poder de los datos




Unos días después el director llamó al padre para disculparse.

Respuesta conciliadora del padre:



“He estado hablando con mi hija –dijo el padre– Resulta que en mi casa han tenido lugar ciertas actividades de las que yo no estaba del todo informado. Mi hija sale de cuentas en agosto. Soy yo el que les debe una disculpa”.

Calidad de datos




Calidad de datos

- Siempre es recomendable dedicar tiempo a limpiar los datos de entrenamiento. La mayoría de los científicos de datos pasan una parte significativa de su tiempo haciendo precisamente eso.
- Si los datos de entrenamiento están llenos de errores, valores atípicos y ruido (por ejemplo, debido a mediciones de mala calidad), el sistema tendrá más dificultades para detectar los patrones subyacentes, por lo que es menos probable que funcione.



Características irrelevantes, ruido, valores perdidos ...

Calidad de datos



Tema 3: Ingeniería de Características y Preprocesamiento de Datos. Calidad de Datos





Fig. 1.3 Forms of data preparation

Fig. 1.4 Forms of data reduction

Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es?
¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)


Algunos retos del aprendizaje automático
en un entorno real

Calidad de datos. La era del big data

Data Centric vs Model Centric


Pinceladas finales. AI Act, IA fiable, ...

Data Centric AI versus Model Centric AI




Data Centric AI versus Model Centric AI

Data-Centric AI



Conceptos Aprendizaje automático



Aprendizaje automático (AA) ¿Qué es? ¿Por qué utilizarlo? Formalización

AA supervisado versus no supervisado

Entorno general de AA

Aprendizaje por refuerzo

Aprendizaje profundo (deep learning)

Algunos retos del aprendizaje automático en un entorno real


Calidad de datos. La era del big data

Data Centric vs Model Centric

Pinceladas finales. AI Act, IA fiable, Ciclo de vida, seguridad, gobernanza, conclusiones


Pinceladas finales

AI Act. Marco regulatorio Europeo



Pinceladas finales

IA (con)fiable



Pinceladas finales


Etapas del proceso de aprendizaje

- Un reto fundamental es la adecuada toma de decisiones en los diferentes elementos y etapas del proceso de aprendizaje automático (**datos, modelo, evaluación**)



Pinceladas finales


Ciclo de vida de la IA





Pinceladas finales

AI safety. Seguridad, robustez, adversarios

Este jersey funciona como capa de invisibilidad frente la Inteligencia Artificial




un jersey que utiliza "patrones adversos" que eliminan los patrones comunes a los que están entrenados estos sistemas y lo convierte en invisible ante la IA.



Pinceladas finales

AI safety. Seguridad, robustez, adversarios

Video




<https://www.cs.umd.edu/~tomg/projects/invisible/>

Zuxuan Wu, Ser-Nam Lim, Larry Davis, Tom Goldstein. Making an Invisibility Cloak: Real World Adversarial Attacks on Object Detectors, [arXiv:1910.14667v2](https://arxiv.org/abs/1910.14667v2), 2020.

Pinceladas finales

Gobernanza de la IA



**Naciones
unidas**

Pinceladas finales

Comentarios finales

- Estamos en la era del big data, en la era de la economía basada en datos, donde el dato es el petróleo del S XXI.
- El aprendizaje automático es un área esencial en la inteligencia artificial para el aprendizaje de modelos para la toma de decisiones.

