






Aprendizaje Automático

Curso 2025-2026

Tema 9. Aspectos Avanzados, retos y desafíos del aprendizaje automático. Parte I



ÉTICA DE LA INTELIGENCIA ARTIFICIAL
Mark Coeckelbergh



CÁTEDRA



- 
- Tema 1: Conceptos básicos del Aprendizaje Automático
 - Tema 2: Aprendizaje Supervisado. Regresión y Clasificación. Modelos. Evaluación
 - Tema 3: Ingeniería de Características y Preprocesamiento de Datos. Calidad de Datos
 - Tema 4: Aprendizaje no Supervisado
 - Tema 5: Aprendizaje Profundo. Fundamentos
 - Tema 6: Aprendizaje Profundo en diferentes tipos de datos y problemas
 - Tema 7. Aprendizaje por refuerzo
 - Tema 8: Optimización en Aprendizaje Automático. Hiperparámetros, selección de modelos y regularización
 - **Tema 9: Aspectos Avanzados, retos y desafíos del aprendizaje automático**



Aspectos Avanzados. Parte I

- Introducción a la Inteligencia Artificial Explicable.
- Fundamentos de AI Safety y OOD Detection. ¿Qué ocurre cuando creemos que lo sabemos todo?
- La causalidad en la IA. ¿Pueden las vacas ir a la playa?
- ¿Podemos eliminar lo aprendido? Aprendizaje continuo y unlearning.

Introducción a la Explainable AI (XAI)

Iván Sevillano-García
DASCI — Universidad de Granada



DASCI


Instituto Andaluz
Interuniversitario en
Ciencia de Datos e
Inteligencia Computacional

"Haciendo inteligible la caja negra"

La caja negra: ¿lobos o perros?


Ejemplo clásico de LIME

Imagen original (husky en la nieve)



Clasificador → **Lobo** (94 % confianza)

Explicación LIME (superpíxeles)



Superpíxeles destacados (amarillo = apoyo lobo, verde = evidencia perro)

LIME revela: el modelo mira la nieve (fondo), no el animal


- ▶ Clasificador lobos vs perros tiene 94 % accuracy sobre test — pero generaliza pésimo.
- ▶ Sin nieve en la imagen, el modelo confunde perros con lobos.
- ▶ **Lección:** la precisión no basta; hay que auditar qué aprende el modelo.

¿Qué es XAI?

Definición

Conjunto de técnicas que hacen comprensibles para humanos las decisiones de modelos de IA complejos (cajas negras).

BLACK BOX TESTING APPROACH



No es un extra estético: **es un requisito de ingeniería** para sistemas críticos.

Tres motivos para usar XAI

Más la creciente presión regulatoria

Confianza

- ▶ Medicina: ¿por qué este paciente es de alto riesgo?
- ▶ Conducción autónoma: ¿por qué frenó el vehículo?
- ▶ El usuario debe *poder* verificar la decisión.

Depuración

- ▶ Sesgos ocultos en datos de entrenamiento.
- ▶ Artefactos de *data leakage*.
- ▶ *Shortcut learning* (nieve → lobo).

Cumplimiento

- ▶ **EU AI Act:** trazabilidad obligatoria.
- ▶ *Right to explanation* (GDPR Art. 22).
- ▶ Auditoría de modelos de alto riesgo.

Sin explicación, no hay despliegue seguro

Taxonomía de la XAI

RED XAI vs BLUE XAI

Dos culturas complementarias (Biecek & Samek, 2024)

RED XAI

(model/validation-oriented):

Research, Explore, Debug.

Cuestiona el modelo para extraer conocimiento, detectar bugs y garantizar **seguridad**.

RED está under-explored: más métodos son necesarios para auditar modelos.

Two XAI Cultures

validation-oriented

Research

Explore

Debug

value-oriented

responsi**B**le

Legal

tru**U**st


Ethics

Figura original: Biecek & Samek (ICML 2024). Resumen de las dos culturas XAI.

BLUE XAI (human/value-oriented): centrado en *trust*, legal, *ethics* y explicaciones para el usuario. La narrativa está dominada por BLUE, pero RED ofrece grandes oportunidades.

Taxonomía de la XAI (I)


Eje temporal: Pre-hoc vs Post-hoc



Clave: No son mutuamente excluyentes. Se pueden combinar ambos enfoques.

Taxonomía de la XAI (II)


Eje de alcance: Local vs Global



Elección: Local para auditoría de casos concretos; Global para entender el modelo como sistema.

Taxonomía de la XAI (III)

Eje de modelo: Agnóstico vs Específico



Compromiso: Agnóstico es versátil pero menos preciso; Específico es preciso pero requiere acceso al modelo.

LIME

Local Interpretable Model-agnostic Explanations

Idea fundamental

Perturbar la entrada localmente y entrenar un modelo simple que aproxime el clasificador negro en esa vecindad.

- ▶ **Agnóstico:** funciona con cualquier clasificador.
- ▶ **Inestable:** distintas perturbaciones → distintas explicaciones.




Figura original: Ribeiro et al. (KDD 2016). LIME aproxima localmente con un modelo interpretable.

SHAP


SHapley Additive exPlanations

Fundamento

Valores de Shapley (teoría de juegos cooperativos). Cada *feature* es un jugador; su contribución se promedia sobre todos los subconjuntos posibles de *features*.

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_{S \cup \{i\}}(x) - f_S(x)]$$

ϕ_i = contribución de la *feature* i , F = conjunto de *features*



- Única solución que satisface eficiencia, simetría, linealidad y *dummy*.
- Coste computacional exponencial en número de *features*.

Contraejemplos (Counterfactual Explanations)

¿Qué tendría que cambiar para otra clase?

Formato natural

En lugar de “peso de la feature = 0.74”, el usuario escucha:

*Si tu ingreso fuera 5.000 EUR mayor, la solicitud sería **aprobada**.*



Ventajas: Más intuitivo para usuarios no técnicos; se alinea con el razonamiento causal humano.

Integrated Gradients

Atribución específica para redes neuronales

Idea

Integrar el gradiente de la salida respecto a la entrada a lo largo de un camino recto desde una *baseline* (ej. imagen negra) hasta la entrada real.

$$\text{IG}_i(x) = (x_i - x'_i) \int_{\alpha=0}^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_i} d\alpha$$

x = entrada, x' = *baseline*, F = red neuronal, α = paso de integración



Top label: viaduct
Score: 0.999994



Figura original: Sundararajan et al. (ICML 2017). Atribuciones mediante Integrated Gradients.

Satisfice: **Sensibilidad & Implementation Invariance.**

LRP

Layer-wise Relevance Propagation

Mecanismo

Propaga la relevancia de la salida hacia atrás, capa por capa, siguiendo reglas de conservación. Cada neurona recibe una fracción de la relevancia total.

$$R_j = \sum_k \frac{a_j w_{jk}}{\sum_{j'} a_{j'} w_{j'k} + \epsilon} R_k$$

a_j = activación, w_{jk} = peso, R_k = relevancia capa superior

Ventaja: heatmaps por píxel sin necesidad de *baseline*.

Reglas: LRP- ϵ , LRP- γ , LRP- $\alpha\beta$ según la capa y no-linealidad.




Figura original: Bach et al. (PLOS ONE 2015). Estructura de propagación de relevancia

LRP.

De píxeles a conceptos

CRP extiende LRP para explicar no solo *qué píxeles* importan, sino *qué conceptos de alto nivel* (ruedas, textura de pelo, alas, ...) activan la decisión.

- Busca hacia atrás en la red qué neuronas representan conceptos.
- Separa contribuciones por concepto semántico.
- Permite responder: ¿por *qué* (no solo *dónde*)?




Figura original: Achitbat et al. (ICLR 2022). CRP conecta mapas de atribución con conceptos semánticos.

Modelos basados en prototipos

ProtoPNet, ProtoPFormer y la XAI intrínseca

Idea RED XAI

El modelo no solo clasifica, sino que dice:

*Esto se parece a **este prototipo***

Cada prototipo es una parte de imagen aprendida durante el entrenamiento.




Figura original: Chen et al. (NeurIPS 2019). “This looks like that” – ProtoPNet compara partes de la entrada con prototipos aprendidos.

Ventaja clave: la explicación **es** el razonamiento del modelo, no una aproximación externa.

Quantus

Toolkit de métricas para XAI

+30 métricas organizadas en categorías

Fidelidad

Faithfulness,
Monotonicity,

Infidelity

Localización

Pointing Game,
Relevance Rank,

AUC

Complejidad

Sparseness,
Complexity,

Effective complexity

Robustez

Stability,
Continuity,

Local Lipschitz

Cita: Quantus permite evaluar de forma reproducible y estandarizada qué método XAI funciona mejor para cada problema.

Propuestas DAsCI en XAI

REVEL

Evaluación sistemática de explicaciones locales

Cinco métricas

1. **Fidelity** — fidelidad al modelo
2. **Concordance** — concordancia con el dominio
3. **Prescriptivity** — capacidad de acción
4. **Conciseness** — simplicidad / brevedad
5. **Robustness** — estabilidad ante perturbaciones




Figura original: Sevillano-García et al. (IJIS 2023). Distribución de métricas REVEL.

X-SHIELD

Regularización con explicaciones integradas en el entrenamiento

Arquitectura

Oculta *features* según explicaciones locales (saliency) durante el entrenamiento.

- ▶ $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{cls}} + \lambda \cdot \mathcal{L}_{\text{shield}}$
- ▶ Penaliza dependencia de *features* espurias.
- ▶ Mejora precisión e interpretabilidad.




Figura original: Sevillano-García et al. (MIR 2025). Arquitectura de X-SHIELD.

STOOD-X

XAI + Detección Out-of-Distribution

Idea clave

Un ejemplo OOD deberá estar lejos en el espacio de *features* que un ejemplo ID. Además, su explicación deberá darnos una idea de por qué es o no OOD.




Figura original: Sevillano-García et al. (Pattern Recognition 2026). Arquitectura de STOOD-X: detección OOD + explicaciones visuales.

Doble función: explica y detecta, sin coste adicional de inferencia.

Three-Level Framework

Técnico, Usuario y Social




Fig. 4: Understandability and dialogue level.

Figura original: Bello et al. (Information Systems Frontiers 2025 / arXiv:2506.05887). Estructura del Three-Level Framework.


CUBIC

Detección automática de sesgos conceptuales en visión


¿Qué hace?

Usa VLMs para descubrir **conceptos** que sesgan un clasificador sin anotaciones previas.

Ejemplo: Clasificador médico/no médico. CUBIC detecta que el fonendoscopio es el concepto sesgante, no la persona.



(a) Linear probe classifier. Example: binary classifier for wearing vs not glasses.



(b) Angle α_C between normal vector $\tilde{n}$ and concept-driven shift in superclass $\mathcal{L}$ embedding.

Concept Dataset
 $\{c_1, c_2, c_3 \dots\}$

Concept $C \cos(\alpha_C)$

Dog	0.03	
Dark hair	-0.24	→ interpreted as class 0 (glasses)
Blond	0.17	→ interpreted as class 1 (no-glasses)
Plate	0.08	
Forest	-0.06	
Car	0.02	

(c) Identification of concepts C inducing bias.

Figura original: Méndez et al. (Information Systems Frontiers 2026).

EU AI Act


Implicaciones para la XAI

Sistemas de alto riesgo

El EU AI Act exige, para sistemas clasificados como de alto riesgo:

- ▶ **Trazabilidad** de las decisiones del modelo.
- ▶ **Explicabilidad** de los resultados.
- ▶ Supervisión humana significativa.
- ▶ Documentación técnica completa.

XAI ya no es opcional — es un requisito legal.



Pirámide de riesgo del EU AI Act. Fuente: European Commission (2024).

Desafíos abiertos (I)

Limitaciones fundamentales de la XAI actual

XAI no es magia

- ▶ Las explicaciones post-hoc **pueden ser engañosas**.
- ▶ *Confirmation bias*: vemos lo que queremos ver.
- ▶ Sin métrica única consensuada — ¿cuándo una explicación es buena?

Coste y escalabilidad

- ▶ SHAP es exponencial en número de *features*.
- ▶ LRP e IG requieren acceso a gradientes (no siempre posible).
- ▶ Coste prohibitivo en LLMs grandes (GPT-4, LLaMA-3).

No todas las explicaciones son igual de fiables

Desafíos abiertos (II)

Nuevas fronteras y conclusión

XAI multimodal

- ▶ Explicar decisiones que combinan visión + texto + audio.
- ▶ ¿Cómo atribuir importancia a cada modalidad?

Cadenas de agentes

- ▶ Múltiples LLMs colaborando en una tarea.
- ▶ ¿A quién pedir explicaciones?

Takeaway

XAI es diseño, no decoración. La explicación debe adaptarse al destinatario, al riesgo de la decisión y al contexto de despliegue.

No hay explicación universal



DASCI

Instituto Andaluz
Interuniversitario en
Ciencia de Datos e
Inteligencia Computacional

Gracias

¿Preguntas?

Iván Sevillano-García

DASCI — Universidad de Granada

isevillano@dasci.es

APRENDIZAJE CONTINUO

Fundamentos de AI Safety y OOD Detection

¿Qué ocurre cuando creemos que lo sabemos todo?

Trustworthy AI

Juicio en EEUU

Precedentes Judiciales



O1	Asilo y refugio
O2	Contratos
O3	Hurtos
O4	Fraude
O5	Divorcios
O6	Adopciones
O7	Licencias y permisos



Trustworthy AI

Caso Cerrado

elEconomista.es
20 Años

Mercados y Cotizaciones Ibex 35 M.Continuo Empresas Economía Tecnología Salud Motor Inmobiliario Opinión

Tecnología

Una firma de abogados que cobra 8.000 euros la hora pide perdón por errores en documentos creados por IA

elEconomista.es

22/04/2026 - 14:48



EL PAÍS

SUSCRÍBETE

Economía

MERCADOS · VIVIENDA · FORMACIÓN · MIS DERECHOS · NEGOCIOS · CINCO DÍAS · RETINA · ÚLTIMAS NOTICIAS

INTELIGENCIA ARTIFICIAL >

■ Sentencias falsas, leyes extranjeras y filtrado de datos: los riesgos de usar ChatGPT se cuelan en los despachos de abogados

El uso incorrecto de la inteligencia artificial ha provocado ya sanciones de los tribunales, que advierten de la necesidad de contrastar la información que ofrece la herramienta

El coche autónomo tiene varios retos que no se arreglan con más sensores: niños, colegios y catástrofes naturales

Waymo de que **Coches autónomos y temporal extremo, un reto tecnológico importantes.**

motor.es

Publicado: 13/05/2026 11:00

≡

20bits

20 minutos



DIRECTO

Luis de la Fuente comunica la lista de los 26 convocados para el Mundial

Las alucinaciones entran en terreno sensible: Google daba información médica errónea en sus búsquedas con IA

INTELIGENCIA ARTIFICIAL NOTICIA

🕒 14 ene 2026 - 13:54

Trustworthy AI




REGLAMENTO (UE) 2024/1689 DEL PARLAMENTO EUROPEO Y DEL CONSEJO
de 13 de junio de 2024
por el que se establecen normas armonizadas en materia de inteligencia artificial y por el que se modifican los Reglamentos (CE) n.º 300/2008, (UE) n.º 167/2013, (UE) n.º 168/2013, (UE) 2018/858, (UE) 2018/1139 y (UE) 2019/2144 y las Directivas 2014/90/UE, (UE) 2016/797 y (UE) 2020/1828 (Reglamento de Inteligencia Artificial)
(Texto pertinente a efectos del EEE)

Trustworthy AI



Trustworthy AI (IA confiable): es un paradigma de inteligencia artificial que engloba todos los **enfoques técnicos y herramientas** para desarrollar, desplegar y utilizar sistemas de IA seguros, legales y éticos.

Trustworthy AI




Trustworthy AI

Enfoque basado en el riesgo



Xiaoyi, el robot que pasa consulta en China tras aprobar Medicina

Este robot médico puede revisar historiales de pacientes y sugerir recetas. Podría ser una solución a los colapsos asistenciales y a la falta de médicos.



Black Mirror - Social Credit System (Nosedive S3E1)



Trustworthy AI




Enfoque basado en el riesgo



Xiaoyi, el robot médico

aprobar Medicina

Este robot médico puede revisar a los pacientes asistenciales y a la falta de médicos.



diver S3E1)

Lacie
4.243

Responsible and safe AI

Los enfoques técnicos de **Trustworthy AI** nos permiten diseñar **Responsible AI Systems**, garantizando la auditabilidad y la rendición de cuentas durante su diseño, desarrollo y uso (en escenarios de (alto) riesgo, tal como se describen en la Ley de IA de la UE — *EU AI Act*)

Responsible AI (IA responsable): es un área de la gobernanza de la inteligencia artificial que se centra en el desarrollo de la IA tanto desde un punto de vista ético como legal.

Responsible AI system (sistema de IA responsable): “Es un sistema de IA que requiere garantizar la auditabilidad y la rendición de cuentas durante su diseño, desarrollo y uso, de acuerdo con las especificaciones y la normativa aplicable del ámbito de práctica en el que se vaya a utilizar el sistema de IA.” [Díaz-Rodríguez et al. 23].



El término *Responsible AI* se ha utilizado ampliamente casi como sinónimo de *Trustworthy AI*, pero obviamente no lo es. *Trustworthy AI* se refiere a las tecnologías y enfoques técnicos de los sistemas de IA para desarrollar sistemas de IA responsables.

Responsible and safe AI

AI safety (seguridad de la IA): es un campo interdisciplinar que se ocupa de prevenir accidentes, usos indebidos u otras consecuencias dañinas que podrían derivarse de los sistemas de inteligencia artificial.

Problemas no resueltos en ML Safety

	Robustez	Crear modelos resilientes ante adversarios, situaciones inusuales y eventos de 'Cisne Negro'.
	Monitoreo	Detectar usos malintencionados, monitorear predicciones y descubrir funcionalidades inesperadas del modelo.
	Alineación	Construir modelos que representen y optimicen de forma segura valores humanos difíciles de especificar.
	Seguridad Externa	Utilizar el AA para abordar riesgos en el manejo de sistemas de AA, tales como los ciberataques.



AI safety $\neq$ AI security

Robustness

Robustez: Capacidad de un sistema de IA para mantener su rendimiento frente a diversas perturbaciones y entradas adversarias a lo largo del AI lifecycle (ciclo de vida de la IA).

AI Lifecycle



Anomalías

Usos maliciosos


Ataques adversarios

Puertas traseras





¿Qué ocurre cuando creemos
que lo sabemos todo?




¿Qué ocurre cuando creemos que lo sabemos todo?




¿Qué ocurre cuando creemos que lo sabemos todo?



MUNDO CERRADO



MUNDO ABIERTO




Necesitamos mejorar la confiabilidad
de los modelos ante un mundo abierto




Mundo cerrado



Sobreocupación de espacio



(a) Closed set classifier



(b) Open Set classifier

No adaptación a la evolución de los datos



Mundo abierto: Out-of-Distribution

A Unified Survey on Anomaly, Novelty, Open-Set, and Out-of-Distribution Detection: Solutions and Future Challenges

Mohammadreza Salehi
University of Amsterdam

Generalized Out-of-Distribution Detection: A Survey

Jingkang Yang · Kaiyang Zhou · Yixuan Li · Ziwei Liu

Out-Of-Distribution Detection Is Not All You Need

Joris Guérin^{1,2}, Kevin Delmas³, Raul Ferreira², Jérémi Guiochet²

Managing the unknown: a survey on Open Set Recognition and tangential areas

Marcos Barcina-Blanco, Jesus L. Lobo, Pablo Garcia-Bringas, Javier Del Ser

Detección de datos (imágenes) OOD



ID
(raza cocker)

OOD
(raza cocker)
Anomalía sensorial

OOD
(mestizo)
Anomalía semántica


ood (out of distribution)
id (in distribution)

- Sikder, M.N.K., Batarseh, F.A.: Outlier detection using AI: a survey. *AI Assurance* 7, 231–291 (2023). <https://doi.org/10.1016/B978-0-32-391919-7.00020-2>
- Winkens, J., Bunel, R., Roy, A. G., Stanforth, R., Natarajan, V., Ledsam, J. R., ... & Ronneberger, O. (2020). Contrastive training for improved out-of-distribution detection. *arXiv preprint arXiv:2007.05566*

Mundo abierto: Out-of-Distribution

Tipos de anomalías semánticas

ID



Near




Far



ID	Near	Far
CIFAR 10	CIFAR 100	EMNIST

Out-of-Distribution



Mucho por hacer


EL PAÍS

Ciencia / Materia

NEUROCIENCIA >

Una mujer consigue 'hablar' en tiempo real, tras 20 años de silencio, al conectar su cerebro a una máquina

Una interfaz entrenada con IA registra su actividad cerebral cuando intenta decir las palabras y las reproduce con la voz sintetizada de la paciente, que sufrió un derrame



Tras 20 años sin poder hablar por un derrame cerebral, la IA le ha permitido volver a comunicarse en tiempo real con su voz sintetizada



Enhancing Out-of-Distribution Detection in Medical Imaging with Normalizing Flows

Dariush Lotfi¹, Mohammad-Ali Nikouei Mahani¹, Mohamad Koohi-Moghadam^{1*}, Kyongtae Ty Bae^{1*}

Class Incremental Learning for Image Classification with Out-of-distribution Task Identification

Xusheng Cao, Haori Lu, Xialei Liu, *Member, IEEE*, Ming-Ming Cheng, *Senior Member, IEEE*,

GDDA: Semantic OOD Detection on Graphs under Covariate Shift via Score-Based Diffusion Models

Zhixia He¹, Chen Zhao², Minglai Shao^{1*}, Yujie Lin¹, Dong Li³, Qin Tian³

APRENDIZAJE CONTINUO

Aprendizaje Continuo

¿Cómo aprenden los modelos a lo largo del tiempo sin olvidar?

Motivación del CL

El mundo real es dinámico

Nuevos datos, nuevas tareas, distribuciones cambiantes. Un modelo estático se vuelve obsoleto.

Reentrenar desde cero es inviable

Coste computacional, energético y temporal prohibitivo en modelos grandes.

Acceso limitado a datos históricos

Regulaciones de privacidad (RGPD) impiden retener todos los datos de entrenamiento.

Los humanos aprenden de forma continua

Acumulamos conocimiento a lo largo de la vida sin olvidar lo aprendido previamente.

10x


más rápido que reentrenar

T1...Tn

secuencia de tareas a dominar

¿Qué es el CL?

Paradigma de entrenamiento donde un modelo aprende **secuencialmente múltiples tareas**, manteniendo el rendimiento en las anteriores sin reentrenar desde cero.



Catastrophic Forgetting

Cuando un modelo se reentrena en una nueva tarea, su rendimiento en las anteriores cae drásticamente. Los nuevos gradientes sobrescriben los pesos aprendidos (McCloskey & Cohen, 1989).

Tras entrenar Task A

95%

Accuracy en Task A

Entrena Task B

Tras entrenar Task B

12%

Accuracy en Task A

¿Por qué ocurre?

Al optimizar $L_B(\theta)$, el descenso del gradiente actualiza todos los pesos del modelo. Esto destruye la representación θ_A^* aprendida para Task A, ya que las redes no tienen mecanismo para proteger pesos críticos.


Cuanto mayor es la diferencia entre tareas, mayor es el olvido.

Tipos de CL

Task-Incremental

El modelo conoce la tarea en test

- ID de tarea disponible en inferencia
- Se puede usar un cabezal de clasificación por tarea
- El más sencillo de los tres escenarios
- Ejemplo: clasificar imágenes de animales, luego vehículos



Perro 1





Gato 2

Domain-Incremental

Misma tarea, distribución diferente


- Las clases no cambian entre tareas
- Cambia la distribución de los datos de entrada
- No se proporciona ID de tarea en test
- Ejemplo: clasificación bajo distintas condiciones de iluminación



Class-Incremental

Nuevas clases en cada tarea

- Nuevas clases se añaden progresivamente
- El modelo debe distinguir entre todas las clases vistas
- El más desafiante: propenso al olvido catastrófico
- Ejemplo: reconocer 10 clases iniciales + 10 nuevas + 10 más...



Perro



Gato

Técnicas de CL. EWC.

Ante el olvido catastrófico, la primera idea es añadir un término de regularización que penalice grandes cambios en los pesos respecto a la tarea anterior.

$$L(\mathbf{x}) = L_B(\mathbf{x}) + \lambda \cdot ||\boldsymbol{\theta} - \boldsymbol{\theta}_{A^*}||^2$$

Componentes


$L_B(\boldsymbol{\theta})$ Pérdida en la nueva tarea B

$\boldsymbol{\theta}_{A^*}$ Pesos óptimos tras la tarea A

λ Parámetro de equilibrio entre tareas

Problema con L2 puro

Penaliza **todos los pesos por igual**, independientemente de su importancia para la tarea A..




Técnicas de CL. EWC.

Elastic Weight Consolidation (Kirkpatrick et al. 2017) usa la **Matriz de Información de Fisher (FIM)** para ponderar la importancia de cada peso para la tarea anterior.

$$L_{EWC}(\mathbf{x}) = L_B(\mathbf{x}) + \lambda \cdot \sum_i F_i \cdot (\theta_i - \theta_{A^*,i})^2$$

Fisher Information Matrix (FIM)

$$F_i = E[(\partial \log p(\mathbf{x}|\theta) / \partial \theta_i)^2]$$



EWC vs L2

- ✓ Pesos importantes quedan protegidos
- ✓ Pesos irrelevantes quedan libres para aprender
- ⚠ Coste: calcular la FIM tras cada tarea
- ⚠ Con muchas tareas, puede volverse restrictivo

Técnicas de CL. LoRA

Low-Rank Adaptation (Hu et al. 2021): en lugar de actualizar todos los pesos $W \in \mathbb{R}^{(d \times k)}$, se añaden matrices de bajo rango que capturan los cambios necesarios.


$$W_{\text{actualizado}} = W_0 + \Delta W = W_0 + B \cdot A$$

$$W_0 \in \mathbb{R}^{d \times k}$$

Pesos originales del modelo preentrenado. Permanecen congelados durante el fine-tuning.

$$B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}$$

Matrices de bajo rango entrenables. Inicialmente $B=0$, $A \sim \mathcal{N}(0, \sigma^2)$ para que $\Delta W=0$.



Técnicas de CL. LoRA

LoRA aplicado al aprendizaje continuo: cada tarea entrena su propio adaptador de bajo rango mientras el modelo base permanece congelado.

Estrategia por tarea

Tarea 1: Entrena (A_1, B_1) , congela W_0

Tarea 2: Entrena (A_2, B_2) , congela $W_0 + A_1B_1$

Inferencia: Activa el adaptador de la tarea correspondiente

Ventajas

- ✓ Sin olvido catastrófico: W_0 nunca cambia
- ✓ Coste mínimo por tarea
- ✓ Compatible con modelos fundacionales (LLMs)

Limitaciones

- ⚠ Requiere conocer el ID de tarea en test
- ⚠ Número de parámetros crece linealmente con las tareas

Variantes para CL

O-LoRA: ortogonaliza los adaptadores entre tareas

LoRA-Pro: optimiza la dirección del gradiente

Adapter Merging: fusiona adaptadores para reducir memoria

Degradación de las tareas anteriores

Tras aprender N tareas secuencialmente, ¿cómo medimos el olvido? La métrica estándar es el **Backward Transfer (BWT)**.

$$\text{BWT} = 1/(N-1) \cdot \sum_{j=1}^{N-1} [A(N,j) - A(j,j)]$$

Interpretación

$A(i,j)$ = accuracy en tarea j tras entrenar en tarea i

$A(j,j)$ = accuracy justo tras aprender la tarea j (referencia)

BWT < 0 Olvido: el rendimiento en tareas anteriores disminuye

BWT = 0 Sin olvido: rendimiento se mantiene intacto

BWT > 0 Transfer positivo: aprender nuevas tareas mejora las anteriores

Matriz de Accuracy

T1 T2 T3

T1 [95% - -]

T2 [60% 91% -]

T3 [28% 55% 88%]

$\text{BWT} = ((28-95)+(55-91))/2 = -51.5\%$

Transición para unlearning

Hemos visto cómo los modelos pueden aprender de forma continua. Ahora exploramos el problema inverso: ¿cómo hacer que un modelo **olvide** información específica?

Aprendizaje Continuo



Añadir conocimiento nuevo

El modelo aprende $T_1, T_2 \dots T_n$ sin olvidar lo anterior.

Control sobre lo que SE APRENDE.



Machine Unlearning



Eliminar conocimiento específico

El modelo olvida datos concretos como si nunca los hubiera visto.

Control sobre lo que SE OLVIDA.

Un modelo entrenado puede revelar sus datos de entrenamiento

Extracción de datos




Carlini et al. 2020

Ataques de pertenencia



Memorización



Puede
memorizar
un dato

“Si se puede extraer tiene sentido poder pedir que se olvide”

Ya tenemos el derecho

RGPD

Derecho al olvido

Art. 17

Derecho de supresión: puedes pedir que borren tus datos personales

AI ACT (2024)

Regulación de IA

AI Act

Obligaciones de transparencia en sistemas de IA de alto riesgo

LOPD-GDD

Ley orgánica 3/2018

LO 3/2018

Adapta el RGPD al marco español con derechos digitales propios

La ley reconoce el derecho al olvido, pero los modelos no fueron diseñados para olvidar

Machine unlearning

Técnicas para que un modelo olvide un dato específico sin necesidad de reentrenarlo desde cero


Objetivo

El modelo se comporta como si nunca hubiera visto ese dato sin sacrificar su rendimiento general.

Cuidado
con
olvidar de
más



Tipos de unlearning



Todo los datos

Algunos datos

Solo lo que olvido

Información estadística

Exacto

Aproximado

Exacto

Aproximado

Tipos de unlearning


Olvido
de
muestra

Olvido
de
clase

Datos a recordar



Datos a olvidar



Técnicas de unlearning. CL

El unlearning se puede enmarcar dentro del continual learning donde la tarea A fue aprender originalmente y la tarea B es olvidar un subconjunto de los datos.

$$L(x) = L_{CL}(x) + L_B(x)$$

L_{CL} es la función de pérdida correspondiente al método de continual learning usado.

L_B es una función de pérdida que favorece el olvido para los x que se quieran olvidar y es 0 para los x que se vayan a recordar.

Para L_B se pueden usar diversas funciones pero se pueden dividir en tres categorías:

- Maximizar un logit distinto al correcto.
- Igualar los valores de todos los logits.
- Minimizar distancias en espacio de embeddings/características.


Técnicas de unlearning. SISA

SISA (Sharded, Isolated, Sliced & Aggregated, Bourtoule et al. 2021): estrategia de entrenamiento que facilita el olvido eficiente sin reentrenar el modelo completo.

Sharded	Isolated	Sliced	Aggregated
Los datos de entrenamiento se dividen en K fragmentos (shards) independientes y disjuntos.	Se entrena un modelo separado por cada shard. Los modelos no comparten información.	Cada shard se divide en slices temporales. Se guardan checkpoints al final de cada slice.	Las predicciones de todos los modelos se combinan mediante votación o promedio para inferencia.

¿Cómo se olvida?

1. Identificar el shard y slice que contiene el dato a olvidar.
2. Reentrenar solo ese modelo desde el último checkpoint anterior al dato.
3. El resto de modelos permanecen intactos.



Técnicas de unlearning. SSD

SSD (Selective Synaptic Dampening, Foster et al. 2023): amortiguamiento selectivo de sinápsis basado en su importancia, usando la Matriz de Información de Fisher. Conexión directa con EWC.

Algoritmo SSD

- 1. Calcular F_{retain} :** FIM sobre el conjunto de datos a retener D_{retain} .
- 2. Calcular F_{forget} :** FIM sobre los datos a olvidar D_{forget} .
- 3. Identificar pesos:** Seleccionar los pesos donde $F_{\text{forget}} > \alpha \cdot F_{\text{retain}}$ (importantes para D_{forget} pero no para D_{retain}).
- 4. Amortiguamiento:** Reducir (dampening) el valor de esos pesos: $\theta_i \leftarrow \theta_i / (1 + \lambda \cdot F_{\text{forget}_i})$.

Ventajas sobre SISA

- ✓ No requiere estrategia de entrenamiento especial
- ✓ Aplicable a modelos ya entrenados
- ✓ Olvido más dirigido y preciso


Limitaciones

- ⚠ Requiere calcular la FIM (costoso)
- ⚠ Puede afectar levemente al rendimiento en D_{retain}
- ⚠ α y λ requieren calibración cuidadosa


Límites del unlearning

Caída de rendimiento

En Approximate Unlearning




Unlearning secuencial



Verificación del olvido

¿Cómo saber si el modelo realmente olvidó?



¿Que diferencia hay entre un dato olvidado y un dato que nunca ha visto en entrenamiento?

¿Pueden las vacas ir a la playa?


Mario García Márquez

Nuestro compañero de hoy

Beepo


Vamos a enseñarle a Beepo a diferenciar entre animales.

Beepo quiere aprender, y ha oído que tal vez la clase de “Machine Learning” va de enseñarle cosas a las máquinas, así que ha venido.



| ¿Cómo se le enseña a Beepo?


¿Qué nos hace falta para enseñarle a Beepo?



| ¿Cómo se le enseña a Beepo?

¿Qué nos hace falta para enseñarle a Beepo?

- Datos, muchos datos.
- Una función de pérdida.



| Los datos

Primero vamos enseñarle imágenes de vacas.

Los datos

Primero vamos enseñarle imágenes de vacas.



Vaca #1

Los datos

Primero vamos enseñarle imágenes de vacas.



Vaca #1



Vaca #2

Los datos


Primero vamos enseñarle imágenes de vacas.



Vaca #1



Vaca #2



Vaca #3

| Los datos

Ahora, le enseñamos a Beepo fotos de camellos.

Los datos

Ahora, le enseñamos a Beepo fotos de camellos.



Camello #1

Los datos

Ahora, le enseñamos a Beepo fotos de camellos.



Camello #1



Camello #2

Los datos

Ahora, le enseñamos a Beepo fotos de camellos.



Camello #1



Camello #2



Camello #3

| El momento de la verdad

Test!

Vamos a enseñarle a Beepo imágenes que nunca ha visto para comprobar cómo generaliza.

¿Que pensáis que va a predecir?



| Oops...

Predicción: CAMELLO

Beepo se ha equivocado pero bien, pero ¿por qué?

¿Cómo lo arreglaríais?



¿Qué está pasando?

Hablemos de las correlaciones espúreas

| ¿Por qué importa este problema?



Problemas de generalización

Las correlaciones hacen que los modelos fallen en entornos reales al confiar en patrones irrelevantes.



Riesgos en Salud

En medicina, un "atajo" algorítmico (como una marca de agua) puede invalidar un diagnóstico crítico.

| Consideremos los siguientes datos

El caso clásico del helado y los ahogamientos




Helados



Ahogos


Visualizamos los datos

Ventas de helados vs. Incidentes de ahogamiento




| Consideremos los siguientes datos

El caso clásico del helado y los ahogamientos



| ¿Pero esto tiene sentido?

Quizás para Beepo, que solo sabe de los datos que ve no sea tan evidente, pero vosotros ¿pensáis que tiene sentido?



Causalidad vs. Correlación

El caso clásico del helado y los ahogamientos



¿Cómo afirmar causalidad?

El caso clásico del helado y los ahogamientos



Datos observados y Causal Discovery

Cuando la intervención directa no es una opción

RESTRICCIÓN

El Límite de la Observación

En muchos escenarios, solo tenemos acceso a datos históricos o pasivos. **No podemos intervenir** en el sistema para ver qué sucede, lo que oculta las verdaderas relaciones de causa y efecto.

METODOLOGÍA

La Solución: Causal Discovery


Mediante algoritmos de **Causal Discovery**, intentamos inferir la estructura del grafo causal analizando las dependencias estadísticas e independencias condicionales en los datos.



Inferencia de Estructura

Causal discovery

El caso clásico del helado y los ahogamientos



Requisitos para Causal Discovery

Condiciones fundamentales para la inferencia de estructuras

SUFICIENCIA

Suficiencia Causal

Debemos haber observado **todas las variables relevantes** que causan a más de una variable en el sistema. Si falta un confusor común, la estructura resultante será incorrecta.



Variables Observadas

ESTRUCTURA

Grafo Acíclico (DAG)

Se asume que la estructura de relaciones es un **Grafo Acíclico Dirigido**. No existen ciclos de retroalimentación causal inmediata ($A \rightarrow B \rightarrow A$) en el modelo estándar.



Sin Ciclos Causales

Volvemos a nuestro problema

¿Cuáles son nuestras variables en este caso?



Causal representation learning

Data Generating Process: Del mundo real a la observación

ESTADO Z

Z

Descripción semántica
perfecta del estado del
mundo.

Causal representation learning

Data Generating Process: Del mundo real a la observación



Causal representation learning


Data Generating Process: Del mundo real a la observación



Nota: Z debe interpretarse como una descripción perfecta de una imagen, capturando todos los mecanismos causales subyacentes.


Causal representation learning

Descomposición del Espacio Latente: Factores Causales e Invariantes



Causal representation learning

Estructura de un Autoencoder y el Espacio Latente Z



Causal representation learning

Supervisión débil

ENTORNO A



Vacas en un prado

ENTORNO B



Vacas en la playa

Causal representation learning

Intervenciones en el Estilo (ZS)

ENTORNO A



Intervención 1

ZS = "Prado de montaña"

El mecanismo de generación $f(ZC, ZS)$ produce una observación donde el estilo es rural e interno.

ENTORNO B



Intervención 2

ZS = "Playa costera"

Cambiamos el factor espurio ZS. ZC (la vaca) permanece invariante ante el cambio de entorno.

Causal representation learning

V-REx: Variance Risk Extrapolation

$$RV-REx = \sum_e R_e + \beta \cdot \text{Var}(\{R_e\}_e)$$

OBJETIVO

Minimizar el riesgo promedio mientras se reduce la varianza del rendimiento entre distintos entornos (Entorno A, B, etc.).

RESULTADO

Se obtienen representaciones **ZC** (invariantes) que ignoran los factores espurios **ZS** presentes en el estilo.

Preguntas

Contacto: mariogmarq@ugr.es



Aspectos Avanzados. Parte II

- Problemas singulares y aprendizaje supervisado
- Privacidad y aprendizaje federado
- Aprendizaje por refuerzo
- Fundamentos matemáticas del Aprendizaje Profundo
- IA Generativa. Nuevo paradigma
- Riesgos, ética y regulación
- IA Confiable - Trustworthy AI
- Bajando a la realidad: seguridad y gobernanza
- IA de propósito general. ¿Qué es y hacia donde avanza?
- Concluyendo (reflexiones y debates)
- Literatura recomendada