





Aprendizaje Automático

Curso 2025-2026

Tema 3. Calidad de datos



Bibliografía



- 
- Tema 1: Conceptos básicos del Aprendizaje Automático
 - Tema 2: Aprendizaje Supervisado. Regresión y Clasificación. Modelos. Evaluación
 - **Tema 3: Ingeniería de Características y Preprocesamiento de Datos. Calidad de Datos**
 - Tema 4: Aprendizaje no Supervisado
 - Tema 5: Aprendizaje Profundo. Fundamentos
 - Tema 6: Aprendizaje Profundo en diferentes tipos de datos y problemas
 - Tema 7. Aprendizaje por refuerzo
 - Tema 8: Optimización en Aprendizaje Automático. Hiperparámetros, selección de modelos y regularización
 - Tema 9: Aspectos Avanzados, retos y desafíos del aprendizaje automático



Calidad de Datos

Calidad de datos

Introducción al preprocesamiento de datos

Integración, limpieza y transformación

Datos imperfectos

Reducción de datos

Discretización

Selección de Características



Selección de Instancias

Comentarios finales



Calidad de datos

MODEL CALCULATIONS "Garbage In-garbage Out" Paradigm




Calidad de datos
para la calidad de
decisiones!

Calidad de datos

- **Preprocesamiento de datos:** La forma de transformar los datos brutos en datos de calidad (Smart data).

D. Pyle, 1999, pp. 90:

“The fundamental purpose of data preparation is to manipulate and transform raw data so that the information content enfolded in the data set can be exposed, or made more easily accesible.”




Dorian Pyle
Data Preparation for Data
Mining Morgan Kaufmann
Publishers, 1999

Calidad de datos

- **Preprocesamiento de datos:** La forma de transformar los datos brutos en datos de calidad (Smart data).

D. Pyle, 1999, pp. 90:

“El propósito fundamental de la preparación de los datos es la manipulación y transformación de los datos sin refinar para que la información contenida en el conjunto de datos pueda ser descubierta o estar accesible de forma más fácil.”




Dorian Pyle
Data Preparation for Data Mining Morgan Kaufmann Publishers, 1999

Calidad de datos

- **Preprocesamiento de datos:** La forma de transformar los datos brutos en datos de calidad (Smart data).

S. García, J. Luengo, F. Herrera, 2015, Preface vii:

“Data preprocessing is an often neglected but major step in the data mining process.” “El preprocesamiento de datos es un paso a menudo descuidado pero muy importante en el proceso de minería de datos”



S. García, J. Luengo, F. Herrera
Data Preprocessing in Data Mining
Springer, January 2015
Website:

<http://sci2s.ugr.es/books/data-preprocessing>



Calidad de Datos

Calidad de datos

Introducción al preprocesamiento de datos

Integración, limpieza y transformación

Datos imperfectos

Reducción de datos

Discretización

Selección de Características

Selección de Instancias

Comentarios finales

Introducción al preprocesamiento de datos

S. García, J. Luengo, F. Herrera, 2015, Preface viii:

Son muchas las ventajas que proporciona el preprocesamiento de datos:

- **Adaptar y particularizar los datos para cada algoritmo de minería de datos.**
- **Incrementar la efectividad y precisión en las tareas predictivas.**
- **Reducir la cantidad de datos necesarios para una tarea de aprendizaje adecuada, disminuyendo también su complejidad temporal.**
- **Hacer posible lo imposible con datos sin procesar, permitiendo que se apliquen algoritmos de minería de datos/aprendizaje automático sobre grandes volúmenes de datos.**
- **Apoyar a la comprensión de los datos.**

Introducción al preprocesamiento de datos

- **Preprocesamiento de datos:** La forma de transformar los datos brutos en datos de calidad (Smart data).

Proceso de minería de datos





Fig. 1.1: KDD process.

Introducción al preprocesamiento de datos

- **Preprocesamiento de datos:** La forma de transformar los datos brutos en datos de calidad (Smart data).



El preprocesamiento de datos consume una parte muy importante del tiempo total en un proceso de minería de datos.



Introducción al preprocesamiento de datos

Importancia del Preprocesamiento de Datos

1. Los datos reales pueden ser impuros, pueden conducir a la extracción de patrones/reglas poco útiles.

Esto se puede deber a:

Datos Incompletos: falta de valores de atributos, ...

Datos con Ruido

Datos inconsistentes (incluyendo discrepancias)

Introducción al preprocesamiento de datos

Importancia del Preprocesamiento de Datos

2. El preprocesamiento de datos puede generar un conjunto de datos más pequeño que el original, lo cual puede mejorar la eficiencia del proceso de Minería de Datos.

Esta actuación incluye:

Selección relevante de datos: eliminando registros duplicados, eliminando anomalías, ...

Reduccion de Datos: Selección de características, muestreo o selección de instancias, discretización.

Introducción al preprocesamiento de datos

Importancia del Preprocesamiento de Datos

3. El preprocesamiento de datos genera “datos de calidad”, los cuales pueden conducir a “patrones/reglas de calidad”.


Por ejemplo, se puede:

Recuperar información incompleta.

Eliminar outliers

Resolver conflictos

Seleccionar variables relevantes, ...





Introducción al preprocesamiento de datos

Importancia del Preprocesamiento de Datos

- Datos de baja calidad puede llevar a modelos de minería de datos de baja calidad.

Decisiones de calidad deben ser basadas en datos de calidad.

- El preprocesamiento de datos (limpieza, transformación, reducción....) puede llevar la mayor parte del tiempo de trabajo en una aplicación de minería de datos (80%).



Introducción al preprocesamiento de datos

¿Qué incluye el Preprocesamiento de Datos?

“El Preprocesamiento de Datos”

engloba a todas aquellas técnicas de análisis de datos que permite mejorar la calidad de un conjunto de datos de modo que las técnicas de extracción de conocimiento/minería de datos puedan obtener mayor y mejor información (mejor porcentaje de clasificación, reglas con más completitud, etc.)

Introducción al preprocesamiento de datos

¿Qué incluye el Preprocesamiento de Datos?

S. García, J. Luengo, F. Herrera, 2015, Preface vii:

“Data preprocessing includes data preparation, compounded by integration, cleaning, normalization and transformation of data; and data reduction tasks; such as feature selection, instance selection, discretization, etc.

...


The result expected after a reliable chaining of data preprocessing tasks is a final dataset, which can be considered correct and useful for further data mining algorithms.”

Introducción al preprocesamiento de datos

¿Qué incluye el Preprocesamiento de Datos?

We refer to **data preparation** as the set of techniques that initialize the data properly to serve as input for a certain ML/DM algorithm.

Data reduction comprises the set of techniques that, in one way or another, obtain a reduced representation of the original data.



S. García, J. Luengo, F. Herrera
Data Preprocessing in Data Mining
Springer, 2015

Introducción al preprocesamiento de datos

¿Qué incluye el Preprocesamiento de Datos?




Fig. 1.3 Forms of data preparation

Introducción al preprocesamiento de datos

¿Qué incluye el Preprocesamiento de Datos?




Fig. 1.4 Forms of data reduction



Calidad de Datos

Calidad de datos

Introducción al preprocesamiento de datos

Integración, limpieza y transformación

Datos imperfectos

Reducción de datos

Discretización

Selección de Características

Selección de Instancias

Comentarios finales

Integración, limpieza y transformación






Fig. 1.3 Forms of data preparation

Integración

Base de
Datos 1




Base de
Datos 2



Extracción,
agregación ..



Servidor
Data Warehouse



Tened en cuenta variables similares en valores. Atributos derivados: Salario mensual versus salario anual

item	Salario/mes
1	5000
2	2400
3	3000

item	Salario
6	50,000
7	100,000
8	40,000

Detección de datos duplicados e inconsistencias.


Redundancia. Un atributo es redundante si puede obtenerse a partir de otros.

Una forma de detectar redundancia es mediante análisis de correlaciones.



Limpieza

► Objetivos:

- resolver inconsistencias
 - suavizar el ruido de los datos,
 - identificar o eliminar *outliers* ...
- 

Transformación

- **Objetivo:** Transformar los datos de la mejor forma posible para la aplicación de los algoritmos de DM.
- Algunas operaciones típicas:
 - Agregación. P.e. totalización de ventas mensuales en un único atributo que sea ventas anuales,...
 - Generalización de los datos. Se trata de obtener datos de más alto nivel a partir de los actuales, utilizando jerarquías de conceptos.
 - Calles → ciudades
 - Edad numérica → {joven, adulto, mediana-edad, anciano}
 - Normalización: Cambiar el rango $[-1,1]$ o $[0,1]$.
 - Transformaciones lineales, cuadráticas, polinomiales, ...

Transformación: Normalización

- **Objetivo:** pasar los valores de un atributo a un rango mejor.
- Útil para algunas técnicas como AANN o métodos basados en distancias (vecinos más próximos,...).
- Algunas técnicas de normalización:
 - **Normalización min-max:** Realiza una transformación lineal de los datos originales.

$$[\min_A, \max_A] \rightarrow [\text{nuevo}_{\min_A}, \text{nuevo}_{\max_A}]$$
$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{nuevo}_{\max_A} - \text{nuevo}_{\min_A}) + \text{nuevo}_{\min_A}$$

Las relaciones entre los datos originales se conservan.

Transformación: Normalización

- **Normalización zero-mean**. Se normaliza en función de la media y la desviación estándar.

$$v' = \frac{v - \bar{A}}{\sigma_A}$$

Útil cuando se desconocen los límites o cuando los datos anómalos pueden dominar la normalización min-max.

- **Normalización por escala decimal**. Normaliza moviendo el punto decimal de los valores del atributo. El número de puntos decimales movidos depende del valor absoluto máximo de A.

$$v' = \frac{v}{10^j}$$

con j igual al menor entero tal que $\max(|v'|) < 1$.

P.e.: si los datos están en $[-986,917]$, entonces $j=3$.



Calidad de Datos

Calidad de datos

Introducción al preprocesamiento de datos

Integración, limpieza y transformación

Datos imperfectos

Reducción de datos


Discretización

Selección de Características

Selección de Instancias

Comentarios finales

Datos imperfectos



Datos imperfectos

Information Sources

Attributes

Class


Att 1	Att 2	Class
0.25	red	positive
0.25	red	negative
0.99	green	negative
1.02	green	positive
2.05	?	negative
=	green	positive

Att. Noise


Class Noise

Kinds of Noise

Missing Values Imputation



Noise Identification



Datos imperfectos: Valores perdidos

	Attributes						
	1	2	3	4	5	...	m
1					?		
2			?				
3		?		?			
4							
5							
6						?	
7			?		?		
8							
9							
10			?			?	
11		?					
:				?			
n							?

Se pueden utilizar las siguientes opciones, aunque algunas de ellas sesgan los datos:

- Ignorar la tupla. Suele usarse cuando la variable a clasificar no tiene valor.
- Rellenar manualmente los datos. En general es impracticable.
- Utilizar una constante global para la sustitución. P.e. "desconocido", "?", ...
- Rellenar utilizando la media/desviación del resto de las tuplas.
- Rellenar utilizando la media/desviación del resto de las tuplas pertenecientes a la misma clase.
- Rellenar con el valor más probable. Para ello utilizar alguna técnica de inferencia, p.e. bayesiana o un árbol de decisión.

Datos imperfectos: Valores perdidos

Posición	Valor original	Pos. 11 perdida	Preservar la media	Preservar la desviación
1	0.0886	0.0886	0.0886	0.0886
2	0.0684	0.0684	0.0684	0.0684
3	0.3515	0.3515	0.3515	0.3515
4	0.9875	0.9875	0.9875	0.9875
5	0.4713	0.4713	0.4713	0.4713
6	0.6115	0.6115	0.6115	0.6115
7	0.2573	0.2573	0.2573	0.2573
8	0.2914	0.2914	0.2914	0.2914
9	0.1662	0.1662	0.1662	0.1662
10	0.4400	0.4400	0.4400	0.4400
11	0.6939	????	0.3731	0.6622
Media	0.4023	0.3731	0.3731	
SD	0.2785	0.2753		0.2753
Error en la estimación			0.3208	0.0317

Datos imperfectos: Valores perdidos

- Rellenar buscando relaciones entre variables.

P.e.: de los datos de las columnas X e Y, se podría estimar $Y = 1.06 \cdot X$ y utilizarlo como estimador para valores perdidos de Y.

X (orig.)	Y (orig.)	Y estimado	error
0.55	0.53	0.51	0.02
0.75	0.37	0.31	0.06
0.32	0.83	0.74	0.09
0.21	0.86	0.85	0.01
0.43	0.54	0.63	0.09

Datos imperfectos: Valores perdidos

Estimación mediante técnicas de aprendizaje automático:

- Imputación con k-NN (KNNI)
- Imputación con k-NN y pesos (WKNNI)
- Imputación basada en clustering (KMI)
- Imputación basada en algoritmos de SVM (SVMI)
- Otros: event covering (EC), singular value decomposition (SVDI), local least squares imputation (LLSI)

Datos imperfectos: Valores perdidos

Algorithm 3 k NNI algorithm.

```
function  $k$ NNI( $T$  - dataset with MVs,  $k$  - number of neighbors per instance to be chosen,  
 $D(x, y)$  - a distance or dissimilarity function of  $x$  and  $y$ ,  $S$  - the imputed version of  $T$ )  
  initialize:  $S = \{\}$   
  for each instance  $y_i$  in  $T$  do  
     $\hat{y}_i \leftarrow y_i$   
    if  $y_i$  contains any missing value then  
      Find set  $I_{K_i}$  with the  $k$  nearest instances to  $y_i$  from  $T$  using  $D$   
      for each missing value in attribute  $h$  of  $y_i$  do  
        if  $h$  is numerical then  
           $\hat{y}_{ih} = \left( \sum_{j \in I_{K_ih}} y_{jh} \right) / (|I_{K_ih}|)$   
        else  
           $\hat{y}_{ih} = \text{mode}(I_{K_ih})$   
        end if  
      end for  
    end if  
     $S \leftarrow \hat{y}_i$   
  end for  
  return  $S$   
end function
```

Datos imperfectos: Valores perdidos

Valores perdidos en clasificación. Ejemplo

Table 4.4 Average ranks for the Rule Induction Learning methods

	C45	Ripper	PART	Slipper	AQ	CN2	SRI	Ritio	Rules-6	Avg.	Ranks
IM	5	8.5	1	4	6.5	10	6.5	6	5	5.83	4
EC	2.5	8.5	6.5	1	6.5	5.5	6.5	6	1	4.89	3
KNNI	9	2.5	6.5	11	11	5.5	11.5	11	11	8.78	11
WKNNI	11	2.5	6.5	7	6.5	1	11.5	6	11	7.00	8
KMI	5	2.5	6.5	3	6.5	5.5	9.5	12	7.5	6.44	6
FKMI	7.5	2.5	6.5	10	2	5.5	1	2	3	4.44	1
SVMI	1	5.5	6.5	7	1	5.5	6.5	6	2	4.56	2
EM	13	12	6.5	7	12	13	3	6	4	8.50	10
SVDI	11	11	6.5	12	10	12	9.5	10	11	10.33	12
BPCA	14	13	13	7	13	14	13	13	13	12.56	14
LLSI	11	5.5	6.5	7	6.5	11	3	6	7.5	7.11	9
MC	7.5	8.5	6.5	2	6.5	5.5	3	6	7.5	5.89	5
CMC	5	8.5	12	13	3	5.5	6.5	1	7.5	6.89	7
DNI	2.5	14	14	14	14	5.5	14	14	14	11.78	13

Datos imperfectos: Valores perdidos

Valores perdidos en clasificación. Ejemplo

Table 4.5 Average ranks for the Black Box methods

	RBFN	RBFND	RBFNI	LOG	LVQ	MLP	NB	ν -SVM	C-SVM	SMO	Avg.	Ranks
IM	9	6.5	4.5	6	3.5	13	12	10	5.5	5.5	7.55	10
EC	1	1	1	3	7	8.5	10	13	1	2	4.75	1
KNNI	5	6.5	10.5	9	7	11	6.5	8	5.5	5.5	7.45	9
WKNNI	13	6.5	4.5	10	10	4.5	6.5	4.5	5.5	5.5	7.05	6
KMI	3.5	2	7	3	11	3	4.5	8	5.5	9	5.65	2
FKMI	12	6.5	10.5	3	1.5	4.5	11	4.5	5.5	3	6.20	3
SVMI	2	11.5	2.5	7.5	3.5	1.5	13	8	11	9	6.95	5
EM	3.5	6.5	13	12	12.5	10	4.5	4.5	10	11.5	8.80	11
SVDI	9	6.5	7	11	12.5	8.5	3	11.5	12	11.5	9.25	12
BPCA	14	14	14	13	7	14	2	2	13	13	10.60	14
LLSI	6	6.5	10.5	7.5	7	6.5	9	4.5	5.5	9	7.20	7
MC	9	6.5	10.5	3	7	6.5	8	11.5	5.5	5.5	7.30	8
CMC	9	13	2.5	3	1.5	1.5	14	14	5.5	1	6.50	4
DNI	9	11.5	7	14	14	12	1	1	14	14	9.75	13

Datos imperfectos: Limpieza ruido




Fig. 5.2 The three types of examples considered in this book: safe examples (labeled as *s*), *borderline* examples (labeled as *b*) and *noisy* examples (labeled as *n*). The continuous line shows the decision boundary between the two classes

Datos imperfectos: Limpieza ruido




Fig. 5.1 Examples of the interaction between classes: a) small disjuncts and b) overlapping between classes



Datos imperfectos: Limpieza ruido

Uso de técnicas de filtrado de ruido en clasificación

Los tres filtros de ruido se mencionan a continuación, los más conocidos, utilizan un esquema de votación para determinar qué casos para eliminar del conjunto de entrenamiento.:

- ***Ensemble Filter (EF)***
- ***Cross-Validated Committees Filter***
- ***Iterative-Partitioning Filter***


Datos imperfectos: Limpieza ruido

Ensemble Filter (EF)

- C.E. Brodley, M.A. Friedl. **Identifying Mislabeled Training Data**. *Journal of Artificial Intelligence Research* 11 (1999) 131-167.
- **Different learning algorithm** (C4.5, 1-NN and LDA) are used to create classifiers in several subsets of the training data that serve as noise filters for the training sets.
- Two main steps:
 1. For each learning algorithm, a **k-fold cross-validation** is used to tag each training example as **correct** (prediction = training data label) or **mislabeled** (prediction $\neq$ training data label).
 2. A **voting scheme** is used to identify the final set of noisy examples.
 - **Consensus voting**: it removes an example if it is misclassified by all the classifiers.
 - **Majority voting**: it removes an instance if it is misclassified by more than half of the classifiers.

Datos imperfectos: Limpieza ruido

Ensemble Filter (EF)



Datos imperfectos: Limpieza ruido

Ensemble Filter (EF)

Algorithm 4 EF algorithm.

function EF(T - dataset with MVs, Γ - number of subsets, μ - number of filters to be used, F - set of classifiers)

Split the training data set T into $T_i, i = 1 \dots \Gamma$ equal sized subsets

for each filter $F_x, x = 1 \text{ to } \mu$ **do**

for each subset T_i **do**

 Use $\{T_j, j \neq i\}$ to train F_x resulting in F_x^i

for each instance t in T_i **do**

 Classify t with every F_x^i

end for

end for

end for

for each instance t in T **do**

 Use a voting scheme to include t in T_N according to the classifications made by each filter F_x

end for

return $T - T_N$

end function

Datos imperfectos: Limpieza ruido

Cross-Validated Committees Filter (CVCF)

- S. Verbaeten, A.V. Assche. **Ensemble methods for noise elimination in classification problems**. *4th International Workshop on Multiple Classifier Systems (MCS 2003)*. LNCS 2709, Springer 2003, Guilford (UK, 2003) 317-325.
- CVCF is similar to EF → two main differences:
 1. **The same learning algorithm (C4.5)** is used to create classifiers in several subsets of the training data.

The authors of CVCF place special emphasis on using **ensembles of decision trees** such as C4.5 because they work well as a filter for noisy data.
 2. Each classifier built with the **k-fold cross-validation** is used to tag **ALL the training examples** (not only the test set) as **correct** (prediction = training data label) or **misabeled** (prediction $\neq$ training data label).


Datos imperfectos: Limpieza ruido

Iterative Partitioning Filter (IPF)

- T.M. Khoshgoftaar, P. Rebour. **Improving software quality prediction by noise filtering techniques**. *Journal of Computer Science and Technology* 22 (2007) 387-396.
- IPF removes noisy data in **multiple iterations** using **CVCF** until a stopping criterion is reached.
- The iterative process stops if, for a number of consecutive iterations, the number of noisy examples in each iteration is less than a percentage of the size of the training dataset.

Datos imperfectos: Limpieza ruido

Iterative Partitioning Filter (IPF)



Datos imperfectos: Limpieza ruido


Table 5.2 Filtering of class noise over three classic classifiers

		Pairwise class noise					Uniform random class noise				
		0%	5%	10%	15%	20%	0%	5%	10%	15%	20%
SVM	None	90.02	88.51	86.97	86.14	84.86	90.02	87.82	86.43	85.18	83.20
	EF	90.49	89.96	89.07	88.33	87.40	90.49	89.66	88.78	87.78	86.77
	CVCF	90.56	89.86	88.94	88.28	87.76	90.48	89.56	88.72	87.92	86.54
	IPF	90.70	90.13	89.37	88.85	88.27	90.58	89.79	88.97	88.48	87.37
Ripper	None	82.46	81.15	80.35	79.39	78.49	82.46	79.81	78.55	76.98	75.68
	EF	83.36	82.87	82.72	82.43	81.53	83.46	83.03	82.87	82.30	81.66
	CVCF	83.17	82.93	82.64	82.03	81.68	83.17	82.59	82.19	81.69	80.45
	IPF	83.74	83.59	83.33	82.72	82.44	83.74	83.61	82.94	82.94	82.48
C4.5	None	83.93	83.66	82.81	82.25	81.41	83.93	82.97	82.38	81.69	80.28
	EF	84.18	84.07	83.70	83.20	82.36	84.16	83.96	83.53	83.38	82.66
	CVCF	84.15	83.92	83.24	82.54	82.13	84.15	83.61	83.00	82.84	81.61
	IPF	84.44	84.33	83.92	83.38	82.53	84.44	83.89	83.84	83.50	82.72

Datos imperfectos: Limpieza ruido

Outliers


Son objetos/datos con características que son considerablemente diferentes de la mayoría de los otros datos/objetos del conjunto.



Datos imperfectos: Limpieza ruido

Outliers

- Valores anómalos, atípicos o extremos (*outliers*): son correctos aunque sean anómalos estadísticamente.
- Pueden ser un inconveniente para métodos basados en ajuste de pesos (p.e. AANN).
- Técnicas de **detección**:
 - Definir una distancia y ver los individuos con mayor distancia media al resto de individuos.
 - Clustering parcial: los datos se agrupan en clusters y los datos que queden fuera pueden considerarse outliers.





Calidad de Datos

Calidad de datos

Introducción al preprocesamiento de datos

Integración, limpieza y transformación

Datos imperfectos

Reducción de datos

Discretización

Selección de Características


Selección de Instancias

Comentarios finales




Reducción de datos

- ✱ Selecciona/extrae datos relevantes para la tarea de la minería de datos/extracción de información.




Reducción de datos

Feature Selection



Instance Selection



Discretization




Fig. 1.4 Forms of data reduction