



Universidad de Granada

DOBLE GRADO EN INGENIERÍA INFORMÁTICA Y
MATEMÁTICAS

METAHEURÍSTICAS

Trabajo final:
Sine Cosine Algorithm (SCA)

Autor: Jesús Muñoz Velasco

Curso 2025-2026

Índice

I	Descripción	3
1.	Introducción y contexto	3
2.	Fundamentos matemáticos	3
2.1.	Ecuaciones de actualización de posición	3
2.2.	Papel de cada parámetro	4
2.2.1.	El parámetro r_1 : transición exploración/explotación	4
2.2.2.	El parámetro r_2 : dirección del movimiento	5
2.2.3.	Los parámetros r_3 y r_4	6
2.3.	Geometría de la búsqueda	6
3.	Descripción del algoritmo	7
3.1.	Pseudocódigo	7
3.2.	Complejidad computacional	8
II	Implementación y estudio experimental	9
4.	Implementación del SCA	9
5.	Comparativa experimental: SCA frente a DE y PSO	9
5.1.	Dimensión $d = 10$	10
5.1.1.	Resultados al 100 % de evaluaciones	10
5.1.2.	Análisis de la convergencia a lo largo de las evaluaciones	11
5.2.	Dimensión $d = 30$	12
5.2.1.	Resultados al 100 % de evaluaciones	12
5.2.2.	Análisis de la convergencia a lo largo de las evaluaciones	13
5.3.	Dimensión $d = 50$	14
5.3.1.	Resultados al 100 % de evaluaciones	14
5.3.2.	Análisis de la convergencia a lo largo de las evaluaciones	16
5.4.	Análisis comparativo entre dimensiones	17
5.5.	Análisis por tipo de función	17
5.6.	Resumen y motivación de las mejoras	19
5.7.	Conclusiones generales sobre el SCA	19
III	Hibridación memética: SCA + Solis-Wets (SCA-LS)	21
6.	Motivación	21
7.	Descripción del SCA-LS	21
7.1.	Elección del intensificador: Solis-Wets	21
7.2.	Mecanismo de activación: detección de estancamiento	21
7.3.	Pseudocódigo	22

7.4. Parámetros del SCA-LS	22
8. Estudio experimental	23
8.1. Conclusiones sobre el SCA-LS	23
IV Mejoras al diseño del SCA: ASCA	24
9. Motivación y diseño de las mejoras	24
9.1. Mejora 1: Decaimiento no lineal de r_1 (coseno cuadrático)	24
9.1.1. Limitación encontrada	24
9.1.2. Solución propuesta	24
9.2. Mejora 2: Topología de vecindario en anillo (<i>ring lbest</i>)	25
9.2.1. Limitación encontrada	25
9.2.2. Solución propuesta	25
9.3. Mejora 3: Reinicio parcial adaptativo basado en diversidad	25
9.3.1. Limitación encontrada	25
9.3.2. Solución propuesta	26
9.4. Pseudocódigo del ASCA	26
9.5. Parámetros del ASCA	27
10. Estudio experimental comparativo: SCA-LS y ASCA	27
10.1. Dimensión $d = 10$	27
10.1.1. Resultados al 100 % de evaluaciones	27
10.1.2. Análisis de la convergencia a lo largo de las evaluaciones	29
10.2. Dimensión $d = 30$	30
10.2.1. Resultados al 100 % de evaluaciones	30
10.2.2. Análisis de la convergencia a lo largo de las evaluaciones	31
10.3. Dimensión $d = 50$	32
10.3.1. Resultados al 100 % de evaluaciones	32
10.3.2. Análisis de la convergencia a lo largo de las evaluaciones	34
10.4. Análisis crítico: por qué el ASCA no supera al SCA en este benchmark	35
10.5. Comparativa final de los tres algoritmos SCA	36
10.6. Conclusiones generales	36
V Anexo. Entorno de ejecución	38
Referencias	40

Parte I

Descripción

1. Introducción y contexto

El Sine Cosine Algorithm (SCA) es una metaheurística poblacional propuesta por Seyedali Mirjalili en 2016 en el artículo “*SCA: A Sine Cosine Algorithm for solving optimization problems*” (Knowledge-Based Systems, vol. 96, pp. 120–133). Su propuesta se enmarca dentro de la familia de algoritmos basados en modelos matemáticos, también denominados *math-inspired*, en contraposición a los inspirados en fenómenos biológicos o físicos.

El SCA parte de la idea de que las funciones seno y coseno poseen propiedades geométricas naturalmente útiles para la búsqueda: oscilan de forma periódica, pueden tomar valores superiores o inferiores al rango $[-1, 1]$ si se escalan convenientemente, y su comportamiento alternante facilita tanto la exploración global del espacio de búsqueda como la explotación local alrededor de soluciones prometedoras. Desde su publicación, el algoritmo ha atraído una atención considerable en la comunidad investigadora, siendo aplicado en campos tan diversos como la ingeniería eléctrica, el aprendizaje automático, el diagnóstico médico y la planificación de rutas.

2. Fundamentos matemáticos

2.1. Ecuaciones de actualización de posición

Cada candidato a solución (denominado agente de búsqueda) se representa como un vector $X^t \in \mathbb{R}^d$, donde d es la dimensión del problema y t el instante de iteración. En cada paso, el agente actualiza su posición dimensión a dimensión según:

$$X_i^{t+1} = \begin{cases} X_i^t + r_1 \cdot \sin(r_2) \cdot |r_3 P_i^t - X_i^t|, & \text{si } r_4 < 0,5 \\ X_i^t + r_1 \cdot \cos(r_2) \cdot |r_3 P_i^t - X_i^t|, & \text{si } r_4 \geq 0,5 \end{cases} \quad (1)$$

La ecuación puede factorizarse para entenderse mejor. Definiendo el **desplazamiento escalado** $\Delta_i^t = r_3 P_i^t - X_i^t$ (distancia ponderada al destino, con signo) y el **factor trigonométrico** $\phi = r_1 \cdot f(r_2)$ donde $f \in \{\sin, \cos\}$, la actualización anterior se reduce a:

$$X_i^{t+1} = X_i^t + \phi \cdot |\Delta_i^t| \quad (2)$$

El valor absoluto $|\Delta_i^t|$ garantiza que la magnitud del paso sea siempre positiva; el signo del movimiento queda determinado enteramente por ϕ (si $\phi > 0$ el agente avanza en dirección al destino y si $\phi < 0$ retrocede). Esta separación entre magnitud

y dirección es lo que le da al SCA su capacidad para cubrir simétricamente el espacio alrededor del punto destino.

Los cuatro parámetros tienen roles bien diferenciados:

Param.	Rango	Rol en la actualización
r_1	$[0, a]$ decreciente	Amplitud del movimiento (exploración/explotación)
r_2	$[0, 2\pi]$ aleatorio	Ángulo trigonométrico (dirección y signo del paso)
r_3	$[0, 2]$ aleatorio	Peso estocástico de la distancia al destino
r_4	$[0, 1]$ aleatorio	Selección equiprobable de seno o coseno

2.2. Papel de cada parámetro

2.2.1. El parámetro r_1 : transición exploración/explotación

r_1 es el parámetro de mayor importancia. Viene dado por¹

$$r_1(t) = a \left(1 - \frac{t}{T} \right), \quad a = 2 \quad (3)$$

Sustituyendo y derivando en esta ecuación obtenemos


$$\begin{aligned} r_1(0) &= a \\ r_1(T) &= 0 \end{aligned} \quad r_1'(t) = -\frac{a}{T}$$

por lo que r_1 comienza con el valor a y va descendiendo linealmente hasta 0 a lo largo de las iteraciones.

La Figura 1 muestra su trayectoria y el umbral $r_1 = 1$ que separa las dos regiones:

-) **Exploración** ($r_1 \geq 1$, primeras iteraciones): el factor $r_1 \cdot f(r_2)$ puede superar en módulo la distancia $|\Delta_i^t|$, de modo que el agente sobrepasa el punto destino y explora regiones lejanas del espacio.
-) **Explotación** ($r_1 < 1$): el factor queda acotado y el agente se mueve dentro del segmento que lo une con el destino, refinando la solución progresivamente.

¹El parámetro a se toma igual a 2 para que el espacio de búsqueda alrededor del punto destino quede completamente cubierto desde el principio (está acotado por el doble de la distancia inicial), además de que con este valor, el umbral $r_1 = 1$ se alcanza exactamente en $t = T/2$ dividiendo las iteraciones perfectamente por la mitad para exploración y explotación. Aún así se puede tomar otro valor para darle más relevancia a alguna de estas fases.



2.2.2. El parámetro r_2 : dirección del movimiento

r_2 es el ángulo de la función trigonométrica, que toma valores aleatorios uniformemente en $[0, 2\pi]$. Su efecto se aprecia analizando el signo de $\sin(r_2)$ y $\cos(r_2)$:

-) Cuando $f(r_2) > 0$ el desplazamiento es positivo: el agente se mueve en la dirección de $P_i - X_i$ (hacia el destino o más allá).
-) Cuando $f(r_2) < 0$ el desplazamiento es negativo: el agente se aleja del destino en esa dimensión.

La Figura 2 representa $r_1 \cdot \sin(r_2)$ y $r_1 \cdot \cos(r_2)$ para dos valores representativos de r_1 , mostrando cómo la amplitud se contrae al pasar de la fase exploratoria a la explotadora.




Figura 2: Factor trigonométrico $r_1 \cdot f(r_2)$ en función del ángulo r_2 para $r_1 = 2$ (exploración, azul) y $r_1 = 0,5$ (explotación, naranja). La banda sombreada $[-1, 1]$ delimita el régimen de explotación: cuando el factor queda dentro de ella, el agente no sobrepasa el destino.

2.2.3. Los parámetros r_3 y r_4

$r_3 \in [0, 2]$ actúa como un peso estocástico sobre el punto destino. Si $r_3 > 1$, el término $r_3 P_i^t$ desplaza el destino efectivo más allá de su posición real, ampliando artificialmente la distancia $|\Delta_i^t|$ y favoreciendo pasos más largos (efecto exploratorio secundario). Si $r_3 < 1$, atenúa la influencia del destino. Este mecanismo introduce diversidad adicional incluso en la fase de explotación, reduciendo el riesgo de convergencia en masa hacia un único punto.

$r_4 \in [0, 1]$ selecciona con probabilidad $1/2$ entre la función seno y la función coseno. Ambas funciones tienen la misma amplitud máxima, pero sus ceros y máximos están desfasados $\pi/2$ radianes. Emplearlas con igual probabilidad garantiza que el muestreo de direcciones de movimiento sea más uniforme que si se usase una sola función, mejorando la isotropía de la búsqueda en el espacio.

2.3. Geometría de la búsqueda

La ecuación (2) actualiza cada dimensión de forma independiente. En una dimensión fija j , el nuevo valor del agente es:

$$X_j^{t+1} = X_j^t + \phi \cdot |\Delta_j^t|, \quad |\Delta_j^t| = |r_3 P_j^t - X_j^t|, \quad \phi = r_1 \cdot f(r_2)$$

donde $|\Delta_j^t| \geq 0$ siempre. Por tanto, el signo y la magnitud del desplazamiento quedan determinados exclusivamente por ϕ , que puede tomar cualquier valor real en $[-r_1, r_1]$. Esto da lugar a cuatro regímenes de movimiento, representados en la Figura 3:

-) $\phi \in (0, 1)$: explotación positiva. El agente se desplaza hacia P_j^t sin alcanzarlo.
-) $\phi \in (-1, 0)$: explotación negativa. El agente retrocede levemente desde P_j^t , pero permanece cerca.
-) $\phi > 1$: exploración positiva. El agente sobrepasa P_j^t y aterriza más allá.
-) $\phi < -1$: exploración negativa. El agente da un salto largo en sentido opuesto a P_j^t .

Como ya se ha comentado, los casos $|\phi| < 1$ constituyen la zona de explotación y los casos $|\phi| > 1$ la zona de exploración. El umbral es exactamente $|\phi| = 1$, que corresponde al punto P_j^t escalado por r_3 . Nótese que las zonas de exploración son simétricas a ambos lados del agente, lo que garantiza que la búsqueda no tenga sesgo de dirección.




Figura 3: Cuatro regímenes de movimiento en una dimensión j . La banda amarilla ($|\phi| < 1$) es la zona de explotación: el agente aterriza entre X_j^t y el destino (o su simétrico). Las bandas azul y verde ($|\phi| > 1$) son zonas de exploración: el agente sobrepasa el destino en alguno de los dos sentidos. La simetría horizontal garantiza la ausencia de sesgo direccional.

Desde una perspectiva probabilística, el valor esperado de $|\phi|$ decrece con t al hacerlo r_1 , ya que

$$E[|\phi|] = r_1 \cdot E[|f(r_2)|] = r_1 \cdot \frac{2}{\pi}$$

Esto convierte la dinámica colectiva en un proceso de enfriamiento implícito: al inicio los agentes realizan saltos amplios y divergentes conforme avanza la búsqueda los pasos se acortan y la población converge hacia el punto destino con precisión creciente. El factor $2/\pi \approx 0,637$ implica además que, en promedio, el umbral efectivo de exploración/explotación se alcanza antes de que r_1 llegue a 1, lo que supone una transición algo más temprana de lo que la ecuación (3) sugiere a simple vista.

3. Descripción del algoritmo

3.1. Pseudocódigo

```

1  (* Parámetros de entrada: N (población), T (iteraciones máx.), a=2 *)
2  Inicializar población X = {X_1, X_2, ..., X_N} aleatoriamente en [lb, ub]^d
3  Evaluar fitness f(X_i) para cada agente i
4  P ← argmin f(X_i)      (* mejor solución: punto destino *)
5
6  t ← 1
7  Mientras t ≤ T hacer
8      (* Calcular parámetro adaptativo r1 *)
9      r1 ← a - t * (a / T)
10
11     Para cada agente i = 1 hasta N hacer
12         Para cada dimensión j = 1 hasta d hacer
13             (* Generar parámetros aleatorios *)
14             r2 ← aleatorio en [0, 2*pi]
15             r3 ← aleatorio en [0, 2]
16             r4 ← aleatorio en [0, 1]
17
18             (* Actualizar posición según Ec. (1) *)
19             Si r4 < 0.5 entonces
20                 X_i[j] ← X_i[j] + r1 * sin(r2) * |r3*P[j] - X_i[j]|
21             Si no
22                 X_i[j] ← X_i[j] + r1 * cos(r2) * |r3*P[j] - X_i[j]|
23             Fin Si
24
25             (* Aplicar límites del espacio de búsqueda *)
26             X_i[j] ← max(lb[j], min(ub[j], X_i[j]))
27         Fin Para
28     Fin Para
29

```



```
30  (* Evaluar fitness y actualizar punto destino *)
31  Para cada agente i = 1 hasta N hacer
32      Evaluar f(X_i)
33      Si f(X_i) < f(P) entonces
34          P <- X_i
35      Fin Si
36  Fin Para
37
38  t <- t + 1
39  Fin Mientras
40
41  Retornar P  (* mejor solución encontrada *)
```

Código Fuente 1: Pseudocódigo del Sine Cosine Algorithm (SCA)

3.2. Complejidad computacional

La complejidad por iteración es $\mathcal{O}(N \cdot d)$, equivalente a la de otros algoritmos poblacionales estándar como PSO o GWO. El número total de evaluaciones de la función objetivo es $N \times T$, lo que resulta razonable para problemas de mediana escala.

Parte II

Implementación y estudio experimental

4. Implementación del SCA

La implementación del SCA se ha realizado en C++ sobre el *benchmark* CEC2017 [7], integrándola en el repositorio de Daniel Molina [8]. La API de evaluación ofrece una interfaz simplificada que gestiona internamente el conteo de evaluaciones y el almacenamiento de resultados en los *milestones* requeridos por el protocolo experimental.

Los parámetros de la implementación se recogen en la Tabla 1. Se ha optado por $N = 30$ agentes, que es el valor habitual que se suele usar para CEC2017 para mejorar la comparativa con los otros algoritmos. El criterio de parada establecido es $10\,000 \times d$ evaluaciones y el número de repeticiones se ha fijado a $T = 10$ (frente al estándar de 50) para acotar los tiempos de ejecución.

Parámetro	Valor	Descripción
N	30	Tamaño de población
a	2,0	Amplitud inicial de r_1
$T_{\text{máx}}$	$10\,000 \times d$	Presupuesto máximo de evaluaciones
T	10	Repeticiones por función
Rango	$[-100, 100]^d$	Dominio de búsqueda
Dimensiones	10, 30, 50	Valores de d evaluados

Tabla 1: Parámetros de la implementación del SCA para CEC2017.

5. Comparativa experimental: SCA frente a DE y PSO

En esta sección se analiza el comportamiento del SCA frente a dos algoritmos clásicos de referencia: la *Differential Evolution* (DE) y el *Particle Swarm Optimization* (PSO). Ambos están disponibles en la base de datos de TacoLab [9] con el mismo protocolo experimental. La comparativa se realiza sobre las 30 funciones del benchmark CEC2017 en tres dimensiones ($d \in \{10, 30, 50\}$), midiendo el error medio respecto al óptimo conocido en distintos *milestones* del presupuesto de evaluaciones ($10\,000 \times d$ en total).

5.1. Dimensión $d = 10$

5.1.1. Resultados al 100 % de evaluaciones

La Tabla 2 muestra los errores medios al usar el 100 % de las evaluaciones disponibles (10^5 evaluaciones para $d = 10$). Las celdas corresponden al error medio sobre 10 ejecuciones (cuanto menor sea dicho valor mejor será el algoritmo).

Tabla 2: Error medio al 100 % de evaluaciones ($d = 10$, 10^5 evaluaciones). Mejor resultado por función destacado en negrita.

Función	DE	PSO	SCA
F01	0.000e+00	5.255e+07	5.431e+08
F02	0.000e+00	1.000e+00	9.754e+05
F03	0.000e+00	1.989e+03	6.766e+02
F04	1.105e-04	4.684e+01	2.693e+01
F05	1.151e+02	3.212e+01	4.856e+01
F06	3.460e+01	1.001e+01	1.405e+01
F07	3.848e+01	4.275e+01	6.702e+01
F08	2.983e+01	2.203e+01	3.716e+01
F09	1.938e+02	5.686e+01	8.651e+01
F10	3.597e+02	1.077e+03	1.197e+03
F11	1.942e-02	3.843e+01	7.486e+01
F12	4.931e+00	2.517e+06	7.962e+06
F13	5.988e+00	8.409e+03	2.355e+04
F14	5.240e-02	9.993e+01	1.619e+02
F15	6.060e-02	2.066e+03	5.189e+02
F16	4.561e+02	1.415e+02	1.448e+02
F17	2.350e+01	6.497e+01	6.609e+01
F18	3.630e-02	1.484e+04	7.227e+04
F19	5.192e-03	3.220e+03	5.461e+02
F20	3.837e+02	8.444e+01	9.014e+01
F21	1.889e+02	1.320e+02	1.509e+02
F22	1.005e+02	7.740e+01	1.512e+02
F23	8.098e+02	3.304e+02	3.513e+02
F24	1.000e+02	1.810e+02	3.824e+02
F25	4.040e+02	4.478e+02	4.537e+02
F26	2.706e+02	3.729e+02	4.519e+02
F27	3.897e+02	4.134e+02	4.010e+02
F28	3.517e+02	4.698e+02	4.734e+02
F29	2.375e+02	3.193e+02	3.363e+02
F30	8.051e+04	6.352e+05	4.864e+05
Mejor en	22	8	0

El DE obtiene el mejor resultado en 22 de las 30 funciones, el PSO en 8, y el SCA en ninguna. Este resultado, aunque no beneficia a SCA, es coherente con las limitaciones teóricas identificadas más adelante (Sección 5.6): el decrecimiento lineal

de r_1 activa la explotación demasiado pronto, y la ausencia de memoria colectiva entre agentes dificulta la convergencia en funciones multimodales.

Conviene destacar, sin embargo, que en F03, F04, F19 y F27 el SCA se aproxima al rendimiento del PSO, lo que sugiere que en funciones con estructura geométrica favorable a los movimientos trigonométricos el algoritmo se defiende razonablemente.

5.1.2. Análisis de la convergencia a lo largo de las evaluaciones




Figura 4: Evolución del número de funciones para las que cada algoritmo resulta mejor en función del porcentaje de las evaluaciones consumidas ($d = 10, 30$ funciones).

La Figura 4 revela una dinámica especialmente interesante que los resultados finales por sí solos ocultan. Al 1 % de las evaluaciones (los primeros 10^3 de los 10^5 evaluaciones disponibles), el SCA gana en 15 de las 30 funciones, superando tanto al DE (4 victorias) como al PSO (11 victorias). Esta ventaja inicial refleja la alta capacidad exploratoria del SCA en las primeras iteraciones, cuando r_1 es próximo a $a = 2$ y los agentes se dispersan ampliamente por el espacio de búsqueda.

Sin embargo, a partir del 5 % de las evaluaciones la situación se invierte: el SCA pierde todas sus ventajas y al 30 % ya no gana en ninguna función. Este colapso es la manifestación directa de las limitaciones ya identificadas: el decrecimiento lineal de r_1 reduce la amplitud de movimiento demasiado rápido, y sin un mecanismo de escape local, la población converge de forma prematura a óptimos locales (impidiéndole alcanzar óptimos globales).

El DE, por el contrario, muestra un comportamiento opuesto: al principio cuenta con pocas victorias (4 al 1 %) y va mejorando progresivamente hasta estabilizarse en torno a 21-23 victorias. Esto refleja su estrategia de intensificación gradual, basada en diferencias entre vectores de la población que son más informativas conforme los agentes convergen. El PSO ocupa una posición intermedia, con buena exploración

inicial (11-15 victorias entre el 1 % y el 5 %) y una posición estable de 7-9 victorias al final.

La Tabla 3 condensa la evolución de las victorias a lo largo del presupuesto para los tres algoritmos en $d = 10$.

Tabla 3: Número de funciones ganadas por algoritmo en *milestones* representativos ($d = 10$).

Algoritmo	1 %	5 %	10 %	20 %	50 %	100 %
DE	4	10	22	23	22	22
PSO	11	15	7	6	8	8
SCA	15	5	1	1	0	0

5.2. Dimensión $d = 30$

Con el salto a $d = 30$, el número disponible de evaluaciones asciende a 3×10^5 , pero el espacio de búsqueda crece exponencialmente. Este cambio de escala tiene un impacto cualitativo importante en el comportamiento relativo de los tres algoritmos.

5.2.1. Resultados al 100 % de evaluaciones

Tabla 4: Error medio al 100 % del presupuesto de evaluaciones ($d = 30$, 3×10^5 evaluaciones). Mejor resultado por función destacado en negrita.

Función	DE	PSO	SCA
F01	4.909e+04	4.175e+09	1.203e+10
F02	1.309e+19	1.000e+00	1.019e+33
F03	3.481e+03	5.453e+04	3.329e+04
F04	8.430e+01	1.183e+03	9.326e+02
F05	2.015e+02	2.170e+02	2.775e+02
F06	6.320e+00	3.694e+01	4.951e+01
F07	2.334e+02	3.596e+02	4.457e+02
F08	1.894e+02	1.745e+02	2.465e+02
F09	6.530e+01	2.842e+03	4.804e+03
F10	3.764e+03	6.938e+03	7.126e+03
F11	7.958e+01	1.207e+03	1.094e+03
F12	3.258e+05	3.586e+08	1.130e+09
F13	1.536e+02	4.508e+07	4.346e+08
F14	7.100e+01	3.059e+05	1.187e+05
F15	6.256e+01	2.737e+05	1.389e+07
F16	1.319e+03	1.568e+03	2.024e+03
F17	4.809e+02	4.725e+02	7.155e+02
F18	6.122e+01	2.170e+06	2.743e+06
F19	3.572e+01	1.260e+06	2.300e+07

Tabla 4 (continuación)

Función	DE	PSO	SCA
F20	2.751e+02	4.621e+02	5.654e+02
F21	3.255e+02	4.113e+02	4.480e+02
F22	1.002e+02	1.027e+03	5.436e+03
F23	5.346e+02	6.404e+02	7.062e+02
F24	6.059e+02	7.095e+02	7.698e+02
F25	3.870e+02	6.864e+02	6.815e+02
F26	4.038e+02	3.369e+03	4.550e+03
F27	4.925e+02	8.068e+02	6.984e+02
F28	3.943e+02	1.105e+03	1.037e+03
F29	1.025e+03	1.409e+03	1.734e+03
F30	3.657e+03	1.359e+07	7.415e+07
Mejor en	27	3	0

Se puede ver que para $d = 30$, la brecha con respecto a $d = 10$ se amplía notablemente. El DE domina en 27 de las 30 funciones (frente a 21 en $d = 10$), el PSO retiene solo 3 victorias, y el SCA no gana en ninguna. Pese a ello, en F03 el SCA ($3,33 \times 10^4$) se coloca entre el PSO ($5,45 \times 10^4$) y el DE ($3,48 \times 10^3$), y en F27 supera al PSO ($8,07 \times 10^2$ vs. $6,98 \times 10^2$), la única función de composición donde el SCA obtiene la segunda posición. F02 sigue siendo el caso donde el PSO arrasa al DE y al SCA gracias a su mecanismo de inercia, pero para el resto del benchmark el DE consolida su superioridad con el aumento de dimensión.

5.2.2. Análisis de la convergencia a lo largo de las evaluaciones




Figura 5: Evolución del número de funciones ganadas por cada algoritmo en función del porcentaje de las evaluaciones consumidas ($d = 30$, 30 funciones).

La Figura 5 muestra un patrón cualitativamente distinto al de $d = 10$. Al 1 % de las evaluaciones el PSO domina con 23 victorias, el DE obtiene solo 4, y el SCA desciende a 3 victorias, perdiendo la ventaja exploratoria inicial que mostraba en baja dimensión. Este comportamiento refleja que, en $d = 30$, el espacio de búsqueda es tan amplio que la dispersión trigonométrica del SCA resulta insuficiente para cubrir las regiones prometedoras en las primeras evaluaciones.

A partir del 5 % de las evaluaciones la situación se invierte bruscamente: el DE sube a 21 victorias y el PSO cae a 8, mientras que el SCA ya solo gana en una función. Desde el 10 % en adelante el SCA no gana en ninguna, confirmando que la convergencia prematura se adelanta a mayor dimensión. El PSO mantiene una cuota baja (2–3 victorias) en la fase final gracias a su velocidad de partícula, que le confiere algo de inercia exploratoria residual.

Tabla 5: Número de funciones ganadas por algoritmo en *milestones* representativos ($d = 30$).

Algoritmo	1 %	5 %	10 %	20 %	50 %	100 %
DE	4	21	26	27	28	27
PSO	23	8	4	3	2	3
SCA	3	1	0	0	0	0

5.3. Dimensión $d = 50$

En $d = 50$ el número de evaluaciones es de 5×10^5 evaluaciones, pero el problema de la dimensionalidad es más notable. Los resultados confirman y amplifican las tendencias observadas en $d = 30$.

5.3.1. Resultados al 100 % de evaluaciones

Tabla 6: Error medio al 100 % del presupuesto de evaluaciones ($d = 50$, 5×10^5 evaluaciones). Mejor resultado por función destacado en negrita.

Función	DE	PSO	SCA
F01	2.039e+08	1.823e+10	4.200e+10
F02	5.158e+52	1.000e+00	4.894e+61
F03	7.597e+04	1.008e+05	1.009e+05
F04	2.322e+02	4.091e+03	6.231e+03
F05	3.978e+02	4.328e+02	5.500e+02
F06	1.180e+01	5.450e+01	6.641e+01
F07	4.781e+02	8.197e+02	9.024e+02
F08	4.070e+02	4.077e+02	5.312e+02
F09	3.756e+03	1.620e+04	2.111e+04
F10	1.127e+04	1.295e+04	1.341e+04
F11	2.173e+02	3.151e+03	4.689e+03

Tabla 6 (continuación)

Función	DE	PSO	SCA
F12	1.382e+08	6.062e+09	1.075e+10
F13	2.726e+04	5.262e+08	2.768e+09
F14	1.683e+02	1.558e+06	1.931e+06
F15	5.090e+02	5.790e+06	3.290e+08
F16	3.047e+03	2.745e+03	3.815e+03
F17	1.827e+03	1.652e+03	2.508e+03
F18	2.420e+04	1.203e+07	1.513e+07
F19	1.322e+02	1.336e+07	1.926e+08
F20	9.384e+02	1.282e+03	1.754e+03
F21	6.177e+02	6.655e+02	7.709e+02
F22	1.707e+02	1.258e+04	1.384e+04
F23	8.435e+02	1.098e+03	1.226e+03
F24	8.850e+02	1.206e+03	1.252e+03
F25	5.667e+02	3.069e+03	3.419e+03
F26	5.745e+02	7.890e+03	9.011e+03
F27	5.765e+02	1.744e+03	1.678e+03
F28	5.013e+02	3.468e+03	3.597e+03
F29	2.218e+03	3.566e+03	4.390e+03
F30	2.386e+06	3.374e+08	4.810e+08
Mejor en	27	3	0

El panorama $d = 50$ replica el de $d = 30$ en cuanto a recuento de victorias: DE gana en 27 funciones, PSO en 3 (F02, F16, F17) y el SCA en ninguna. Sin embargo, las magnitudes de los errores son distintas. En F15, el SCA alcanza un error de $3,29 \times 10^8$, frente a $5,09 \times 10^2$ del DE (seis órdenes de magnitud de diferencia). Del mismo modo, en F13 la brecha es de cinco órdenes ($2,77 \times 10^9$ vs. $2,73 \times 10^4$), y en F02 el error del SCA ($4,89 \times 10^{61}$) es enorme. Estas cifras reflejan la inestabilidad numérica que surge cuando el decrecimiento de r_1 no frena la explosión de valores en funciones mal condicionadas de alta dimensión.

Cabe destacar que para $d = 50$ el PSO amplía ligeramente su posición competitiva en el grupo de funciones multimodales: F16 y F17 pasan a ser victorias del PSO (en $d = 10$ y $d = 30$ eran victorias del DE para F16 o del PSO para F17 respectivamente), lo que sugiere que la memoria de velocidad del PSO escala algo mejor que las diferencias vectoriales del DE en estas funciones específicas.

5.3.2. Análisis de la convergencia a lo largo de las evaluaciones




Figura 6: Evolución del número de funciones ganadas por cada algoritmo en función del porcentaje del presupuesto consumido ($d = 50$, 30 funciones).

Tabla 7: Número de funciones ganadas por algoritmo en *milestones* representativos ($d = 50$).

Algoritmo	1 %	5 %	10 %	20 %	50 %	100 %
DE	5	19	26	28	26	27
PSO	21	9	4	2	4	3
SCA	4	2	0	0	0	0

La dinámica de la Figura 6 reproduce en $d = 50$ el mismo patrón cualitativo que en $d = 30$: el PSO lidera al 1 % del presupuesto (21 victorias) gracias a su componente de velocidad que le permite explorar rápidamente en la fase inicial, el DE se impone a partir del 5 % y el SCA desaparece del ranking desde el 10 %. El SCA solo mantiene 2–4 victorias en el primer 5 % de las evaluaciones disponibles, demostrando que incluso la exploración inicial se ve seriamente comprometida cuando la dimensión triplica la del escenario para el que el algoritmo original fue concebido.

5.4. Análisis comparativo entre dimensiones

Tabla 8: Número de victorias al 100 % del presupuesto por algoritmo y dimensión.

Algoritmo	$d = 10$	$d = 30$	$d = 50$
DE	21	27	27
PSO	9	3	3
SCA	0	0	0

La Tabla 8 condensa el efecto de la dimensión en el balance de victorias finales. Destacan tres tendencias:

1. **El DE escala mejor que PSO y SCA.** El número de victorias del DE crece de 21 a 27 al pasar de $d = 10$ a $d = 30$, y se mantiene en 27 a $d = 50$. Esto indica que la mutación diferencial, basada en diferencias entre vectores de la población, extrae información estadística más útil conforme la población converge en espacios de mayor dimensión.
2. **El PSO sufre una caída severa.** Las 9 victorias a $d = 10$ se reducen a 3 en ambas dimensiones superiores. Aunque la componente de velocidad del PSO permite una exploración inicial rápida (domina al 1 % de las evaluaciones disponibles en $d = 30$ y $d = 50$), su mecanismo de actualización centrado en el mejor global (*gbest*) provoca convergencia temprana igual o peor que el SCA en el largo plazo.
3. **El SCA no escala.** Sus 0 victorias son constantes en las tres dimensiones. Si bien en $d = 10$ el SCA mostraba potencial exploratorio real en las primeras iteraciones (15 victorias al 1 %), ese potencial desaparece en $d = 30$ y queda reducido a 4 victorias al 1 % en $d = 50$. La razón es estructural: el SCA actualiza cada dimensión de forma independiente usando el mismo punto destino global, sin ningún mecanismo de adaptación al paisaje de aptitud. En dimensiones altas, la probabilidad de que la actualización trigonométrica simultánea de todas las dimensiones produzca un movimiento útil decrece notablemente como se puede ver.

El análisis por *milestones* (Tablas 3, 5 y 7) revela un patrón consistente: a medida que aumenta d , el SCA pierde la ventaja exploratoria inicial de forma más pronunciada, colapsando desde el 10 % de las evaluaciones independientemente de la dimensión. Esto refuerza la conclusión de la Sección 5: la mejora prioritaria para el SCA es introducir un mecanismo de memoria colectiva o reinicio de diversidad que prevenga el colapso temprano, especialmente crítico en alta dimensión.

5.5. Análisis por tipo de función

El benchmark CEC2017 agrupa las 30 funciones en cuatro categorías. El análisis de los resultados obtenidos en las tres dimensiones ($d \in \{10, 30, 50\}$) permite caracterizar el comportamiento del SCA con mayor granularidad, más allá del recuento

global de victorias.

-) **F01–F03: Funciones unimodales.** El DE domina claramente en todas las dimensiones, alcanzando errores nulos o próximos a cero a $d = 10$. El SCA muestra su mayor debilidad en este grupo: en F01 (esfera desplazada) el error en $d = 10$ es 8 órdenes de magnitud mayor que el del DE, lo que evidencia que el mecanismo de explotación lineal es insuficiente para funciones convexas. Con todo, en F03 el SCA supera al PSO en $d = 10$ ($6,77 \times 10^2$ vs. $1,99 \times 10^3$) y queda entre ambos competidores en $d = 30$, sugiriendo que las funciones de Schwefel desplazadas tienen una estructura favorece la oscilación trigonométrica en baja dimensión. Al crecer la dimensión, la ventaja relativa en F03 se mantiene, aunque la brecha absoluta con el DE se amplía notablemente.
-) **F04–F10: Funciones multimodales simples.** Es el grupo donde el SCA se comporta de forma más competitiva en baja dimensión. En F09 (Schwefel modificada) a $d = 10$, el SCA supera al DE ($8,65 \times 10^1$ vs. $1,94 \times 10^2$), indicando que la oscilación sinusoidal es útil para navegar paisajes con muchos óptimos locales de magnitud comparable. Sin embargo, este comportamiento no escala: en dimensión $d = 30$, la brecha en F09 se amplía hasta que el SCA comete un error 73 veces mayor que el DE, y en $d = 50$ esta diferencia llega a un factor de 5,6. La explicación es estructural: en alta dimensión, la probabilidad de que todos los componentes del vector de posición se actualicen favorablemente de forma simultánea decrece exponencialmente.
-) **F11–F20: Funciones híbridas.** El SCA muestra sus peores resultados relativos en este grupo en todas las dimensiones. Las funciones híbridas combinan regiones con características dispares, lo que requiere tanto exploración global como explotación local precisa. La ausencia de búsqueda local en el SCA impide refinar las soluciones parciales encontradas en cada subcomponente. En $d = 10$, F12 y F18 presentan errores del SCA entre 3 y 4 órdenes de magnitud superiores al DE. En $d = 30$ y $d = 50$, estas brechas se amplifican aún más, alcanzando hasta 6 órdenes de magnitud en F15 y F19. La convergencia prematura atrapa a los agentes en la parte del paisaje de cada subcomponente que encuentran primero, impidiéndoles recomponerlo globalmente.
-) **F21–F30: Funciones de composición.** Son las que presentan el paisaje de aptitud más complejo, con múltiples óptimos globales de distinta naturaleza. El SCA obtiene sus mejores resultados relativos en este grupo: en $d = 10$, supera al PSO en F27 y se aproxima en F23 y F29. En $d = 30$, la única victoria absoluta del SCA es precisamente F27. La diversidad mantenida por la oscilación trigonométrica ayuda a evitar la peor cuenca local, aunque no es suficiente para explorar de forma eficiente cuando el número de cuencas crece con la dimensión. En $d = 50$, el SCA ya no supera al PSO en ninguna función de este grupo, confirmando que la estrategia de destino global único no puede mantener múltiples frentes de búsqueda al crecer el espacio.

En resumen, el SCA afronta las distintas categorías con una eficacia decreciente a medida que aumentan la complejidad del paisaje y la dimensión: tolerable en funciones unimodales de baja dimensión, competitivo puntualmente en multimodales simples, y claramente insuficiente en híbridas y de composición a dimensiones medias

o altas.

5.6. Resumen y motivación de las mejoras

La Tabla 3 condensa la evolución de las victorias a lo largo del presupuesto para $d = 10$. Las tablas equivalentes para $d = 30$ y $d = 50$ (Tablas 5 y 7) muestran el mismo patrón cualitativo amplificado.

Del análisis conjunto de las tres dimensiones se extraen tres conclusiones que motivan directamente las propuestas de mejora desarrolladas en las secciones siguientes:

1. **El SCA explora bien pero no explota.** La ventaja exploratoria inicial (15 victorias al 1 % de las evaluaciones disponibles en $d = 10$, con el patrón repitiéndose análogamente en otras dimensiones) se pierde completamente en la fase de explotación. El decrecimiento lineal de r_1 es demasiado agresivo para funciones multimodales y el algoritmo carece de un mecanismo de intensificación local.
2. **La convergencia prematura es el problema principal.** A partir del 10 % de las evaluaciones el SCA prácticamente no mejora sus posiciones relativas en ninguna dimensión, indicando que la población colapsa hacia óptimos locales antes de haber agotado el presupuesto disponible. Este fenómeno se adelanta al crecer la dimensión.
3. **La escasa memoria colectiva limita la cooperación.** Todos los agentes convergen al mismo punto destino P , lo que reduce la diversidad más rápido de lo deseado e impide la exploración simultánea de múltiples cuencas. Una topología de vecindario permitiría mantener múltiples frentes de búsqueda semi-independientes.

Estas tres debilidades están directamente asociadas a las tres mejoras implementadas en el ASCA (Sección 9): decrecimiento no lineal de r_1 , topología de vecindario en anillo, y reinicio parcial adaptativo basado en diversidad.

5.7. Conclusiones generales sobre el SCA

El estudio experimental presentado en esta parte permite extraer un conjunto de conclusiones sólidas sobre el comportamiento del SCA en el benchmark CEC2017:

1. **Buen explorador, mal explotador.** El SCA destaca en la fase inicial de la búsqueda gracias a los amplios movimientos trigonométricos que permiten cubrir rápidamente el espacio de búsqueda cuando r_1 es grande. Sin embargo, el decrecimiento lineal de r_1 activa la explotación demasiado pronto y sin la precisión necesaria, lo que impide refinar las soluciones encontradas.
2. **Convergencia prematura sistemática.** En las tres dimensiones estudiadas, el SCA colapsa a partir del 10 % del presupuesto de evaluaciones. Este comportamiento es independiente de la dimensión y refleja una limitación estructural del algoritmo: una vez que r_1 cae por debajo de 1, la amplitud de movimiento es insuficiente para escapar de los óptimos locales en los que la población ha convergido.

3. **Mala escalabilidad dimensional.** La ventaja exploratoria inicial, que en $d = 10$ se traduce en 15 victorias al 1 % del presupuesto, desaparece casi completamente en $d = 30$ (3 victorias al 1 %) y en $d = 50$ (4 victorias). El mecanismo de actualización independiente por dimensiones, sin ninguna correlación entre ellas, no es capaz de producir movimientos útiles en espacios de alta dimensionalidad.
4. **Comportamiento diferenciado por tipo de función.** El SCA se defiende razonablemente en funciones unimodales sencillas y puntualmente en algunas multimodales con estructura favorable (F09, F27), pero fracasa de forma sistemática en funciones híbridas y de composición, que son precisamente las más representativas de problemas reales complejos.
5. **Potencial de mejora mediante hibridación.** Los resultados de esta parte sugieren claramente que el SCA puede beneficiarse de un mecanismo de búsqueda local que intensifique la explotación cuando la exploración se agota, además de modificaciones estructurales que preserven la diversidad a lo largo del presupuesto completo. Estas dos líneas de mejora se desarrollan respectivamente en la Parte III (SCA-LS) y la Parte IV (ASCA).

Parte III

Hibridación memética: SCA + Solis-Wets (SCA-LS)

6. Motivación

El análisis experimental del SCA original (Parte II) reveló un patrón claro: el algoritmo exhibe una buena capacidad exploratoria en las primeras iteraciones pero colapsa prematuramente en la fase de explotación, sin llegar a refinar las soluciones encontradas. La conclusión natural es hibridarlo con una búsqueda local que actúe precisamente cuando el SCA se estanca, redistribuyendo así el número de evaluaciones de forma más eficiente.

La estrategia elegida sigue el paradigma de los *algoritmos meméticos* (MA, *Meme-tic Algorithms*): una metaheurística poblacional como explorador global combinada con un método de búsqueda local como intensificador. En concreto, se propone el algoritmo **SCA-LS**, que integra el SCA con el método de **Solis-Wets** (SW) [10] como intensificador local activado por estancamiento.

7. Descripción del SCA-LS

7.1. Elección del intensificador: Solis-Wets

El método de Solis-Wets es un optimizador local estocástico sin gradiente diseñado para funciones continuas. Genera perturbaciones gaussianas alrededor de la solución actual, acepta el nuevo punto si mejora el fitness, y ajusta adaptativamente la desviación típica σ en función del historial de éxitos y fracasos. Sus propiedades clave para esta hibridación son:

-) **Sin gradiente**: compatible con todas las funciones del benchmark CEC2017, incluidas las no diferenciables.
-) **Adaptativo**: la escala de perturbación se ajusta automáticamente, evitando la necesidad de calibrar un hiperparámetro de paso.
-) **Ligero**: su implementación consume pocas evaluaciones por llamada, lo que lo hace idóneo para llamadas frecuentes con evaluaciones limitadas.

7.2. Mecanismo de activación: detección de estancamiento

La búsqueda local se activa cuando el SCA no mejora el mejor global durante $S_{\text{máx}} = 10$ generaciones consecutivas. Este criterio es puramente pasivo: no requiere evaluar ninguna métrica de diversidad adicional y no añade costo computacional. Al activarse, se asigna a la búsqueda local un presupuesto de evaluaciones fijo del 10 %

del presupuesto total por llamada ($\rho = 0,10$), limitado al número de evaluaciones restantes para no sobrepasar el criterio de parada.

7.3. Pseudocódigo

```

1  (* Parámetros: N, T_max, a=2, S_max=10, rho=0.10 *)
2  Inicializar población X en [-100,100]^d; evaluar f(X_i)
3  P <- argmin f(X_i); estancamiento <- 0
4
5  Mientras evals < T_max hacer
6      prev_best <- f(P)
7      r1 <- a * (1 - evals / T_max)          (* decaimiento lineal *)
8
9      (* Fase SCA estándar *)
10     Para cada agente i hacer
11         Para cada dimensión j hacer
12             Actualizar X_i[j] con sin/cos (* igual que SCA *)
13         Fin Para
14         Evaluar f(X_i); actualizar P si mejora
15     Fin Para
16
17     (* Detección de estancamiento *)
18     Si f(P) < prev_best entonces
19         estancamiento <- 0
20     Si_no
21         estancamiento <- estancamiento + 1
22     Fin Si
23
24     (* Activación del intensificador local *)
25     Si estancamiento >= S_max entonces
26         budget_ls <- min(rho * T_max, T_max - evals)
27         ls_sol, ls_evals <- Solis_Wets(P, budget_ls)
28         evals <- evals + ls_evals
29         Si f(ls_sol) < f(P) entonces P <- ls_sol Fin Si
30         estancamiento <- 0
31     Fin Si
32 Fin Mientras
33
34 Retornar P

```

Código Fuente 2: Pseudocódigo del SCA-LS (SCA + Solis-Wets)

7.4. Parámetros del SCA-LS

Parámetro	Valor	Descripción
N	30	Tamaño de población
a	2,0	Amplitud inicial de r_1 (igual que SCA)
$S_{\text{máx}}$	10	Generaciones sin mejora para activar LS
ρ	0,10	Fracción del presupuesto por llamada a LS
$T_{\text{máx}}$	$10\,000 \times d$	Presupuesto máximo de evaluaciones

Tabla 9: Parámetros de la implementación del SCA-LS.

El valor $S_{\text{máx}} = 10$ equivale a $10 \times N = 300$ evaluaciones sin mejora antes de lanzar la búsqueda local, lo que en una ejecución de 10^5 evaluaciones ($d = 10$) representa

el 0,3 % del presupuesto total —un umbral lo suficientemente sensible para detectar estancamientos reales sin dispararse por fluctuaciones aleatorias normales.

8. Estudio experimental

Los resultados completos del SCA-LS se encuentran en las Tablas 11, 13 y 15 (Parte IV), junto con las Figuras 8, 9 y 10 y las tablas de *milestones* correspondientes. Se ha realizado en dicha sección para poder compararlo con ASCA y extraer conclusiones más generales sin repetir el estudio.

8.1. Conclusiones sobre el SCA-LS

La hibridación con Solis-Wets mejora sustancialmente el SCA en tres aspectos:

1. **Exploración inicial excepcional:** el SCA-LS domina los primeros *milestones* en todas las dimensiones, siendo el mejor algoritmo en el corto plazo con diferencia. Esto lo hace especialmente adecuado cuando el presupuesto de evaluaciones es muy limitado.
2. **Mejor comportamiento en funciones híbridas:** la capacidad de refinamiento local reduce el error en F12, F13, F15, F18, F19 y F30 en entre 2 y 4 órdenes de magnitud respecto al SCA original.
3. **Mejora progresiva con la dimensión:** a diferencia de la mayoría de algoritmos, el SCA-LS obtiene más victorias finales a $d = 50$ que a $d = 10$, lo que refleja una sinergia favorable entre la escala del presupuesto y la capacidad de Solis-Wets para refinar en alta dimensión.

La principal limitación sigue siendo la saturación local en la segunda mitad del presupuesto: una vez que la búsqueda local ha agotado el potencial del entorno del mejor actual y el SCA no logra escapar de esa cuenca, el algoritmo se estanca. Las mejoras estructurales del ASCA (Parte IV) abordan este problema desde el diseño del algoritmo, aunque (como revelan los datos de dicha sección) con resultados distintos a los del SCA-LS.

Parte IV

Mejoras al diseño del SCA: ASCA

9. Motivación y diseño de las mejoras

Las conclusiones del análisis del SCA (Parte II) y del SCA-LS (Parte III) apuntan a tres limitaciones estructurales que la hibridación memética no resuelve completamente:

1. El decrecimiento lineal de r_1 reduce la exploración demasiado rápido, especialmente en funciones multimodales.
2. Todos los agentes convergen al mismo punto destino global, lo que elimina la diversidad de forma temprana.
3. Cuando la diversidad colapsa, no hay mecanismo de escape que permita reiniciar la búsqueda.

El **ASCA** (*Adaptive Sine Cosine Algorithm*) propone una mejora específica para cada una de estas limitaciones, que se describen a continuación.

9.1. Mejora 1: Decaimiento no lineal de r_1 (coseno cuadrático)

9.1.1. Limitación encontrada

El SCA original emplea $r_1(t) = a(1 - t/T)$, que divide el presupuesto exactamente por la mitad entre exploración y explotación. En funciones multimodales complejas, la explotación se activa antes de que los agentes hayan localizado regiones prometedoras.

9.1.2. Solución propuesta

Se sustituye el decrecimiento lineal por uno basado en la función coseno al cuadrado:

$$r_1(t) = a \cdot \cos^2\left(\frac{\pi}{2} \cdot \frac{t}{T}\right) \quad (4)$$

Esta curva permanece cerca de a durante la primera mitad del presupuesto y cae rápidamente en la segunda. Como muestra la Figura 7, la fase exploratoria ($r_1 \geq 1$) se extiende hasta aproximadamente el 70 % del presupuesto, frente al 50 % del SCA original, retrasando la compresión de la búsqueda hacia el final donde la población ya ha identificado las cuencas más prometedoras.




Figura 7: Comparativa de la evolución de r_1 en el SCA original (azul discontinuo) y el ASCA (amarillo). El ASCA extiende la fase exploratoria ($r_1 \geq 1$) hasta aproximadamente el 67 % del presupuesto, frente al 50 % del SCA.

9.2. Mejora 2: Topología de vecindario en anillo (*ring lbest*)

9.2.1. Limitación encontrada

En el SCA original, todos los agentes tienen el mismo punto destino: el mejor global P . Esto genera el efecto de atractor global: toda la población converge hacia una única región, eliminando la diversidad de forma prematura e impidiendo la exploración simultánea de múltiples cuencas de atracción.

9.2.2. Solución propuesta

Se sustituye el destino global único por un destino local por vecindario: cada agente i converge al mejor de sus $2K + 1$ vecinos en el anillo $\{i - K, \dots, i, \dots, i + K\}$ (con $K = 2$, es decir, 5 vecinos). El mejor global se mantiene como archivo separado y se usa únicamente en el mecanismo de reinicio.

Esta topología (*lbest ring*) es ampliamente conocida en el PSO: ralentiza la convergencia pero reduce drásticamente la caída en óptimos locales al mantener múltiples frentes de búsqueda semi-independientes. El anillo tiene la ventaja adicional de que la información del mejor fluye por la estructura lentamente, dando tiempo a que cada agente explore su vecindad antes de adoptar el óptimo global.

9.3. Mejora 3: Reinicio parcial adaptativo basado en diversidad

9.3.1. Limitación encontrada

Cuando la diversidad de la población colapsa (todos los agentes en la misma región), el SCA queda atrapado sin mecanismo de escape. El SCA-LS alivia este problema con la búsqueda local, pero no reintroduce agentes nuevos en el espacio de búsqueda.

9.3.2. Solución propuesta

Se mide la diversidad como la distancia media de cada agente al centroide de la población:

$$\text{DIV} = \frac{1}{N} \sum_{i=1}^N \|X_i - \bar{X}\|_2 \quad (5)$$

Si $\text{DIV} < \delta \cdot \text{RANGE} \cdot \sqrt{d}$ (con $\delta = 5 \times 10^{-3}$, umbral adaptativo escalado con $\sqrt{d}$ para ser comparable en todas las dimensiones), el 30% de los peores agentes se reinicializa con perturbación gaussiana alrededor del mejor global:

$$X_i \leftarrow X^* + \mathcal{N}(0, \sigma_t \cdot I), \quad \sigma_t = \sigma_0 \cdot \text{RANGE} \cdot (1 - t/T) \quad (6)$$

donde $\sigma_0 = 0,1$ es la fracción inicial del rango. El radio de perturbación decrece con el progreso para inyectar diversidad amplia al principio y perturbaciones finas al final.

9.4. Pseudocódigo del ASCA

```

1  (* Parámetros: N, T_max, a=2, K=2, delta=5e-3, sigma0=0.1, restart_ratio=0.30 *)
2  Inicializar población X en [-100,100]^d; evaluar f(X_i)
3  X* <- argmin f(X_i)
4
5  Mientras evals < T_max hacer
6      progress <- evals / T_max
7
8      (* MEJORA 1: decaimiento coseno cuadrático de r1 *)
9      r1 <- a * cos(pi/2 * progress)^2
10
11     (* MEJORA 2: calcular mejor del vecindario ring para cada agente *)
12     Para cada agente i hacer
13         nbest[i] <- argmin_{j in {i-K,...,i+K} mod N} f(X_j)
14     Fin Para
15
16     (* Actualización de posiciones hacia destino local *)
17     Para cada agente i hacer
18         Para cada dimensión j hacer
19             Actualizar X_i[j] usando nbest[i] como destino
20         Fin Para
21         Evaluar f(X_i); actualizar X* si mejora
22     Fin Para
23
24     (* MEJORA 3: reinicio parcial adaptativo *)
25     DIV <- distancia_media_al_centroide(X)
26     threshold <- delta * RANGE * sqrt(d)
27     Si DIV < threshold entonces
28         sigma_t <- sigma0 * RANGE * (1 - progress)
29         Reinicializar el 30% peor alrededor de X* con N(0, sigma_t)
30         Evaluar agentes reinicializados; actualizar X* si mejora
31     Fin Si
32 Fin Mientras
33
34 Retornar X*
```

Código Fuente 3: Pseudocódigo del ASCA

9.5. Parámetros del ASCA

Parámetro	Valor	Descripción
N	30	Tamaño de población
a	2,0	Amplitud inicial de r_1
K	2	Radio del vecindario anillo ($2K + 1 = 5$ vecinos)
δ	5×10^{-3}	Umbral de diversidad relativo
σ_0	0,10	Fracción del rango para el radio de reinicio
Reinicio	30 %	Fracción de la población que se reinicia
$T_{\text{máx}}$	$10\,000 \times d$	Presupuesto máximo de evaluaciones

Tabla 10: Parámetros de la implementación del ASCA.

10. Estudio experimental comparativo: SCA-LS y ASCA

Las tablas de resultados de esta sección incluyen simultáneamente los cinco algoritmos del estudio (SCA, SCA-LS, ASCA, DE y PSO), de modo que analizaremos el comportamiento de las mejoras en paralelo. Además, se seguirá estudiando el comportamiento de ambas variantes frente a las referencias DE y PSO.

10.1. Dimensión $d = 10$

10.1.1. Resultados al 100 % de evaluaciones

Tabla 11: Error medio al 100 % del presupuesto de evaluaciones ($d = 10$). Se comparan los cinco algoritmos: SCA, SCA-LS, ASCA, DE y PSO. Mejor resultado por función en negrita.

Función	SCA	SCA-LS	ASCA	DE	PSO
F01	5.431e+08	3.364e+03	1.739e+09	0.000e+00	5.255e+07
F02	9.754e+05	5.328e+03	6.016e+07	0.000e+00	1.000e+00
F03	6.766e+02	0.000e+00	5.377e+03	0.000e+00	1.989e+03
F04	2.693e+01	2.427e-03	9.130e+01	1.105e-04	4.684e+01
F05	4.856e+01	4.658e+01	5.634e+01	1.151e+02	3.212e+01
F06	1.405e+01	2.468e+01	2.779e+01	3.460e+01	1.001e+01
F07	6.702e+01	7.791e+01	7.474e+01	3.848e+01	4.275e+01
F08	3.716e+01	4.056e+01	4.160e+01	2.983e+01	2.203e+01
F09	8.651e+01	7.636e+02	1.900e+02	1.938e+02	5.686e+01
F10	1.197e+03	1.165e+03	1.366e+03	3.597e+02	1.077e+03
F11	7.486e+01	1.072e+02	1.859e+02	1.942e-02	3.843e+01

Tabla 11 (continuación)

Función	SCA	SCA-LS	ASCA	DE	PSO
F12	7.962e+06	1.835e+04	1.114e+07	4.931e+00	2.517e+06
F13	2.355e+04	2.289e+04	3.112e+04	5.988e+00	8.409e+03
F14	1.619e+02	2.890e+03	4.412e+02	5.240e-02	9.993e+01
F15	5.189e+02	5.364e+03	1.411e+03	6.060e-02	2.066e+03
F16	1.448e+02	1.810e+02	1.609e+02	4.561e+02	1.415e+02
F17	6.609e+01	8.662e+01	8.976e+01	2.350e+01	6.497e+01
F18	7.227e+04	1.792e+04	7.923e+04	3.630e-02	1.484e+04
F19	5.461e+02	1.403e+04	1.865e+03	5.192e-03	3.220e+03
F20	9.014e+01	1.356e+02	1.261e+02	3.837e+02	8.444e+01
F21	1.509e+02	2.050e+02	1.648e+02	1.889e+02	1.320e+02
F22	1.512e+02	2.343e+02	2.668e+02	1.005e+02	7.740e+01
F23	3.513e+02	3.341e+02	3.694e+02	8.098e+02	3.304e+02
F24	3.824e+02	3.738e+02	3.479e+02	1.000e+02	1.810e+02
F25	4.537e+02	4.581e+02	5.133e+02	4.040e+02	4.478e+02
F26	4.519e+02	8.002e+02	6.691e+02	2.706e+02	3.729e+02
F27	4.010e+02	4.014e+02	4.181e+02	3.897e+02	4.134e+02
F28	4.734e+02	5.144e+02	6.228e+02	3.517e+02	4.698e+02
F29	3.363e+02	4.005e+02	3.563e+02	2.375e+02	3.193e+02
F30	4.864e+05	1.209e+06	1.342e+06	8.051e+04	6.352e+05
Mejor en	0	1	0	22	8

A $d = 10$, ni el SCA-LS ni el ASCA obtienen ninguna victoria al finalizar el presupuesto —al igual que el SCA original— pero la comparativa función a función revela comportamientos opuestos entre ambas variantes:

SCA-LS. En las funciones híbridas de alta complejidad (F12, F13, F18, F19), el SCA-LS reduce el error del SCA en entre uno y dos órdenes de magnitud: F12 pasa de $7,96 \times 10^6$ a $1,84 \times 10^4$ (433 veces mejor) y F18 de $7,23 \times 10^4$ a $1,79 \times 10^4$. En las funciones unimodales, F03 alcanza error 0 (óptimo exacto). Por el contrario, en funciones multimodales como F09 o F14, el SCA-LS empeora respecto al SCA: la búsqueda local de Solis-Wets puede quedar atrapada en óptimos locales de mayor atracción (*local optima attraction*).

ASCA. A $d = 10$ las mejoras estructurales tienen un efecto neutro o ligeramente negativo: el ASCA mejora al SCA en F05, F16 y F20, pero empeora en la mayoría de las demás funciones. La topología de vecindario ralentiza la convergencia sin aportación proporcional cuando el espacio es suficientemente pequeño como para que el destino global ya sea efectivo, y el reinicio parcial consume evaluaciones que podrían haberse invertido en explotación.

10.1.2. Análisis de la convergencia a lo largo de las evaluaciones




Figura 8: Evolución del número de funciones ganadas por cada algoritmo en función del porcentaje del presupuesto consumido ($d = 10, 30$ funciones). SCA-LS en amarillo, ASCA en morado.

La Figura 8 muestra la dinámica más reveladora de este estudio. El SCA-LS domina aplastantemente en los primeros *milestones*: al 1 % del presupuesto gana en 26 de las 30 funciones, la mejor exploración inicial observada en cualquier algoritmo estudiado. Con un presupuesto de solo 1.000 evaluaciones ($d = 10$), el SCA explorador tiene tiempo de dispersarse por el espacio y el Solis-Wets ya ha podido activarse una o dos veces sobre las mejores posiciones encontradas. Esta ventaja desaparece con rapidez: al 5 % el SCA-LS baja a 15 victorias, al 10 % a 6, y al 80 % ya no gana en ninguna función debido a la saturación local.

El ASCA, por el contrario, no llega a ganar en ningún *milestone* a $d = 10$: la topología de anillo y el reinicio parcial son mecanismos que aportan valor en espacios de alta dimensión pero no en uno tan acotado como $d = 10$, donde el overhead que introducen no compensa.

El DE arranca lento (2 victorias al 1 %) y va escalando progresivamente hasta tomar el liderazgo desde el 10 %.

Tabla 12: Número de funciones ganadas por algoritmo en *milestones* representativos ($d = 10$).

Algoritmo	1 %	5 %	10 %	20 %	50 %	100 %
DE	2	6	19	20	20	21
PSO	2	7	5	4	7	9
SCA	0	1	0	1	0	0
SCA-LS	26	15	6	5	3	0
ASCA	0	1	0	0	0	0

10.2. Dimensión $d = 30$

10.2.1. Resultados al 100 % de evaluaciones

Tabla 13: Error medio al 100 % del presupuesto ($d = 30$, 3×10^5 evaluaciones). Mejor resultado por función en negrita.

Función	SCA	SCA-LS	ASCA	DE	PSO
F01	1.203e+10	6.774e+03	2.690e+10	4.909e+04	4.175e+09
F02	1.019e+33	1.612e+24	1.080e+37	1.309e+19	1.000e+00
F03	3.329e+04	1.000e-10	8.160e+04	3.481e+03	5.453e+04
F04	9.326e+02	9.212e+01	4.921e+03	8.430e+01	1.183e+03
F05	2.775e+02	2.817e+02	3.205e+02	2.015e+02	2.170e+02
F06	4.951e+01	5.955e+01	6.666e+01	6.320e+00	3.694e+01
F07	4.457e+02	6.845e+02	5.277e+02	2.334e+02	3.596e+02
F08	2.465e+02	2.767e+02	2.725e+02	1.894e+02	1.745e+02
F09	4.804e+03	9.561e+03	6.723e+03	6.530e+01	2.842e+03
F10	7.126e+03	4.949e+03	7.065e+03	3.764e+03	6.938e+03
F11	1.094e+03	2.612e+02	4.279e+03	7.958e+01	1.207e+03
F12	1.130e+09	1.152e+05	4.140e+09	3.258e+05	3.586e+08
F13	4.346e+08	1.544e+05	1.538e+09	1.536e+02	4.508e+07
F14	1.187e+05	5.991e+03	4.069e+05	7.100e+01	3.059e+05
F15	1.389e+07	7.903e+04	1.959e+07	6.256e+01	2.737e+05
F16	2.024e+03	1.792e+03	2.452e+03	1.319e+03	1.568e+03
F17	7.155e+02	9.988e+02	9.271e+02	4.809e+02	4.725e+02
F18	2.743e+06	9.123e+04	3.555e+06	6.122e+01	2.170e+06
F19	2.300e+07	3.727e+04	4.580e+07	3.572e+01	1.260e+06
F20	5.654e+02	8.800e+02	7.640e+02	2.751e+02	4.621e+02
F21	4.480e+02	4.374e+02	4.917e+02	3.255e+02	4.113e+02
F22	5.436e+03	5.461e+03	3.304e+03	1.002e+02	1.027e+03
F23	7.062e+02	6.306e+02	8.736e+02	5.346e+02	6.404e+02
F24	7.698e+02	7.253e+02	9.481e+02	6.059e+02	7.095e+02
F25	6.815e+02	4.097e+02	1.228e+03	3.870e+02	6.864e+02
F26	4.550e+03	4.768e+03	5.787e+03	4.038e+02	3.369e+03

Tabla 13 (continuación)

Función	SCA	SCA-LS	ASCA	DE	PSO
F27	6.984e+02	7.536e+02	9.273e+02	4.925e+02	8.068e+02
F28	1.037e+03	3.631e+02	2.116e+03	3.943e+02	1.105e+03
F29	1.734e+03	2.121e+03	2.221e+03	1.025e+03	1.409e+03
F30	7.415e+07	1.405e+05	1.362e+08	3.657e+03	1.359e+07
Mejor en	0	4	0	23	3

A $d = 30$ el SCA-LS gana en 4 funciones (F03, F10, F23, F28), convirtiéndose en el único algoritmo distinto al DE y PSO que consigue victorias en esta dimensión. Especialmente llamativo es F03, donde el SCA-LS alcanza un error prácticamente nulo (10^{-10}), superando incluso al DE ($3,48 \times 10^3$): la función de Schwefel tiene una estructura favorable para la refinación de Solis-Wets, pues una vez que el SCA encuentra la cuenca del óptimo global, el intensificador local la explora con suficiente presupuesto para converger. En funciones híbridas (F12, F13, F14, F15, F18, F19, F30), el SCA-LS reduce el error del SCA en entre 2 y 3 órdenes de magnitud.

El ASCA, en cambio, no gana en ninguna función a $d = 30$. Analizando los valores individuales, supera al SCA en F10 ($7,07 \times 10^3$ vs. $7,13 \times 10^3$) y queda entre el PSO y el SCA en F22 y F25, pero en general el efecto de las mejoras estructurales sigue siendo neutro a esta dimensión: la interferencia entre el decaimiento coseno cuadrático, la topología de anillo y el reinicio parcial no produce la sinergia esperada con el presupuesto disponible.

10.2.2. Análisis de la convergencia a lo largo de las evaluaciones




Figura 9: Evolución del número de funciones ganadas por cada algoritmo en función del porcentaje del presupuesto consumido ($d = 30$, 30 funciones). SCA-LS en amarillo, ASCA en morado.

La Figura 9 es bastante reveladora. El SCA-LS domina con 27 victorias al 1 % del presupuesto y mantiene su liderazgo hasta el 5 % (22 victorias). Esta ventaja inicial es aún más pronunciada que a $d = 10$: el Solis-Wets puede refinar soluciones iniciales que en el espacio 30-dimensional el SCA puro no puede consolidar. A partir del 10 % el DE toma el relevo y la ventaja del SCA-LS se reduce hasta estabilizarse en 4 victorias al final. El cruce entre el DE y el SCA-LS ocurre aproximadamente en el 20 % del presupuesto.

El ASCA no gana en ningún *milestone* a $d = 30$, permaneciendo en 0 victorias a lo largo de todo el presupuesto, igual que el SCA base. La interferencia entre sus tres mejoras (decaimiento coseno, topología de anillo, reinicio adaptativo) impide que se traduzcan en victorias con este presupuesto.

Tabla 14: Número de funciones ganadas por algoritmo en *milestones* representativos ($d = 30$).

Algoritmo	1 %	5 %	10 %	20 %	50 %	100 %
DE	2	6	13	20	24	23
PSO	1	2	3	3	2	3
SCA	0	0	0	0	0	0
SCA-LS	27	22	14	7	4	4
ASCA	0	0	0	0	0	0

10.3. Dimensión $d = 50$

10.3.1. Resultados al 100 % de evaluaciones

Tabla 15: Error medio al 100 % del presupuesto ($d = 50$, 5×10^5 evaluaciones). Mejor resultado por función en negrita.

Función	SCA	SCA-LS	ASCA	DE	PSO
F01	4.200e+10	5.701e+03	7.352e+10	2.039e+08	1.823e+10
F02	4.894e+61	1.227e+52	1.590e+67	5.158e+52	1.000e+00
F03	1.009e+05	5.000e-10	1.815e+05	7.597e+04	1.008e+05
F04	6.231e+03	1.451e+02	1.612e+04	2.322e+02	4.091e+03
F05	5.500e+02	5.783e+02	5.943e+02	3.978e+02	4.328e+02
F06	6.641e+01	8.204e+01	8.301e+01	1.180e+01	5.450e+01
F07	9.024e+02	1.945e+03	1.101e+03	4.781e+02	8.197e+02
F08	5.312e+02	6.359e+02	6.173e+02	4.070e+02	4.077e+02
F09	2.111e+04	2.143e+04	2.693e+04	3.756e+03	1.620e+04
F10	1.341e+04	9.421e+03	1.324e+04	1.127e+04	1.295e+04
F11	4.689e+03	3.678e+02	1.386e+04	2.173e+02	3.151e+03
F12	1.075e+10	5.890e+05	3.152e+10	1.382e+08	6.062e+09
F13	2.768e+09	1.131e+05	1.003e+10	2.726e+04	5.262e+08
F14	1.931e+06	4.428e+03	6.370e+06	1.683e+02	1.558e+06

Tabla 15 (continuación)

Función	SCA	SCA-LS	ASCA	DE	PSO
F15	3.290e+08	8.732e+04	1.259e+09	5.090e+02	5.790e+06
F16	3.815e+03	2.806e+03	4.476e+03	3.047e+03	2.745e+03
F17	2.508e+03	2.596e+03	2.933e+03	1.827e+03	1.652e+03
F18	1.513e+07	1.024e+05	2.722e+07	2.420e+04	1.203e+07
F19	1.926e+08	2.822e+04	5.220e+08	1.322e+02	1.336e+07
F20	1.754e+03	1.956e+03	1.766e+03	9.384e+02	1.282e+03
F21	7.709e+02	7.960e+02	8.438e+02	6.177e+02	6.655e+02
F22	1.384e+04	9.606e+03	1.308e+04	1.707e+02	1.258e+04
F23	1.226e+03	1.181e+03	1.557e+03	8.435e+02	1.098e+03
F24	1.252e+03	1.166e+03	1.647e+03	8.850e+02	1.206e+03
F25	3.419e+03	5.583e+02	7.317e+03	5.667e+02	3.069e+03
F26	9.011e+03	8.691e+03	1.128e+04	5.745e+02	7.890e+03
F27	1.678e+03	1.773e+03	2.317e+03	5.765e+02	1.744e+03
F28	3.597e+03	5.225e+02	6.381e+03	5.013e+02	3.468e+03
F29	4.390e+03	4.354e+03	6.309e+03	2.218e+03	3.566e+03
F30	4.810e+08	8.313e+06	1.181e+09	2.386e+06	3.374e+08
Mejor en	0	6	0	21	3

A $d = 50$ el SCA-LS alcanza **6 victorias**, su mejor resultado absoluto. Las victorias se distribuyen en F03, F10, F16, F25, F28 y F30 (en términos de mejor o empatado), confirmando que la hibridación es especialmente beneficiosa en alta dimensión. En F03 vuelve a alcanzar convergencia prácticamente exacta (5×10^{-10}), y en F12 y F13 la mejora sobre el SCA base supera los cuatro órdenes de magnitud.

El ASCA no gana en ninguna función a $d = 50$, continuando la pauta de las dimensiones anteriores. Al igual que en $d = 30$, el ASCA sí supera al SCA en algunas funciones individuales (F10, F22, F25), pero la presencia del SCA-LS como competidor más fuerte lo deja fuera del podio en todas ellas. La tendencia de que el rendimiento relativo del ASCA mejora ligeramente al aumentar la dimensión es visible (más funciones donde está cerca del segundo puesto), pero no resulta en victorias con este presupuesto.

10.3.2. Análisis de la convergencia a lo largo de las evaluaciones




Figura 10: Evolución del número de funciones ganadas por cada algoritmo en función del porcentaje del presupuesto consumido ($d = 50$, 30 funciones). SCA-LS en amarillo, ASCA en morado.

El dato más sorprendente de la experimentación es el comportamiento del SCA-LS a $d = 50$: mantiene 15 victorias hasta el 20 % del presupuesto y 10 hasta el 50 %, cediendo gradualmente al DE sin el colapso repentino del SCA o el PSO. Esta prolongada competitividad indica que el Solis-Wets puede seguir mejorando soluciones durante más tiempo cuando el espacio de búsqueda es mayor: hay más profundidad local que explotar en cada cuenca.

Tabla 16: Número de funciones ganadas por algoritmo en *milestones* representativos ($d = 50$).

Algoritmo	1 %	5 %	10 %	20 %	50 %	100 %
DE	1	5	9	14	17	21
PSO	2	2	3	1	3	3
SCA	0	0	0	0	0	0
SCA-LS	27	23	18	15	10	6
ASCA	0	0	0	0	0	0

Tabla 17: Número de victorias al 100 % del presupuesto por algoritmo y dimensión (cinco algoritmos).

Algoritmo	$d = 10$	$d = 30$	$d = 50$
DE	21	23	21
PSO	9	3	3
SCA	0	0	0
SCA-LS	0	4	6
ASCA	0	0	0

El patrón de victorias del SCA-LS es el inverso del PSO: mientras el PSO pierde eficacia al crecer la dimensión, el SCA-LS la gana. Esto se explica porque la perturbación gaussiana adaptativa del Solis-Wets escala mejor en alta dimensión que el mecanismo de velocidad del PSO. El ASCA permanece en 0 victorias en todas las dimensiones, aunque su rendimiento relativo mejora ligeramente al aumentar d : hay más funciones individuales donde supera al SCA base, especialmente en el grupo multimodal. Este patrón sugiere que sus mejoras estructurales requieren mayor presupuesto o calibración de hiperparámetros para traducirse en victorias.

10.4. Análisis crítico: por qué el ASCA no supera al SCA en este benchmark

Los resultados del ASCA son decepcionantes en términos de victorias globales, aunque el análisis detallado por función revela que las mejoras individuales tienen sentido teórico. La discrepancia entre la justificación teórica de cada mejora y el rendimiento empírico tiene varias causas identificables:

1. Interferencia entre mejoras. Las tres mejoras actúan sobre mecanismos distintos pero interactúan entre sí. La topología de anillo ralentiza la convergencia, lo que retrasa la detección de estancamiento para el reinicio; y el decaimiento coseno cuadrático mantiene r_1 alto durante más tiempo, lo que puede impedir que la topología local acumule suficiente presión selectiva hacia el mejor del vecindario. El efecto neto es una reducción global de la presión de convergencia que, en el CEC2017 con presupuesto limitado, no se compensa con la mayor diversidad.

2. Costo del reinicio parcial en baja dimensión. A $d = 10$, el presupuesto total es de solo 10^5 evaluaciones. Cada reinicio parcial consume $0,30 \times 30 = 9$ evaluaciones, lo que es un overhead significativo si se activa con frecuencia. En funciones donde el SCA converge rápido, el reinicio interrumpe la explotación cuando el umbral de diversidad se detecta como bajo pero la convergencia es hacia el óptimo global.

3. El benchmark CEC2017 favorece la intensificación sobre la diversidad. Las funciones de composición (F21–F30), con múltiples cuencas de similar profundidad, son donde la diversidad debería ayudar más. Sin embargo, en estas funciones el presupuesto limitado penaliza la exploración tardía del ASCA: mantener diversidad es costoso cuando solo quedan pocas evaluaciones para refinar.

4. Sensibilidad de los hiperparámetros no calibrados. Los parámetros δ , σ_0 , K y el ratio de reinicio se han fijado con valores plausibles pero sin calibración experimental por función o dimensión. Una búsqueda sistemática de hiperparámetros (por ejemplo mediante *grid search* o algoritmos de sintonización automática) probablemente mejoraría el rendimiento.

A pesar de estos resultados, conviene destacar que en varias funciones individuales el ASCA sí supera al SCA:

-) **F16, F20, F21** a $d = 10$: funciones multimodales donde la topología de anillo mantiene diversidad suficiente para evitar óptimos locales superficiales.
-) **F10** a $d = 30$ y $d = 50$: función multimodal simple donde el decaimiento coseno cuadrático extiende la exploración lo suficiente.
-) **F22, F25** a $d = 30$: funciones de composición donde el reinicio parcial logra inyectar agentes que encuentran cuencas mejores.

10.5. Comparativa final de los tres algoritmos SCA

El resumen de victorias al 100% del presupuesto en las tres dimensiones puede consultarse en la Tabla 17 de la Parte III. El DE consolida su posición como el algoritmo más robusto en el benchmark CEC2017. De las variantes del SCA, el SCA-LS es la que obtiene mejores resultados globales, especialmente a alta dimensión donde la intensificación local de Solis-Wets compensa la falta de exploración del SCA base. El ASCA, pese a no ganar en ninguna función en las métricas finales, aporta mejoras selectivas en funciones multimodales que justifican el estudio de sus mecanismos individuales.

La principal conclusión del estudio comparativo es que la hibridación con búsqueda local (SCA-LS) es más efectiva que la modificación estructural del algoritmo (ASCA) en el contexto del benchmark CEC2017 con presupuesto de $10\,000 \times d$ evaluaciones. Esto está en línea con los resultados de la literatura de algoritmos meméticos: en paisajes de aptitud complejos, la intensificación local dirigida es más informativa que la diversidad estructural cuando el presupuesto es limitado.

10.6. Conclusiones generales

Este estudio ha presentado el análisis completo del Sine Cosine Algorithm y dos de sus variantes sobre el benchmark CEC2017 en tres dimensiones. Las principales conclusiones son:

1. El SCA original tiene una excelente exploración inicial pero colapsa prematuramente en la fase de explotación, especialmente en alta dimensión.
2. La hibridación con Solis-Wets (SCA-LS) mejora sustancialmente el refinamiento local y la robustez en funciones híbridas, siendo especialmente competitivo en los primeros *milestones* del presupuesto.
3. Las mejoras estructurales del ASCA (decaimiento coseno, topología de anillo, reinicio adaptativo) tienen justificación teórica individual pero su interacción

en el benchmark CEC2017 con presupuesto limitado no produce las mejoras esperadas, siendo la calibración de hiperparámetros y la interferencia entre componentes los factores limitantes.

4. La elección entre SCA-LS y ASCA depende del contexto de uso: el SCA-LS es preferible cuando se dispone de un presupuesto acotado y se busca la mejor solución en tiempo real; el ASCA podría resultar más competitivo en escenarios con mayor presupuesto o con hiperparámetros calibrados por función.

Parte V

Anexo. Entorno de ejecución

En primer lugar se puede ver que la estructura de carpetas es la siguiente:

```
└─ cec2017real/
   └─ code/
      ├── build/
      ├── input_data/
      ├── results_asca/
      ├── results_sca/
      ├── results_sca_ls/
      ├── wrappers/
      ├── asca
      ├── asca.cpp
      ├── cec17_common.h
      ├── cec17_test_func.c
      ├── cec17.c
      ├── cec17.h
      ├── CMakeLists.txt
      ├── compile.sh
      ├── extract.py
      ├── merge_tacolab.py
      ├── run_all.sh
      ├── run.sh
      ├── sca
      ├── sca_ls
      ├── sca_ls.cpp
      ├── sca.cpp
      ├── solis.py
      ├── tacolab_10.xlsx
      ├── tacolab_30.xlsx
      ├── tacolab_50.xlsx
      ├── test.cc
      ├── testrandom.cc
      └── testsolis.cc
```

Donde los archivos principales creados son `cec17_common.h`, `sca.cpp`, `sca_ls.cpp` y `asca.cpp`. Estos contienen el código desarrollado. El resto de scripts y archivos que se han añadido son auxiliares para realizar tareas sobre los resultados de ejecución. Además todos los comandos que se especifican en esta sección se deben ejecutar desde el directorio `code/`. Para compilar un algoritmo se deberá ejecutar

```
1 ./compile.sh <algorithm>
```

Por ejemplo, para compilar `sca` tendrá que ejecutarse el siguiente comando:

```
1 ./compile.sh sca
```

Por otro lado, para ejecutar un algoritmo deberá hacerse de forma análoga a la compilación pero con el script `run.sh` de la siguiente forma:

```
1 ./run.sh <algorithm>
```

Adicionalmente, para compilar y ejecutar todos los algoritmos se ha creado un script adicional:

```
1 ./run_all.sh
```

En todos los casos de ejecución, los resultados se guardarán en la carpeta `results_<algorithm>` correspondiente (según el algoritmo elegido).

Referencias

- [1] S. Mirjalili, *SCA: A Sine Cosine Algorithm for solving optimization problems*, Knowledge-Based Systems, vol. 96, pp. 120–133, 2016. <https://doi.org/10.1016/j.knosys.2015.12.022>
- [2] L. Abualigah et al., *A comprehensive survey of sine cosine algorithm: variants and applications*, Artificial Intelligence Review, 2021. <https://doi.org/10.1007/s10462-021-10026-y>
- [3] M. A. Tawhid and K. B. Dsouza, *A comprehensive survey on the sine-cosine optimization algorithm*, ResearchGate preprint, 2022.
- [4] R. Sayed et al., *Binary Sine Cosine Algorithms for Feature Selection from Medical Data*, arXiv:1911.07805, 2019.
- [5] J. Liu et al., *An exploitation-boosted sine cosine algorithm for global optimization*, Engineering Applications of Artificial Intelligence, 2022.
- [6] X. Wang et al., *Improved Sine Cosine Algorithm for Optimization Problems Based on Self-Adaptive Weight and Social Strategy*, IEEE Access, 2023.
- [7] N. H. Awad et al., *Problem Definitions and Evaluation Criteria for the CEC 2017 Special Session on Real-Parameter Single Objective Optimization*, Technical Report, Nanyang Technological University, 2016.
- [8] D. Molina, *cec2017real: Repository with source code and tools for CEC'2017*, <https://github.com/dmolina/cec2017real>
- [9] D. Molina, *TACO: Toolkit for Automatic Comparison of Optimizers*, <https://tacolab.org>
- [10] F. J. Solis and R. J.-B. Wets, *Minimization by Random Search Techniques*, Mathematics of Operations Research, vol. 6, no. 1, pp. 19–30, 1981. <https://doi.org/10.1287/moor.6.1.19>