

Modelos matemáticos II: Optimización en dimensión finita

Juan Calvo Yagüe, Departamento de Matemática Aplicada

Universidad de Granada

Curso 2025-2026

Departamento de
Matemática
Aplicada



Disponible bajo licencia Creative
Commons 4.0 Internacional



Generalidades sobre optimización 1d

Sea $f : D \rightarrow \mathbb{R}$ tal que $f(x) > -\infty \forall x \in D \subset \mathbb{R}$.

Diremos que f **alcanza su mínimo** (global) si existen $x_0 \in D$, $m > -\infty$ tales que:

- 1 $f(x_0) = m$,
- 2 $f(x) \geq f(x_0) \forall x \in D$.

Generalidades sobre optimización 1d

Sea $f : D \rightarrow \mathbb{R}$ tal que $f(x) > -\infty \forall x \in D \subset \mathbb{R}$.

Diremos que f **alcanza su mínimo** (global) si existen $x_0 \in D$, $m > -\infty$ tales que:

- ❶ $f(x_0) = m$,
- ❷ $f(x) \geq f(x_0) \forall x \in D$.

En cuyo caso diremos que:

- f alcanza su mínimo (global) en x_0 .
- El mínimo de f en D es el valor numérico m .
- $x_0 \in \operatorname{argmin}_D f = \{x \in D / f(x) = m\}$.

Generalidades sobre optimización 1d

Sea $f : D \rightarrow \mathbb{R}$ tal que $f(x) > -\infty \forall x \in D \subset \mathbb{R}$.

Diremos que f **alcanza su mínimo** (global) si existen $x_0 \in D$, $m > -\infty$ tales que:

- 1 $f(x_0) = m$,
- 2 $f(x) \geq f(x_0) \forall x \in D$.

En cuyo caso diremos que:

- f alcanza su mínimo (global) en x_0 .
- El mínimo de f en D es el valor numérico m .
- $x_0 \in \operatorname{argmin}_D f = \{x \in D / f(x) = m\}$.

Si $f(x_0) < f(x) \forall x \in D \setminus \{x_0\}$, el mínimo global será estricto.

Generalidades sobre optimización 1d

Sea $f : D \rightarrow \mathbb{R}$ tal que $f(x) > -\infty \forall x \in D \subset \mathbb{R}$.

Diremos que f **alcanza su mínimo** (global) si existen $x_0 \in D$, $m > -\infty$ tales que:

- 1 $f(x_0) = m$,
- 2 $f(x) \geq f(x_0) \forall x \in D$.

En cuyo caso diremos que:

- f alcanza su mínimo (global) en x_0 .
- El mínimo de f en D es el valor numérico m .
- $x_0 \in \operatorname{argmin}_D f = \{x \in D / f(x) = m\}$.

Si $f(x_0) < f(x) \forall x \in D \setminus \{x_0\}$, el mínimo global será estricto.

Para el caso de máximos se revierte todo lo anterior.

Extremos locales

Sea D un intervalo y $f : D \rightarrow \mathbb{R}$.

Diremos que f **alcanza un mínimo local** en $x_0 \in \overset{\circ}{D}$ si existe un intervalo abierto $I \subset D$ tal que $x_0 \in I$ y $f(x) \geq f(x_0) \forall x \in I$.

Extremos locales

Sea D un intervalo y $f : D \rightarrow \mathbb{R}$.

Diremos que f **alcanza un mínimo local** en $x_0 \in \overset{\circ}{D}$ si existe un intervalo abierto $I \subset D$ tal que $x_0 \in I$ y $f(x) \geq f(x_0) \forall x \in I$.

De forma análoga para mínimo local estricto y para máximos locales.

Extremo local = máximo o mínimo local.

Algunos espacios funcionales

Sea $I \subset \mathbb{R}$ un intervalo.

$$C(I) := \{f : I \rightarrow \mathbb{R} / f(x) \text{ es continua } \forall x \in I\} = C^0(I).$$

Algunos espacios funcionales

Sea $I \subset \mathbb{R}$ un intervalo.

$$C(I) := \{f : I \rightarrow \mathbb{R} / f(x) \text{ es continua } \forall x \in I\} = C^0(I).$$

Si I es abierto, $C^1(I) := \{f \in C(I) / f' \in C(I)\}.$

Algunos espacios funcionales

Sea $I \subset \mathbb{R}$ un intervalo.

$$C(I) := \{f : I \rightarrow \mathbb{R} / f(x) \text{ es continua } \forall x \in I\} = C^0(I).$$

Si I es abierto, $C^1(I) := \{f \in C(I) / f' \in C(I)\}$.

Si $I = [a, b]$,
 $C^1(I) := \{f \in C(I) / f' \in C(]a, b[), f' \text{ tiene límites finitos en } a, b\}$.

De forma similar para intervalos semiabiertos.

Algunos espacios funcionales

Sea $I \subset \mathbb{R}$ un intervalo.

$$C(I) := \{f : I \rightarrow \mathbb{R} / f(x) \text{ es continua } \forall x \in I\} = C^0(I).$$

Si I es abierto, $C^1(I) := \{f \in C(I) / f' \in C(I)\}.$

Si $I = [a, b]$,
 $C^1(I) := \{f \in C(I) / f' \in C(]a, b[), f' \text{ tiene límites finitos en } a, b\}.$

De forma similar para intervalos semiabiertos.

Generalizaciones: $C^k(I)$ con $k \in \mathbb{N}$, $C^\infty(I).$

Condiciones para extremo local

Condición necesaria de extremo local (I)

Sean I abierto, $f \in C^1(I)$, $x_0 \in I$. Si x_0 es un extremo local, entonces $f'(x_0) = 0$.

Condición suficiente de extremo local

Sean I abierto, $f \in C^2(I)$. Si $x_0 \in I$ es tal que $f'(x_0) = 0$ y $f''(x_0) > 0$, entonces en x_0 se alcanza un mínimo local (“ x_0 es un mínimo local”).

(Resp. $f''(x_0) < 0$ para máximo local.)

Condiciones para extremo local

Condición necesaria de extremo local (I)

Sean I abierto, $f \in C^1(I)$, $x_0 \in I$. Si x_0 es un extremo local, entonces $f'(x_0) = 0$.

Condición suficiente de extremo local

Sean I abierto, $f \in C^2(I)$. Si $x_0 \in I$ es tal que $f'(x_0) = 0$ y $f''(x_0) > 0$, entonces en x_0 se alcanza un mínimo local (“ x_0 es un mínimo local”).

(Resp. $f''(x_0) < 0$ para máximo local.)

- Si $f'(x_0) = f''(x_0) = 0$, este análisis no permite concluir nada.
- Si f no es derivable en x_0 , este análisis no se puede aplicar en x_0 .
- El cálculo de $f'(x)$ podría no ser factible.

Desarrollos de Taylor

Sean $I \subset \mathbb{R}$ abierto, $f \in C^2(I)$, $x_0 \in I$. Entonces,

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2}(x - x_0)^2 + R[f](x) \quad \forall x \in I.$$

Aquí $R[f](x) = o((x - x_0)^2)$ para $x \rightarrow x_0$; es decir,

$$\lim_{x \rightarrow x_0} \frac{R[f](x)}{(x - x_0)^2} = 0.$$

Desarrollos de Taylor

Sean $I \subset \mathbb{R}$ abierto, $f \in C^2(I)$, $x_0 \in I$. Entonces,

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2}(x - x_0)^2 + R[f](x) \quad \forall x \in I.$$

Aquí $R[f](x) = o((x - x_0)^2)$ para $x \rightarrow x_0$; es decir,

$$\lim_{x \rightarrow x_0} \frac{R[f](x)}{(x - x_0)^2} = 0.$$

Si $f \in C^3(I)$, entonces $R[f](x) = O((x - x_0)^3)$ para $x \rightarrow x_0$; es decir,

existe $C > 0$ tal que $|R[f](x)| \leq C|x - x_0|^3$ para $x \rightarrow x_0$.

De hecho, en estas circunstancias existe ξ_0 entre x_0 y x tal que

$$R[f](x) = \frac{f'''(\xi_0)}{3!}(x - x_0)^3.$$

Optimización global en intervalos

Buscamos determinar los extremos globales de $f : D \rightarrow \mathbb{R}$.

Si D no está acotado, hay que estudiar el comportamiento en infinito.

Si D no es abierto, hay que estudiar el comportamiento en la frontera (en dimensión uno suele bastar con hacer una lista de las evaluaciones de f en la frontera).

En general, los extremos no necesariamente se van a alcanzar.

Direcciones admisibles

Dado D no necesariamente abierto, diremos que f **alcanza un mínimo local** en $x_0 \in D$ si existe $I \subset \mathbb{R}$ abierto tal que $x_0 \in D \cap I$ cumple que $f(x_0) \leq f(x) \forall x \in D \cap I$.

Direcciones admisibles

Dado D no necesariamente abierto, diremos que f **alcanza un mínimo local** en $x_0 \in D$ si existe $I \subset \mathbb{R}$ abierto tal que $x_0 \in D \cap I$ cumple que $f(x_0) \leq f(x) \forall x \in D \cap I$.

Diremos que $v \in \mathbb{R}$ es una **dirección admisible** para x_0 en D si existe $\epsilon > 0$ tal que el segmento dado por x_0 y $x_0 + \epsilon v$ está contenido en D (realmente basta considerar $v = \pm 1$).

En ese caso, se define la **derivada direccional** asociada (derivada lateral en este caso) mediante

$$\delta_v f(x_0) := \lim_{h \searrow 0} \frac{f(x_0 + hv) - f(x_0)}{h}.$$

Direcciones admisibles

Dado D no necesariamente abierto, diremos que f **alcanza un mínimo local** en $x_0 \in D$ si existe $I \subset \mathbb{R}$ abierto tal que $x_0 \in D \cap I$ cumple que $f(x_0) \leq f(x) \forall x \in D \cap I$.

Diremos que $v \in \mathbb{R}$ es una **dirección admisible** para x_0 en D si existe $\epsilon > 0$ tal que el segmento dado por x_0 y $x_0 + \epsilon v$ está contenido en D (realmente basta considerar $v = \pm 1$).

En ese caso, se define la **derivada direccional** asociada (derivada lateral en este caso) mediante

$$\delta_v f(x_0) := \lim_{h \searrow 0} \frac{f(x_0 + hv) - f(x_0)}{h}.$$

Condición necesaria de extremo local (II)

Sean $f \in C^1(D)$ y $x_0 \in D$. Si en x_0 f alcanza un mínimo local, entonces $v f'(x_0) \geq 0$ para toda v dirección admisible para x_0 .

Nociones de convexidad

Sean D un intervalo y $f : D \rightarrow \mathbb{R}$. Diremos que f suficientemente regular **es convexa** en D si se cumple alguna de las siguientes condiciones:

- 1 $f''(x) \geq 0 \quad \forall x \in \overset{\circ}{D}$.
- 2 $f(x_1) \geq f(x_0) + f'(x_0)(x_1 - x_0) \quad \forall x_0, x_1 \in \overset{\circ}{D}$.
- 3 $f(\theta x_0 + (1 - \theta)x_1) \leq \theta f(x_0) + (1 - \theta)f(x_1),$
 $\forall x_0, x_1 \in D, \forall \theta \in [0, 1]$.

Nociones de convexidad

Sean D un intervalo y $f : D \rightarrow \mathbb{R}$. Diremos que f suficientemente regular **es convexa** en D si se cumple alguna de las siguientes condiciones:

- 1 $f''(x) \geq 0 \quad \forall x \in \overset{\circ}{D}$.
- 2 $f(x_1) \geq f(x_0) + f'(x_0)(x_1 - x_0) \quad \forall x_0, x_1 \in \overset{\circ}{D}$.
- 3 $f(\theta x_0 + (1 - \theta)x_1) \leq \theta f(x_0) + (1 - \theta)f(x_1),$
 $\forall x_0, x_1 \in D, \forall \theta \in [0, 1]$.

Hablamos de **convexidad estricta** si todas las desigualdades son estrictas (con $x_0 \neq x_1$ en 2,3 y $\theta \in (0, 1)$ en 3).

Hablamos de **concavidad** si le damos la vuelta a las desigualdades.

Nociones de convexidad

Sean D un intervalo y $f : D \rightarrow \mathbb{R}$. Diremos que f suficientemente regular **es convexa** en D si se cumple alguna de las siguientes condiciones:

- 1 $f''(x) \geq 0 \quad \forall x \in \overset{\circ}{D}$.
- 2 $f(x_1) \geq f(x_0) + f'(x_0)(x_1 - x_0) \quad \forall x_0, x_1 \in \overset{\circ}{D}$.
- 3 $f(\theta x_0 + (1 - \theta)x_1) \leq \theta f(x_0) + (1 - \theta)f(x_1),$
 $\forall x_0, x_1 \in D, \forall \theta \in [0, 1]$.

Hablamos de **convexidad estricta** si todas las desigualdades son estrictas (con $x_0 \neq x_1$ en 2,3 y $\theta \in (0, 1)$ en 3).

Hablamos de **concavidad** si le damos la vuelta a las desigualdades.

Dada $f : D \rightarrow \mathbb{R}$ convexa, todo mínimo local (de existir) es global. Además, como mucho hay un mínimo global. Podría no alcanzarse el mínimo, y de alcanzarse, no necesariamente está en el interior.

Generalidades sobre optimización en dimensión finita

Consideramos $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$.

Denotamos $x = (x_1, \dots, x_n)^T \in \mathbb{R}^n$.

Mínimos y máximos locales y globales se definen de forma análoga a dimensión uno; para conceptos locales se sustituyen intervalos abiertos por entornos abiertos (basta considerar bolas abiertas).

Generalidades sobre optimización en dimensión finita

Consideramos $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$.

Denotamos $x = (x_1, \dots, x_n)^T \in \mathbb{R}^n$.

Mínimos y máximos locales y globales se definen de forma análoga a dimensión uno; para conceptos locales se sustituyen intervalos abiertos por entornos abiertos (basta considerar bolas abiertas).

En $\mathbb{R}^n$ todas las normas son equivalentes, de forma que basta usar bolas relativas a la norma 2 usual, que denotamos por $|x|$:

$$B(c, R) := \{x \in \mathbb{R}^n / |x - c| < R\}, \quad \overline{B(c, R)} = \{x \in \mathbb{R}^n / |x - c| \leq R\}.$$

Generalidades sobre optimización en dimensión finita

Consideramos $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$.

Denotamos $x = (x_1, \dots, x_n)^T \in \mathbb{R}^n$.

Mínimos y máximos locales y globales se definen de forma análoga a dimensión uno; para conceptos locales se sustituyen intervalos abiertos por entornos abiertos (basta considerar bolas abiertas).

En $\mathbb{R}^n$ todas las normas son equivalentes, de forma que basta usar bolas relativas a la norma 2 usual, que denotamos por $|x|$:

$$B(c, R) := \{x \in \mathbb{R}^n / |x - c| < R\}, \quad \overline{B(c, R)} = \{x \in \mathbb{R}^n / |x - c| \leq R\}.$$

$$\nabla f : D \rightarrow \mathbb{R}^n, \quad \nabla f(x) := \left(\frac{\partial f}{\partial x_1}(x), \dots, \frac{\partial f}{\partial x_n}(x) \right)^T.$$

Conjuntos de nivel

Se definen los **conjuntos de nivel** de f como

$$S_c := \{x \in D / f(x) = c\}, \quad \text{para cualquier } c \in \mathbb{R}.$$

Conjuntos de nivel



Se definen los **conjuntos de nivel** de f como

$$S_c := \{x \in D/f(x) = c\}, \quad \text{para cualquier } c \in \mathbb{R}.$$

$\nabla f(x_0)$ es normal al conjunto de nivel $S_{f(x_0)}$ en el punto x_0 . En otras palabras, $\nabla f(x_0)$ es perpendicular al vector tangente en x_0 de cualquier curva que pase por x_0 y esté contenida en $S_{f(x_0)}$. Además, $\nabla f(x_0)$ es la dirección de crecimiento más rápido a partir de x_0 .


El espacio tangente a $S_{f(x_0)}$ en x_0 vienen dado por $(x - x_0)^T \nabla f(x_0) = 0$ (siempre que $\nabla f(x_0) \neq 0$).

Conjuntos de nivel



(E.K.P. Chong, S. H. Zak, An introduction to optimization. Wiley 2008)

Conjuntos de nivel



(CAD UGR)

Condiciones para extremo local

Condición necesaria de extremo local

Sean $\Omega \subset \mathbb{R}^n$ abierto, $f \in C^1(\Omega)$, $x_0 \in \Omega$. Si f alcanza un extremo local en x_0 , entonces $\nabla f(x_0) = 0$.

Condiciones para extremo local

Condición necesaria de extremo local

Sean $\Omega \subset \mathbb{R}^n$ abierto, $f \in C^1(\Omega)$, $x_0 \in \Omega$. Si f alcanza un extremo local en x_0 , entonces $\nabla f(x_0) = 0$.

Situaciones prototípicas para $D \subset \mathbb{R}^2$ vienen dadas por:

- $f(x, y) = x^2 + y^2$ (*mínimo local*).
- $f(x, y) = -x^2 - y^2$ (*máximo local*).
- $f(x, y) = x^2 - y^2$ (*punto de silla*).

Condiciones para extremo local

Condición necesaria de extremo local

Sean $\Omega \subset \mathbb{R}^n$ abierto, $f \in C^1(\Omega)$, $x_0 \in \Omega$. Si f alcanza un extremo local en x_0 , entonces $\nabla f(x_0) = 0$.


Situaciones prototípicas para $D \subset \mathbb{R}^2$ vienen dadas por:

- $f(x, y) = x^2 + y^2$ (*mínimo local*).
- $f(x, y) = -x^2 - y^2$ (*máximo local*).
- $f(x, y) = x^2 - y^2$ (*punto de silla*).

Estas funciones se pueden representar como formas cuadráticas:

$$f(x, y) = (x \ y) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$

$$f(x, y) = (x \ y) \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$



Condiciones para extremo local

Condición necesaria de extremo local


Sean $\Omega \subset \mathbb{R}^n$ abierto, $f \in C^1(\Omega)$, $x_0 \in \Omega$. Si f alcanza un extremo local en x_0 , entonces $\nabla f(x_0) = 0$.

Situaciones prototípicas para $D \subset \mathbb{R}^2$ vienen dadas por:

- $f(x, y) = x^2 + y^2$ (*mínimo local*).
- $f(x, y) = -x^2 - y^2$ (*máximo local*).
- $f(x, y) = x^2 - y^2$ (*punto de silla*).

Estas funciones se pueden representar como formas cuadráticas:

$$f(x, y) = (x \ y) \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$



Formas cuadráticas

Dada $Q \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica, definimos $f_Q : \mathbb{R}^n \rightarrow \mathbb{R}$,
 $f_Q(x) := x^T Q x$.

Formas cuadráticas

Dada $Q \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica, definimos $f_Q : \mathbb{R}^n \rightarrow \mathbb{R}$, $f_Q(x) := x^T Q x$.

Diremos que f_Q , o análogamente la propia matriz Q , es definida positiva (denotado $Q > 0$) si $f_Q(x) > 0 \forall x \in \mathbb{R}^n \setminus \{0\}$.

- Semidefinida positiva ($Q \geq 0$).
- Definida negativa ($Q < 0$).
- Semidefinida negativa ($Q \leq 0$).
- Indefinida.

Formas cuadráticas

Dada $Q \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica, definimos $f_Q : \mathbb{R}^n \rightarrow \mathbb{R}$, $f_Q(x) := x^T Q x$.

Diremos que f_Q , o análogamente la propia matriz Q , es definida positiva (denotado $Q > 0$) si $f_Q(x) > 0 \forall x \in \mathbb{R}^n \setminus \{0\}$.

- Semidefinida positiva ($Q \geq 0$).
- Definida negativa ($Q < 0$).
- Semidefinida negativa ($Q \leq 0$).
- Indefinida.

Teorema de Sylvester

Sea $Q \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica. Equivalen:

- 1 $Q > 0$.
- 2 Todos los valores propios de Q son estrictamente positivos.
- 3 Todos los menores principales de Q son estrictamente positivos.

Formas cuadráticas

Dada $Q \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica, definimos $f_Q : \mathbb{R}^n \rightarrow \mathbb{R}$, $f_Q(x) := x^T Q x$.

Diremos que f_Q , o análogamente la propia matriz Q , es definida positiva (denotado $Q > 0$) si $f_Q(x) > 0 \forall x \in \mathbb{R}^n \setminus \{0\}$.

- Semidefinida positiva ($Q \geq 0$).
- Definida negativa ($Q < 0$).
- Semidefinida negativa ($Q \leq 0$).
- Indefinida.



Ley de inercia de Sylvester

Sea $Q \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica. Entonces, el número de valores propios positivos n_+ , el número de valores propios negativos n_- y el número de valores propios cero n_0 permanecen constantes bajo cambio de base.

Formas cuadráticas

Ley de inercia de Sylvester

Sea $Q \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica. Entonces, el número de valores propios n_+ , el número de valores propios negativos n_- y el número de valores propios cero n_0 permanecen constantes bajo cambio de base.



Desarrollos de Taylor

Lema de Swarz

Sea $f \in C^2(\Omega)$. Entonces $\text{Hess } f(x_0) = D^2f(x_0)$ es una matriz simétrica, y define una forma cuadrática.

Desarrollos de Taylor

Lema de Swarz

Sea $f \in C^2(\Omega)$. Entonces $\text{Hess } f(x_0) = D^2f(x_0)$ es una matriz simétrica, y define una forma cuadrática.

Dado $x_0 \in \Omega$, para $x \in \Omega$ se cumple que

$$f(x) = f(x_0) + (x - x_0)^T \nabla f(x_0) + \frac{1}{2} (x - x_0)^T D^2f(x_0) (x - x_0) + o(|x - x_0|^2).$$

Desarrollos de Taylor

Lema de Swarz

Sea $f \in C^2(\Omega)$. Entonces $\text{Hess } f(x_0) = D^2f(x_0)$ es una matriz simétrica, y define una forma cuadrática.

Dado $x_0 \in \Omega$, para $x \in \Omega$ se cumple que

$$f(x) = f(x_0) + (x - x_0)^T \nabla f(x_0) + \frac{1}{2} (x - x_0)^T D^2f(x_0) (x - x_0) + o(|x - x_0|^2).$$

Condiciones de segundo orden para mínimo local

Sean Ω abierto, $x_0 \in \Omega$ y $f \in C^2(\Omega)$.

- ➊ Si x_0 es *mínimo local*, entonces $\nabla f(x_0) = 0$ y $D^2f(x_0) \geq 0$.
- ➋ Si $\nabla f(x_0) = 0$ y $D^2f(x_0) > 0$, entonces x_0 es *mínimo local estricto*.


Desarrollos de Taylor

Lema de Swarz

Sea $f \in C^2(\Omega)$. Entonces $\text{Hess } f(x_0) = D^2f(x_0)$ es una matriz simétrica, y define una forma cuadrática.

Dado $x_0 \in \Omega$, para $x \in \Omega$ se cumple que

$$f(x) = f(x_0) + (x - x_0)^T \nabla f(x_0) + \frac{1}{2} (x - x_0)^T D^2f(x_0) (x - x_0) + o(|x - x_0|^2).$$



(Wikipedia: By Nicoguaro)

Optimización global

El máximo y/o el mínimo global no necesariamente se alcanzan.

Hay que estudiar tanto la frontera del recinto como las direcciones en las que no está acotado.

Optimización global

El máximo y/o el mínimo global no necesariamente se alcanzan.

Hay que estudiar tanto la frontera del recinto como las direcciones en las que no está acotado.

Dado $x_0 \in D$, diremos que $v \in \mathbb{R}^n \setminus \{0\}$ es **dirección admisible** para f en x_0 si existe $\epsilon_0 > 0$ tal que $x_0 + \epsilon v \in D \forall \epsilon \in [0, \epsilon_0)$.

Se define entonces la derivada direccional asociada según

$$\delta_v f(x_0) := \lim_{h \searrow 0} \frac{f(x_0 + hv) - f(x_0)}{h}.$$

Basta con considerar direcciones con $|v| = 1$. Obsérvese que

$$\delta_v f(x_0) = v^T \nabla f(x_0).$$

Caso de entornos relativos

Condiciones necesarias para mínimo local



Sean $f : D \rightarrow \mathbb{R}$, con $D \subset \mathbb{R}^n$ suficientemente regular, y sea $x_0 \in D$. Entonces:

- 1 Si en x_0 se alcanza un mínimo local, entonces $v^T \nabla f(x_0) \geq 0$ para toda $|v| = 1$ dirección admisible.
- 2 Supongamos que en x_0 se alcanza un mínimo local. Sea v una dirección admisible para x_0 . Si se cumple que $v^T \nabla f(x_0) = 0$, entonces se tiene que $v^T D^2 f(x_0) v \geq 0$.

Optimización con restricciones: dimensión dos

Consideramos $f : \mathbb{R}^2 \rightarrow \mathbb{R}$. Nos planteamos optimizar f sobre

$$D = \{x \in \mathbb{R}^2 / h(x) = 0\}, \quad h : \mathbb{R}^2 \rightarrow \mathbb{R}.$$



(E.K.P. Chong, S. H. Zak, An introduction to optimization. Wiley 2008)

Optimización con restricciones: dimensión dos

Consideramos $f : \mathbb{R}^2 \rightarrow \mathbb{R}$. Nos planteamos optimizar f sobre

$$D = \{x \in \mathbb{R}^2 / h(x) = 0\}, \quad h : \mathbb{R}^2 \rightarrow \mathbb{R}.$$

Sea $x^* \in D$ un punto donde se alcanza un mínimo o máximo de f . Entonces $\nabla f(x^*)$ y $\nabla h(x^*)$ son paralelos. Por tanto, si $\nabla h(x^*) \neq 0$, entonces existe un escalar $\lambda \in \mathbb{R}$ tal que


$$\nabla f(x^*) + \lambda \nabla h(x^*) = 0.$$

(Si $\nabla h(x^*) \neq 0$, decimos que x^* es un punto regular de D .)

Optimización con restricciones: dimensión dos

Figure 20.12 Four examples where the Lagrange condition is satisfied: (a) maximizer, (b) minimizer, (c) minimizer, (d) not an extremizer.

(Adapted from [120].)




(E.K.P. Chong, S. H. Zak, An introduction to optimization. Wiley 2008)

Ejemplo

Determinar los extremos de $f(x, y) = x^2 + y^2$ sobre la elipse $x^2 + 2y^2 = 1$.

Ejemplo

Determinar los extremos de $f(x, y) = x^2 + y^2$ sobre la elipse $x^2 + 2y^2 = 1$.



(E.K.P. Chong, S. H. Zak, An introduction to optimization. Wiley 2008)

Multiplicadores de Lagrange

Consideramos la optimización de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sobre conjuntos dados como la intersección de varias hipersuperficies, descritas a partir de funciones $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, m$:

$$\min_S f, \quad S := \{x \in \mathbb{R}^n / h_1(x) = 0, \dots, h_m(x) = 0\}.$$

Diremos que $x^* \in S$ es un punto regular si $\nabla h_1(x^*), \dots, \nabla h_m(x^*)$ son linealmente independientes.

Multiplicadores de Lagrange

Consideramos la optimización de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sobre conjuntos dados como la intersección de varias hipersuperficies, descritas a partir de funciones $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, m$:

$$\min_S f, \quad S := \{x \in \mathbb{R}^n / h_1(x) = 0, \dots, h_m(x) = 0\}.$$

Diremos que $x^* \in S$ es un punto regular si $\nabla h_1(x^*), \dots, \nabla h_m(x^*)$ son linealmente independientes.

Teorema (Lagrange)

Sea $x^* \in S$ un extremo local de f sobre S . Supongamos que x^* es un punto regular. Entonces existen m escalares $\lambda_1, \dots, \lambda_m \in \mathbb{R}$ (“multiplicadores de Lagrange”) tales que

$$\nabla f(x^*) + \lambda_1 \nabla h_1(x^*) + \dots + \lambda_m \nabla h_m(x^*) = 0.$$

Cocientes de Rayleigh

Consideramos $A \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica. Buscamos el valor mínimo de la función $f : \mathbb{R}^n \setminus \{0\} \rightarrow \mathbb{R}$ dada por

$$f(x) = \frac{x^T A x}{|x|^2} .$$

Cocientes de Rayleigh

Consideramos $A \in \mathcal{M}_{n \times n}(\mathbb{R})$ simétrica. Entonces

$$\lambda_{\min} = \min_{x \neq 0} \frac{\langle x, Ax \rangle}{\langle x, x \rangle}, \quad \lambda_{\max} = \max_{x \neq 0} \frac{\langle x, Ax \rangle}{\langle x, x \rangle}.$$

El cocientes de Rayleigh $\mu : \mathbb{R}^n \rightarrow \mathbb{R}$, $\mu(x) = \frac{\langle x, Ax \rangle}{\langle x, x \rangle}$ verifica:

Sean $\lambda_1 \leq \dots \leq \lambda_n$ los valores propios de A , con vectores propios asociados $\eta_1, \dots, \eta_n$. Entonces:

$$\lambda_i = \min_{0 \neq x \in S^-} \mu(x) = \max_{0 \neq x \in S^+} \mu(x)$$

con

$$S^- := \text{span}(\eta_i, \dots, \eta_n), \quad S^+ := \text{span}(\eta_1, \dots, \eta_i)$$

Nociones de convexidad

Dado $D \subset \mathbb{R}^n$, diremos que **es convexo** si, dados $x_1, x_2 \in D$, entonces $\theta x_0 + (1 - \theta)x_1 \in D, \forall \theta \in [0, 1], \forall x_0, x_1 \in D$.

- $\emptyset$, los semiespacios y $\mathbb{R}^n$ son convexos.
- Las bolas son convexas, las esferas no.
- La intersección de conjuntos convexos es convexa.
- La suma de conjuntos convexos es convexa.




Fig. 1-12. Minkowski sum of two sets.

Nociones de convexidad

Sean $D \subset \mathbb{R}^n$ convexo y $f : D \rightarrow \mathbb{R}$. Diremos que f suficientemente regular **es convexa** en D si se cumple alguna de las siguientes condiciones:

- ❶ $D^2 f(x) \geq 0 \quad \forall x \in \overset{\circ}{D}.$
- ❷ $f(x_1) \geq f(x_0) + (x_1 - x_0)^T \nabla f(x_0) \quad \forall x_0, x_1 \in \overset{\circ}{D}.$
- ❸ $f(\theta x_0 + (1 - \theta)x_1) \leq \theta f(x_0) + (1 - \theta)f(x_1),$
 $\forall x_0, x_1 \in D, \forall \theta \in [0, 1].$

La combinación lineal de funciones convexas es a su vez una función convexa.

Nociones de convexidad

Sean $D \subset \mathbb{R}^n$ convexo y $f : D \rightarrow \mathbb{R}$. Diremos que f suficientemente regular **es convexa** en D si se cumple alguna de las siguientes condiciones:

- ❶ $D^2 f(x) \geq 0 \quad \forall x \in \overset{\circ}{D}$.
- ❷ $f(x_1) \geq f(x_0) + (x_1 - x_0)^T \nabla f(x_0) \quad \forall x_0, x_1 \in \overset{\circ}{D}$.
- ❸ $f(\theta x_0 + (1 - \theta)x_1) \leq \theta f(x_0) + (1 - \theta)f(x_1),$
 $\forall x_0, x_1 \in D, \forall \theta \in [0, 1]$.

La combinación lineal de funciones convexas es a su vez una función convexa.

Dada $f : D \rightarrow \mathbb{R}$ convexa, todo extremo local es un mínimo global. El conjunto de mínimos globales $\operatorname{argmin}_D f$ es convexo. Si f es estrictamente convexa, este conjunto tiene a lo sumo un elemento.

Programación lineal

Example 1.4 (A Blending Problem) A type of linear programming problem frequently encountered is one involving blending. Typically a manufacturer wishes to form a mixture of several commodities that he can purchase so that the blend has known characteristics and costs the least. The percent characteristics of the blend are precisely specified.

A manufacturer wishes to produce an alloy (blend) that is 30 percent lead, 30 percent zinc, and 40 percent tin. Suppose there are on the market alloys $j = 1, \dots, 9$ with the percent composition (of lead, zinc, and tin) and prices as shown in the display below. How much of each type of alloy should be purchased in order to minimize costs per pound of blend?

Alloy	1	2	3	4	5	6	7	8	9	Blend
Lead (%)	20	50	30	30	30	60	40	10	10	30
Zinc (%)	30	40	20	40	30	30	50	30	10	30
Tin (%)	50	10	50	30	40	10	10	60	80	40
Cost (\$/lb)	7.3	6.9	7.3	7.5	7.6	6.0	5.8	4.3	4.1	Min

(G.B. Dantzig, M. N. Thapa, Linear Programming. Springer 1997)

Programación lineal

Alloy	1	2	3	4	5	6	7	8	9	Blend
Lead (%)	20	50	30	30	30	60	40	10	10	30
Zinc (%)	30	40	20	40	30	30	50	30	10	30
Tin (%)	50	10	50	30	40	10	10	60	80	40
Cost (\$/lb)	7.3	6.9	7.3	7.5	7.6	6.0	5.8	4.3	4.1	Min

Obviously the manufacturer can purchase alloy 5 alone, but it will cost him \$7.60 per pound. On the other hand with $\frac{1}{2}$ pound of alloy 2 and $\frac{1}{4}$ pound each of alloys 8 and 9 he will be able to blend a 30-30-40 mixture at a cost of \$5.55 per pound. However, if he buys $\frac{1}{4}$ pound each of alloys, 6, 7, 8, and 9, he will also be able to blend a 30-30-40 mixture at a cost of \$5.05. After a few trials of this sort, the manufacturer may well seek a more scientific approach to his problem.

(G.B. Dantzig, M. N. Thapa, Linear Programming. Springer 1997)

Programación lineal

We shall require that a definite amount of blended metal be produced. It is clear that the most economical purchasing plan for producing one pound of a specified blend can be immediately converted into the most economical purchasing plan for producing n pounds of output simply by multiplying the fractional amounts of each type of alloy by n ; and thus we will restrict the *quantity of alloys to those combinations that produce one pound of specified blend of metal*. This stipulation has the further happy result that the percentage requirements of the original statement of the problem now become concrete: the mixture must contain 0.3 pounds of lead, 0.3 pounds of zinc, and 0.4 pounds of tin.

We shall formulate this model by writing down the material balance constraints. The decision variables are

$$x_j \geq 0, \quad j = 1, \dots, 9,$$

where x_j is the fractional pounds of alloy j to be used in the blend.

(G.B. Dantzig, M. N. Thapa, Linear Programming. Springer 1997)

Programación lineal

There are five items (not four as may have been expected): one for each of the three components (lead, zinc, and tin) of the alloy, the cost of purchasing the alloy, and its weight. As per our discussion above, we shall solve the blending problem for producing exactly one pound of the blend. It is now clear that the problem to be solved is

Minimize the *Objective*

$7.3x_1 + 6.9x_2 + 7.3x_3 + 7.5x_4 + 7.6x_5 + 6.0x_6 + 5.8x_7 + 4.3x_8 + 4.1x_9 = z$
subject to

$$\begin{array}{rrrrrrrrrr} x_1 + & x_2 + & x_3 + & x_4 + & x_5 + & x_6 + & x_7 + & x_8 + & x_9 = & 1 \\ .2x_1 + & .5x_2 + & .3x_3 + & .3x_4 + & .3x_5 + & .6x_6 + & .4x_7 + & .1x_8 + & .1x_9 = & .3 \\ .3x_1 + & .4x_2 + & .2x_3 + & .4x_4 + & .3x_5 + & .3x_6 + & .5x_7 + & .3x_8 + & .1x_9 = & .3 \\ .5x_1 + & .1x_2 + & .5x_3 + & .3x_4 + & .4x_5 + & .1x_6 + & .1x_7 + & .6x_8 + & .8x_9 = & .4 \end{array}$$



and $x_j \geq 0, j = 1, \dots, 9$.

Only minor changes in the model are required in the event the blend specifications are not given precisely but they must lie between certain lower and upper bounds.

(G.B. Dantzig, M. N. Thapa, Linear Programming. Springer 1997)



Programación lineal

Diremos que $A \subset \mathbb{R}^n$ es un **poliedro** si se puede escribir como la intersección de un número finito de semiespacios.



Programación lineal

Diremos que $A \subset \mathbb{R}^n$ es un **poliedro** si se puede escribir como la intersección de un número finito de semiespacios.



Todo poliedro es convexo.

Dado $A \subset \mathbb{R}^n$ un poliedro y $f : A \rightarrow \mathbb{R}$ lineal, son problemas de programación lineal:

$$\min_A f, \quad \min_{\partial A} f \quad (\text{resp. con max}).$$

Programación lineal

Un problema de programación lineal **en forma estandar** consiste en

encontrar valores $x_1, \dots, x_n$

que minimizan $\mathbf{z} = c_1 x_1 + \dots + c_n x_n$

sujeto a las $(m + n)$ restricciones

$$\left. \begin{array}{l} a_{11}x_1 + \dots + a_{1n}x_n \leq b_1 \\ \vdots \\ a_{m1}x_1 + \dots + a_{mn}x_n \leq b_m \end{array} \right\}$$

$$x_j \geq 0, j = 1, \dots, n.$$

(Aquí $a_{ij}, b_i, c_i \in \mathbb{R}$.)

Programación lineal

Un problema de programación lineal **en forma canónica** consiste en

encontrar valores $x_1, \dots, x_s$

que minimizan $\mathbf{z} = c_1 x_1 + \dots + c_s x_s$

sujeto a las $(m + s)$ restricciones

$$\left. \begin{array}{l} a_{11}x_1 + \dots + a_{1s}x_s = b_1 \\ \vdots \\ a_{m1}x_1 + \dots + a_{ms}x_s = b_m \end{array} \right\}$$

$$x_j \geq 0, \quad j = 1, \dots, s.$$

(Aquí $a_{ij}, b_i, c_i \in \mathbb{R}$.)

Transformaciones usuales

1 $\min \sum_{i=1}^n c_i x_i = - \max \left(- \sum_{i=1}^n c_i x_i \right)$

2 $k_1 x_1 + \cdots + k_n x_n \geq b \implies -k_1 x_1 - \cdots - k_n x_n \leq -b$

3 $\sum_{j=1}^n a_{ij} x_j = b_i$ se expresa como

$$\sum_{j=1}^n a_{ij} x_j \leq b_i \quad \text{junto con} \quad \sum_{j=1}^n a_{ij} x_j \geq b_i$$

4 Si $x_j \in \mathbb{R}$ es admisible para el problema, se puede escribir como $x_j = x_j^+ - x_j^-$ con $x_j^+, x_j^- \geq 0$ restringidas.

Slack variables/variables de holgura

$$a_{i1} x_1 + \cdots + a_{in} x_n \leq b_i \rightarrow a_{i1} x_1 + \cdots + a_{in} x_n + u_i = b_i \text{ (con } u_i \geq 0 \text{)}.$$

Transformaciones usuales

Slack variables/variables de holgura

$$a_{i1}x_1 + \cdots + a_{in}x_n \leq b_i \rightarrow a_{i1}x_1 + \cdots + a_{in}x_n + u_i = b_i \text{ (con } u_i \geq 0\text{)}.$$

Dado $(x_1, \dots, x_n)^T$ admisible para un problema en forma estandar, adjuntar las m variables de holgura

$$x_{n+i} = b_i - a_{i1}x_1 - \cdots - a_{in}x_n$$

nos da

$$(x_1, \dots, x_n, x_{n+1}, \dots, x_{n+m})^T$$

admisible para el problema canónico.

Y viceversa, ya que como $x_{n+i} \geq 0$, eliminando las holguras se cumple que


$$a_{i1}x_1 + \cdots + a_{in}x_n \leq b_i.$$

Viabilidad de un programa lineal

Diremos que $x \in \mathbb{R}^n$ **es admisible** (o factible) para un problema dado si cumple el conjunto de restricciones.

Dado K convexo, $p \in K$ se dirá **punto extremo**/extremal si no se puede escribir como combinación convexa de puntos de K que no sean él mismo.

(En otras palabras, no existen $p_1, p_2 \in \mathbb{R}^n$ tales que $p = \theta p_1 + (1 - \theta)p_2$ para algún $\theta \in (0, 1)$.)



Viabilidad de un programa lineal

Diremos que $x \in \mathbb{R}^n$ **es admisible** (o factible) para un problema dado si cumple el conjunto de restricciones.

Dado K convexo, $p \in K$ se dirá **punto extremo**/extremal si no se puede escribir como combinación convexa de puntos de K que no sean él mismo.

(En otras palabras, no existen $p_1, p_2 \in \mathbb{R}^n$ tales que $p = \theta p_1 + (1 - \theta)p_2$ para algún $\theta \in (0, 1)$.)

En el caso de un poliedro, los puntos extremos son sus vértices.

Viabilidad de un programa lineal

Teorema

Para un problema de programación lineal en forma estandar, se cumplen las siguientes propiedades:

- 1 Si el problema no admite solución, entonces el conjunto admisible es vacío o no acotado.
- 2 Por tanto, si el conjunto admisible es no vacío y acotado, el problema admite solución.
- 3 Si el problema admite solución, ésta se alcanza en puntos extremos (si se alcanza en varios, también se alcanza en combinaciones convexas de los mismos).

Viabilidad de un programa lineal

Teorema

Para un problema de programación lineal en forma estandar, se cumplen las siguientes propiedades:

- 1 Si el problema no admite solución, entonces el conjunto admisible es vacío o no acotado.
- 2 Por tanto, si el conjunto admisible es no vacío y acotado, el problema admite solución.
- 3 Si el problema admite solución, ésta se alcanza en puntos extremos (si se alcanza en varios, también se alcanza en combinaciones convexas de los mismos).

Métodos de resolución populares:

Método del simplex, método de Karkarmar,...

Existencia de extremos en dimensión finita

Teorema de Weierstrass

Sea $K \subset \mathbb{R}^d$ compacto y $f : K \rightarrow \mathbb{R}$ continua. Entonces f alcanza su mínimo.

Se define $\alpha := \inf_K f (> -\infty)$.

Se toma $\{x_n\} \subset K$ tal que $\{f(x_n)\} \searrow \alpha$ (**sucesión minimizante**).

Por la compacidad, existe $\bar{x} \in K$ y una parcial $\{x_{n_k}\} \rightarrow \bar{x}$.

Por la continuidad, $\{f(x_{n_k})\} \rightarrow f(\bar{x}) = \alpha$.

Existencia de extremos en dimensión finita

Teorema de Weierstrass

Sea $K \subset \mathbb{R}^d$ compacto y $f : K \rightarrow \mathbb{R}$ continua. Entonces f alcanza su mínimo.

Se define $\alpha := \inf_K f (> -\infty)$.

Se toma $\{x_n\} \subset K$ tal que $\{f(x_n)\} \searrow \alpha$ (**sucesión minimizante**).

Por la compacidad, existe $\bar{x} \in K$ y una parcial $\{x_{n_k}\} \rightarrow \bar{x}$.

Por la continuidad, $\{f(x_{n_k})\} \rightarrow f(\bar{x}) = \alpha$.

¿Y en dimensión infinita?

- Cuantos menos abiertos haya, más conjuntos compactos habrá.
- Cuantos más abiertos haya, más fácil es tener continuidad.

Optimización en dimensión infinita: convenios

En lo sucesivo consideraremos X un espacio vectorial (real).
Dado $\mathcal{D} \subset X$, un funcional $\mathcal{F}$ es una aplicación

$$\mathcal{F} : \mathcal{D} \rightarrow \mathbb{R}$$

Estamos interesados en problemas de la forma $\min_{y \in \mathcal{D}} \mathcal{F}[y]$.

Supondremos que $\mathcal{D}$ (dominio del funcional) es tal que
 $\mathcal{F}[y] > -\infty \forall y \in \mathcal{D}$.

Optimización en dimensión infinita: convenios

En lo sucesivo consideraremos X un espacio vectorial (real).
Dado $\mathcal{D} \subset X$, un funcional $\mathcal{F}$ es una aplicación

$$\mathcal{F} : \mathcal{D} \rightarrow \mathbb{R}$$

Estamos interesados en problemas de la forma $\min_{y \in \mathcal{D}} \mathcal{F}[y]$.

Supondremos que $\mathcal{D}$ (dominio del funcional) es tal que $\mathcal{F}[y] > -\infty \forall y \in \mathcal{D}$.

Diremos que $\mathcal{F}$ alcanza su mínimo global en $y_0 \in \mathcal{D}$ si $\mathcal{F}[y_0] \leq \mathcal{F}[y]$ para todo $y \in \mathcal{D}$. En cuyo caso:

- El mínimo de $\mathcal{F}$ en $\mathcal{D}$ es el valor numérico $\mathcal{F}[y_0]$.
- Diremos que $y_0 \in \operatorname{argmin}_{\mathcal{D}} \mathcal{F}$.
- Si $\mathcal{F}[y_0] < \mathcal{F}[y] \forall y \in \mathcal{D} \setminus \{y_0\}$, el mínimo global se dirá estricto.

Optimización en dimensión infinita: convenios

En lo sucesivo consideraremos X un espacio vectorial (real).
Dado $\mathcal{D} \subset X$, un funcional $\mathcal{F}$ es una aplicación

$$\mathcal{F} : \mathcal{D} \rightarrow \mathbb{R}$$

Estamos interesados en problemas de la forma $\min_{y \in \mathcal{D}} \mathcal{F}[y]$.

Supondremos que $\mathcal{D}$ (dominio del funcional) es tal que
 $\mathcal{F}[y] > -\infty \forall y \in \mathcal{D}$.

Diremos que $\mathcal{F}$ alcanza un mínimo local en $y_0 \in \mathcal{D}$ si
 $\mathcal{F}[y_0] \leq \mathcal{F}[y]$ para todo y en un entorno de y_0 (relativo a $\mathcal{D}$).

Los entornos dependen de la topología considerada. En las topologías inducidas por una norma, los podemos describir por medio de bolas.